

Institut Supérieur d'Informatique et Mathématiques
Monastir

Cours : Big DATA

Chapitre 1: Introduction au Big Data

MAJ: 10/09/2026

Asma KERKENI **asma.kerkeni@gmail.com**

Objectifs

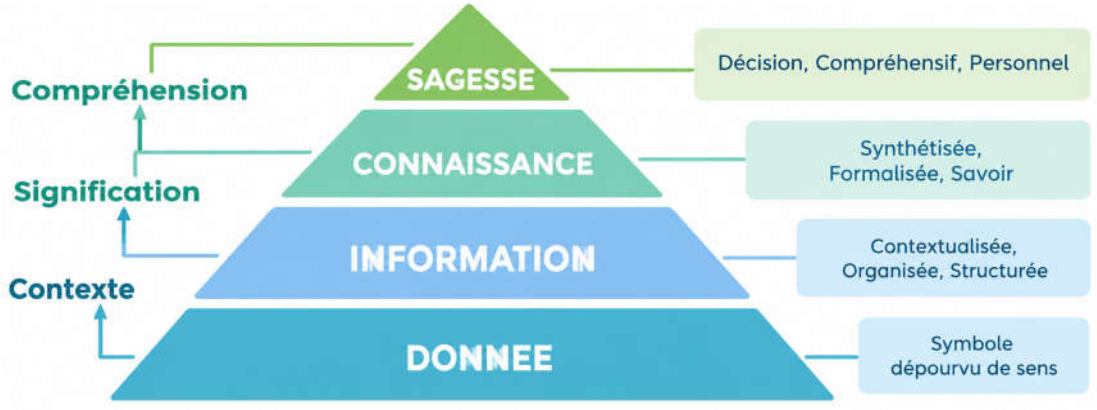
- Au terme de ce chapitre, vous serez capable de:
  - Définir le Big Data
  - Définir les 3Vs
  - Donner des exemples d'applications du Big DATA
  - Donner des chiffres sur les données massives
  - Comprendre la nature de ces données
  - Situer les bases de données NOSQL dans le Big Data

Plan

- Data: c'est quoi?
- Typologie de données
- Explosion des données
- Définition du Big Data
- Les 3V, 4V, 5V
- Applications du Big Data
- Big Data et NOSQL

Data : C'est quoi ?

- Les données sont des symboles qui représentent les propriétés des objets et évènements.
  - Elle n'a pas de sens en elle-même. Elle existe tout simplement.
  - C'est la matière première sur laquelle la plupart des informations sont basées.
  - Exemple:
    - **Données :** { « Ali », « Ben Ahmed », 55}
    - **Information:** Données +sens : {Prénom: « Ali », Nom:« Ben Ahmed », age: 55}



Pyramide DIKW (Data, Information, Knowledge, Wisdom)

Typologie des données

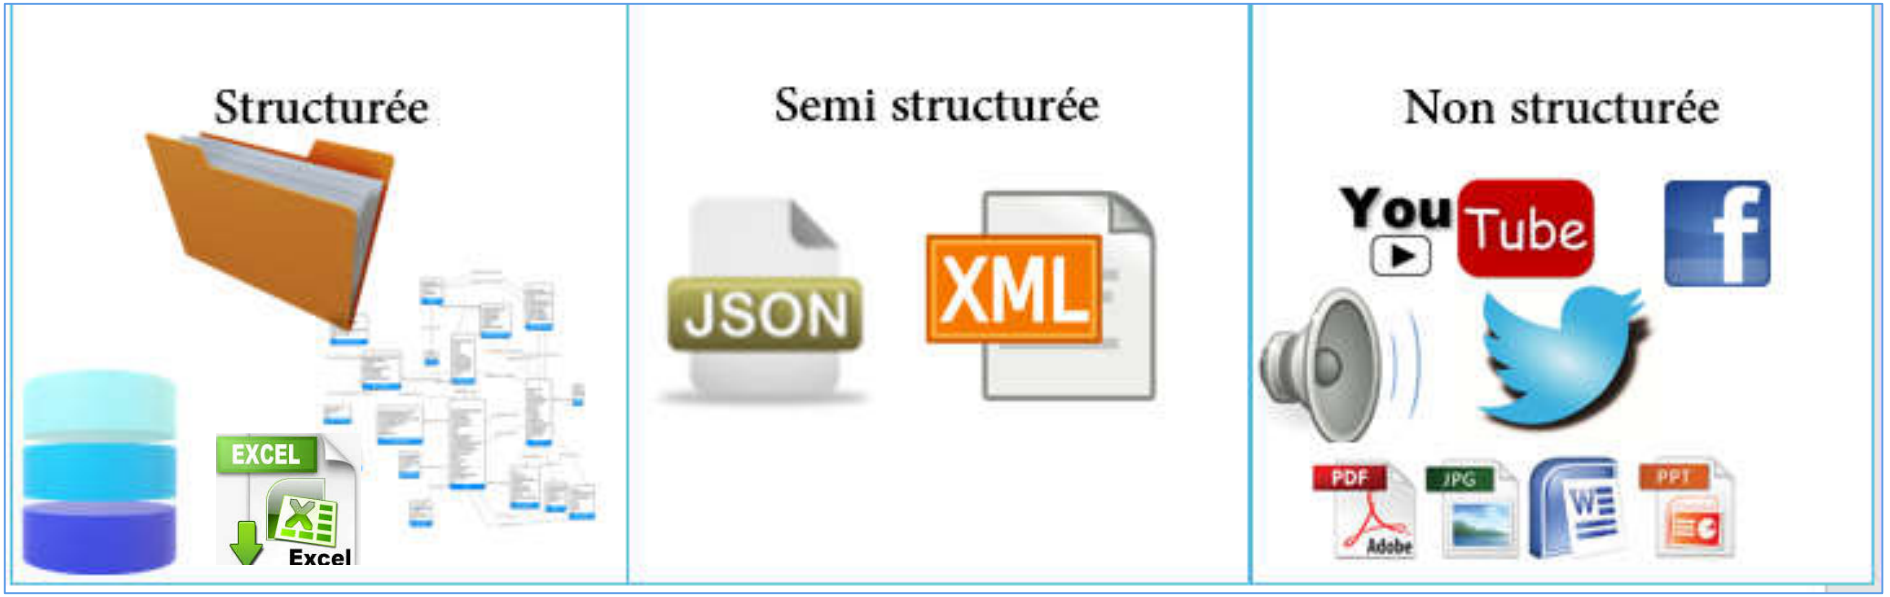
Données qualitatives/ quantitatives:

- **Quantitative:** sont des données qui peuvent être mesurées (taille, poids…) ou repérées (température…)

- **Qualitative:** sont des données auxquelles on ne peut pas attribuer une valeur ou une caractéristique (la couleur, la texture, le goût, l'odeur).

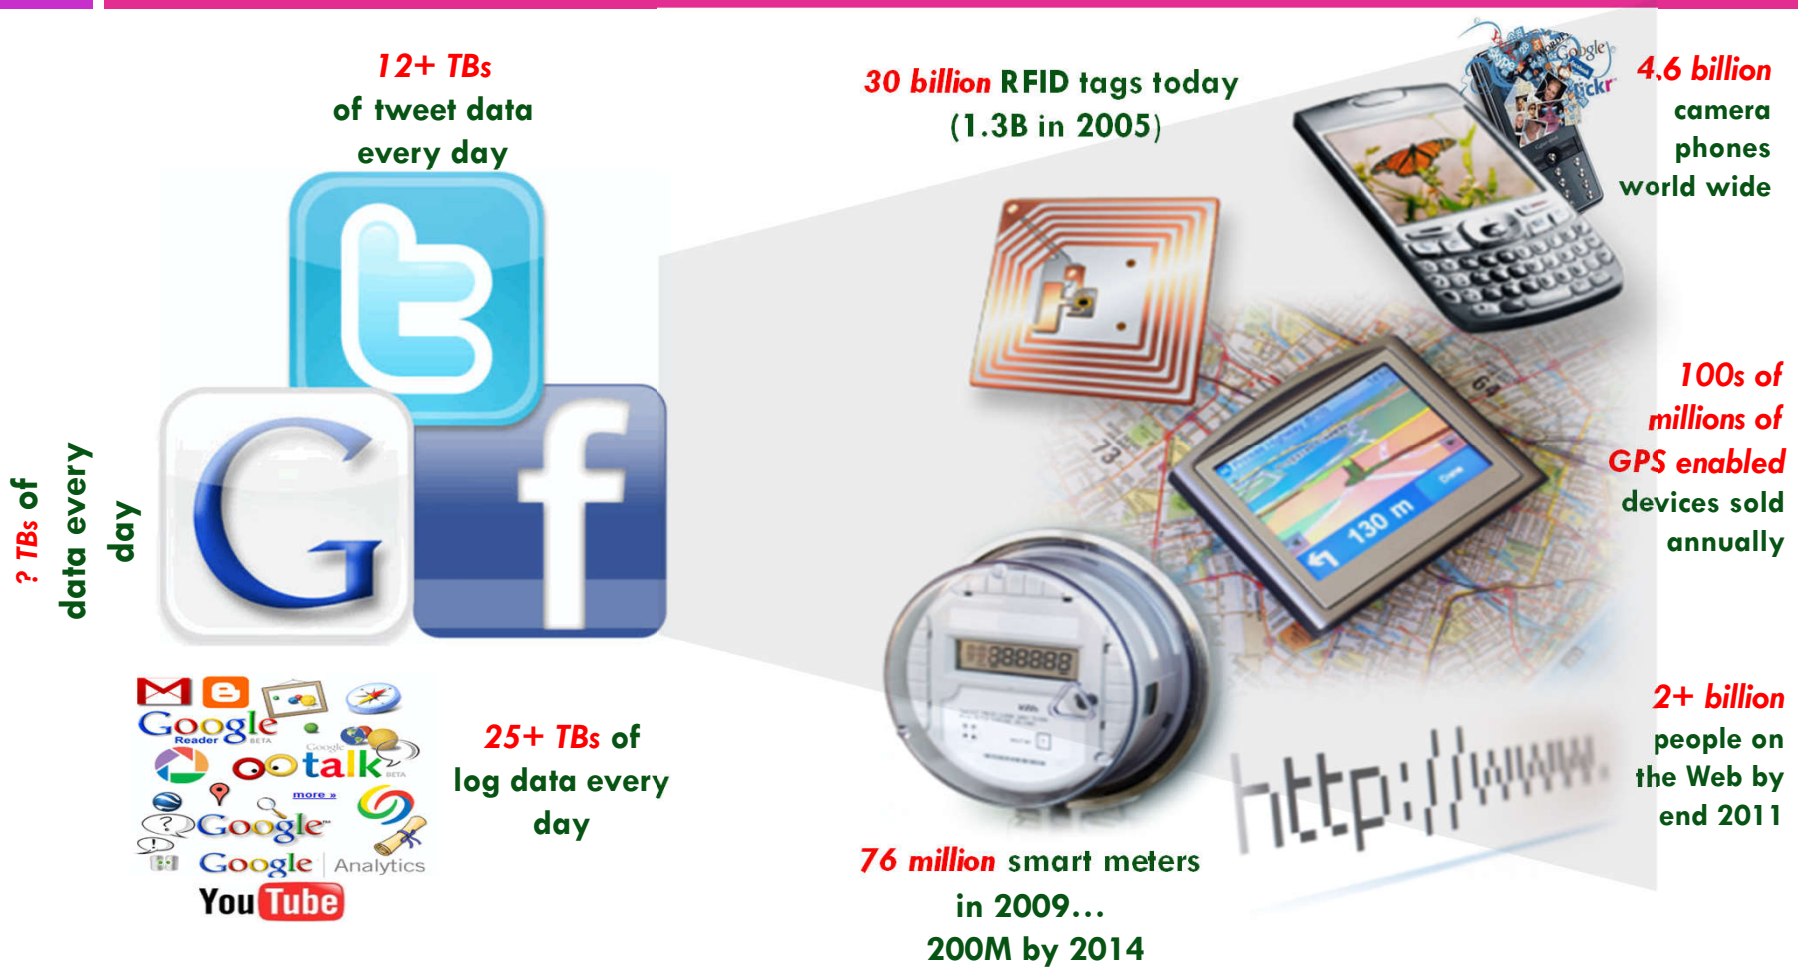
Typologie des données

☐ Données structurées/Semi-structurées/Non structurées



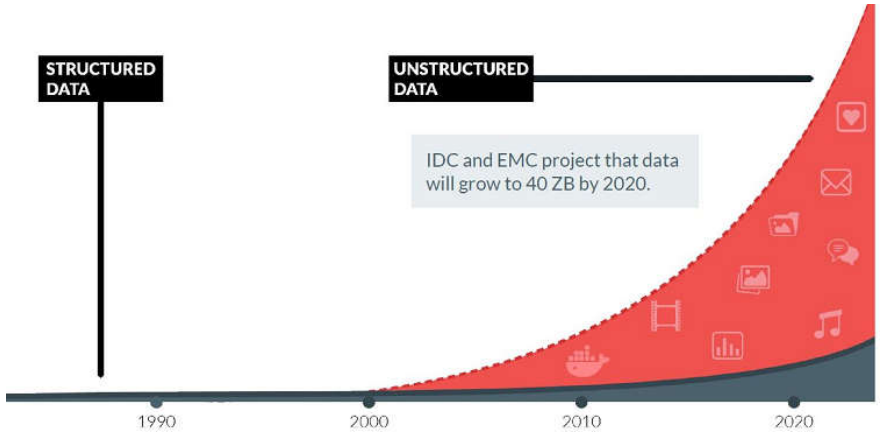


D'où viennent les données?



D'où viennent les données?

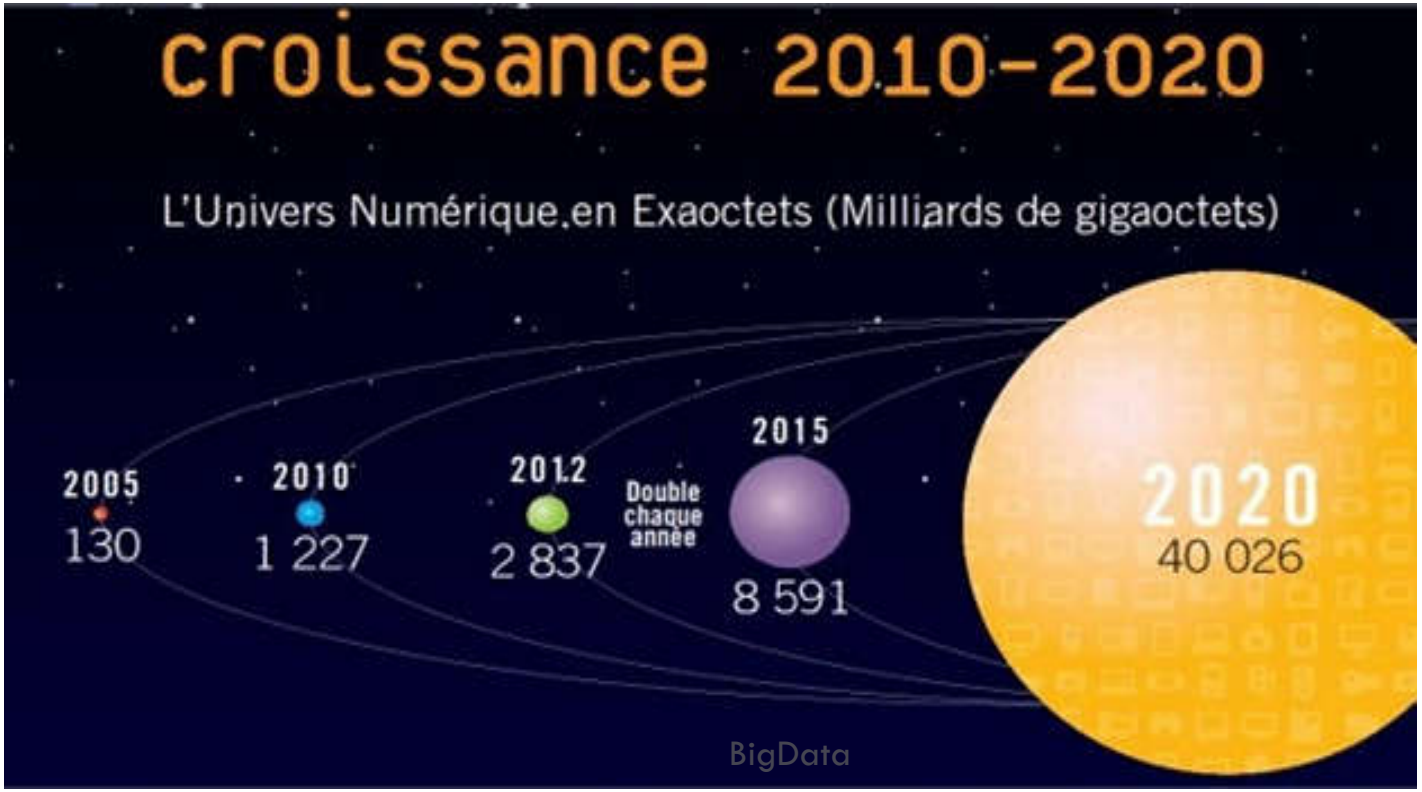
- Généralement, ce ne sont pas seulement des données structurées (comme dans les BD traditionnels) normalisées.
- Ce sont des données semi ou non structurées:
  - Tweets
  - Logs des serveurs
  - Pages web
  - Objets connectés
  - Fichiers CSV, JSON , etc. volumineux



{"hashtags":[{"text":"TulsaAirport", "indices":[0,13]},{"text":"Oklahoma","indices":[14,23]}],"trends":[],"urls":[{"url":"http:\/\/t.co\/SnC8ST3gQC","expanded_url":"http:\/\/bit.ly\/188eNcw","display_url":"bit.ly\/188eNcw","indices":[93,115]}],"user_mentions":[],"symbols":[]},"favorited":false,"retweeted":false,"possibly_sensitive":false,"filter_level":"low","lang":"en","timestamp_ms":"1421853664710"} {"created_at":"WedJan 21 15:21:04 +0000 2015","id":557920823877464064,"id_str":"557920823877464064","text":"An imeepisode updated: Kyoukaino Kanata: Mini Theater # 6 (http:\/\/t.co\/kjEPWveEHM)

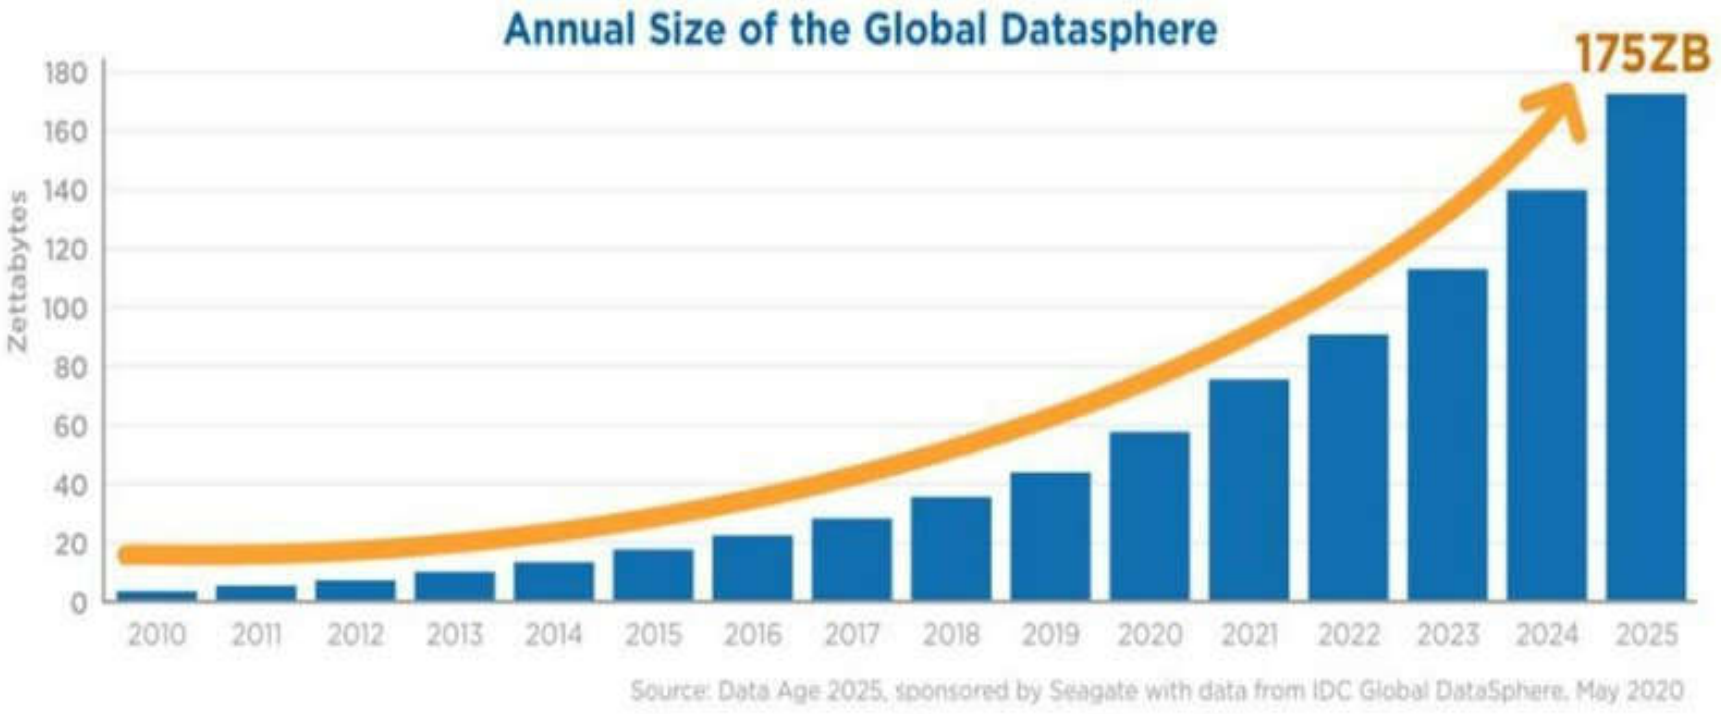
Explosion des données

- Il n'y avait que **130 exaoctets** de données dans l'univers numérique en **2005**.
- Il devrait y en avoir plus de **40 000 exaoctets** à l'horizon **2020.**
- En **2020,** les données représentent l'équivalent de plus de **5 000 GO** par personne!



Explosion des données

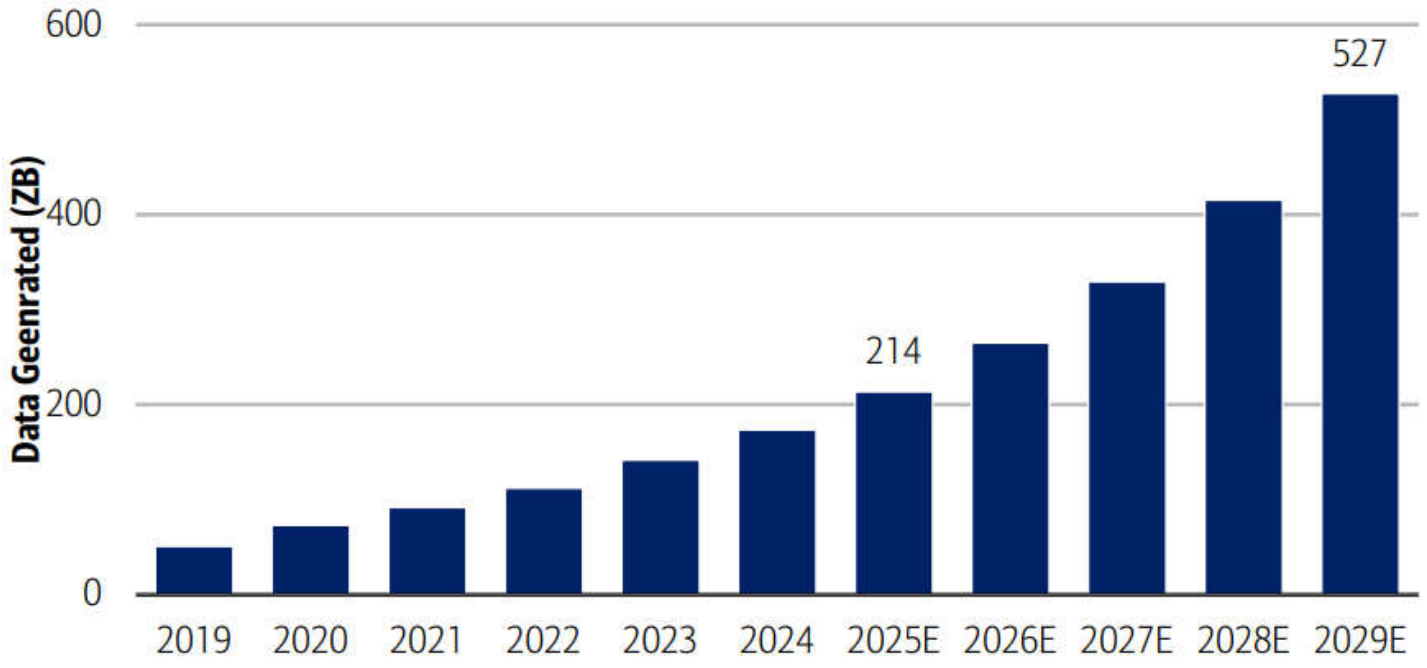
☐ Effet de l'IA générative



Explosion des données

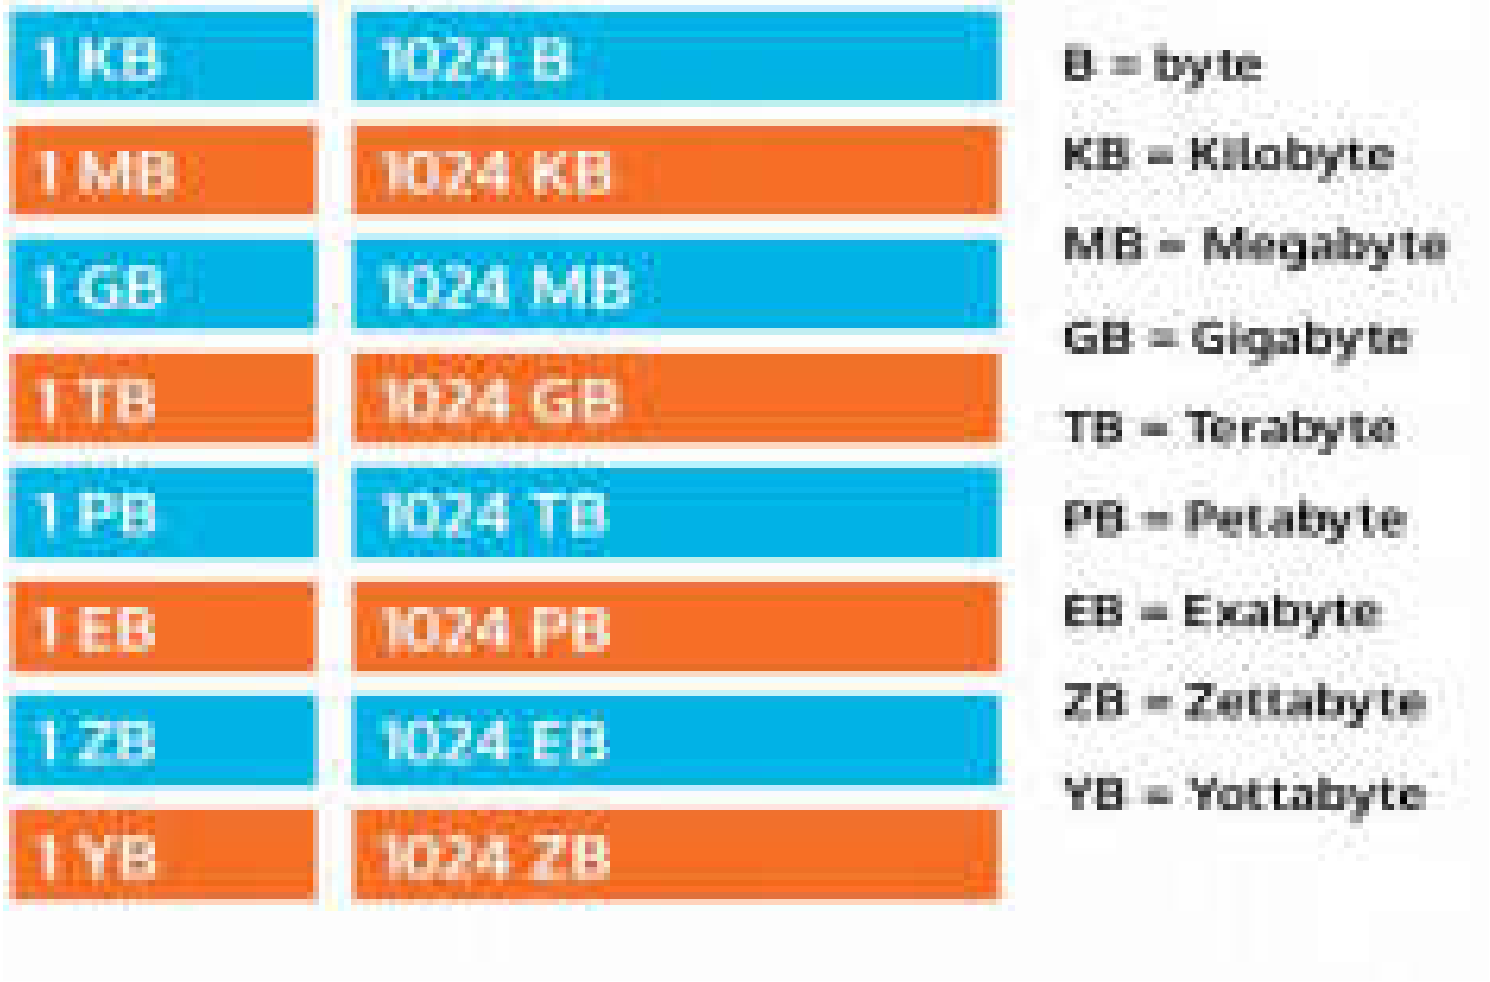
☐ Effet de l'IA générative

Figure 5: Annual data generated is expected to reach 527 ZB by 2029
Data generation volume



Source: IDC

Explosion des données



Encore des chiffres

- Volumes de données totales estimées :
  - Google: 15 000PB (=15 Exabytes)
  - Facebook: 300PB
  - Ebay: 90PB

> "90% of the data
> in the world today
> has been created
> in the last two years alone."
> - IBM

- Volumes de données par jour:
  - Google: 100 PB (5 milliards de requêtes par jour)
  - Twitter: 100 TB (>200 millions de tweets par jour)
  - Facebook: 600 TB

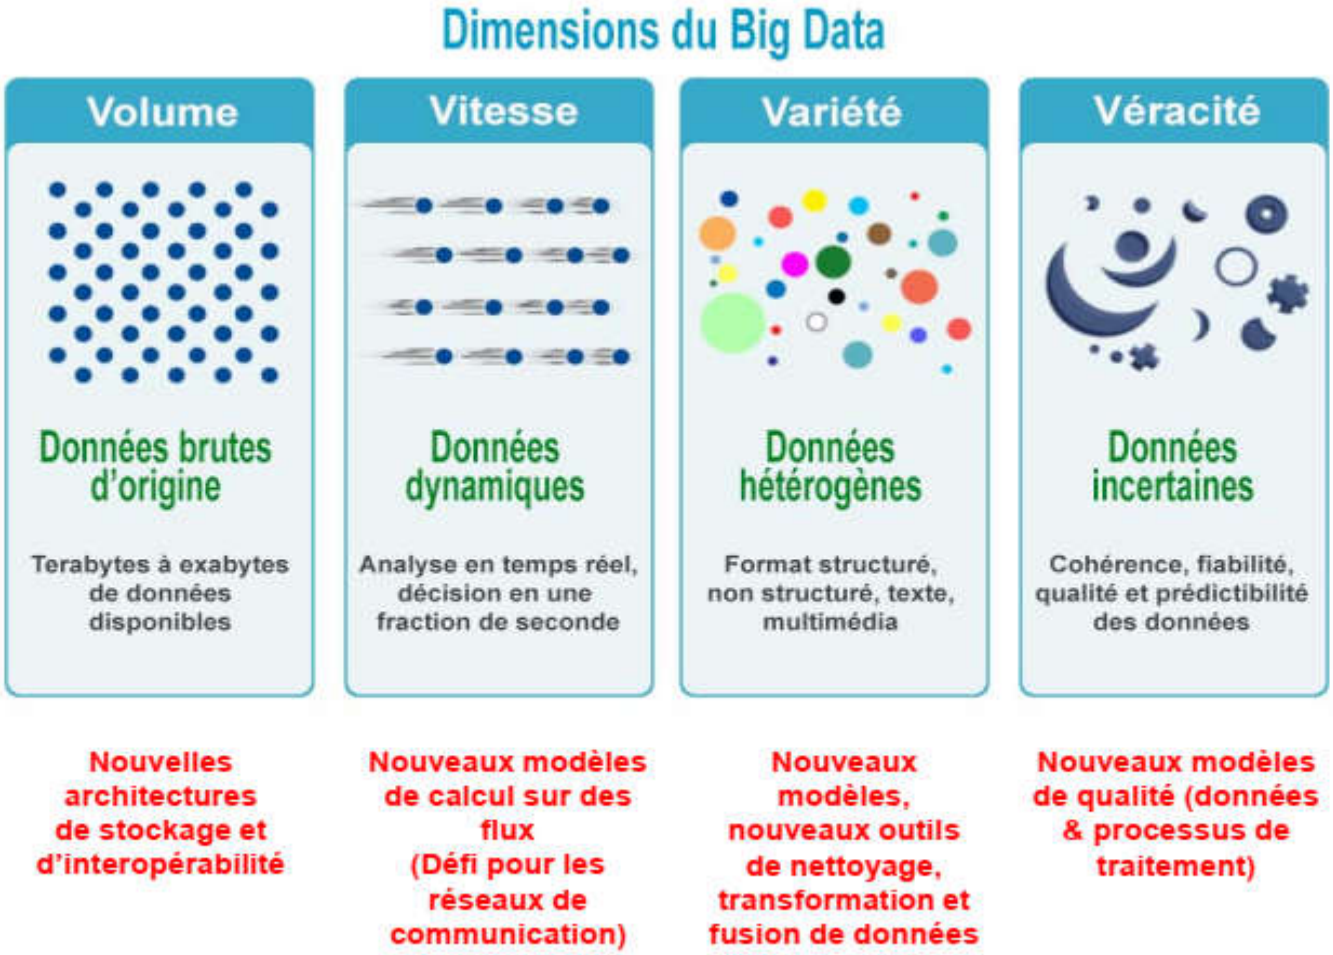
Big Data: C'est quoi donc ?



- En français: Mégadonnées, Données massives
- C'est donc le volume de données??
  - **Réponse: Non.**
  - Il n'y a pas que la dimension volume
- Le Big Data représente les collections de données caractérisées par un **volume**, une **vélocité** et une **variété** si **grands** que leur transformation en **valeur** utilisable requiert l'utilisation de **technologies et de méthodes analytiques spécifiques**. *(d'après Gartner)*

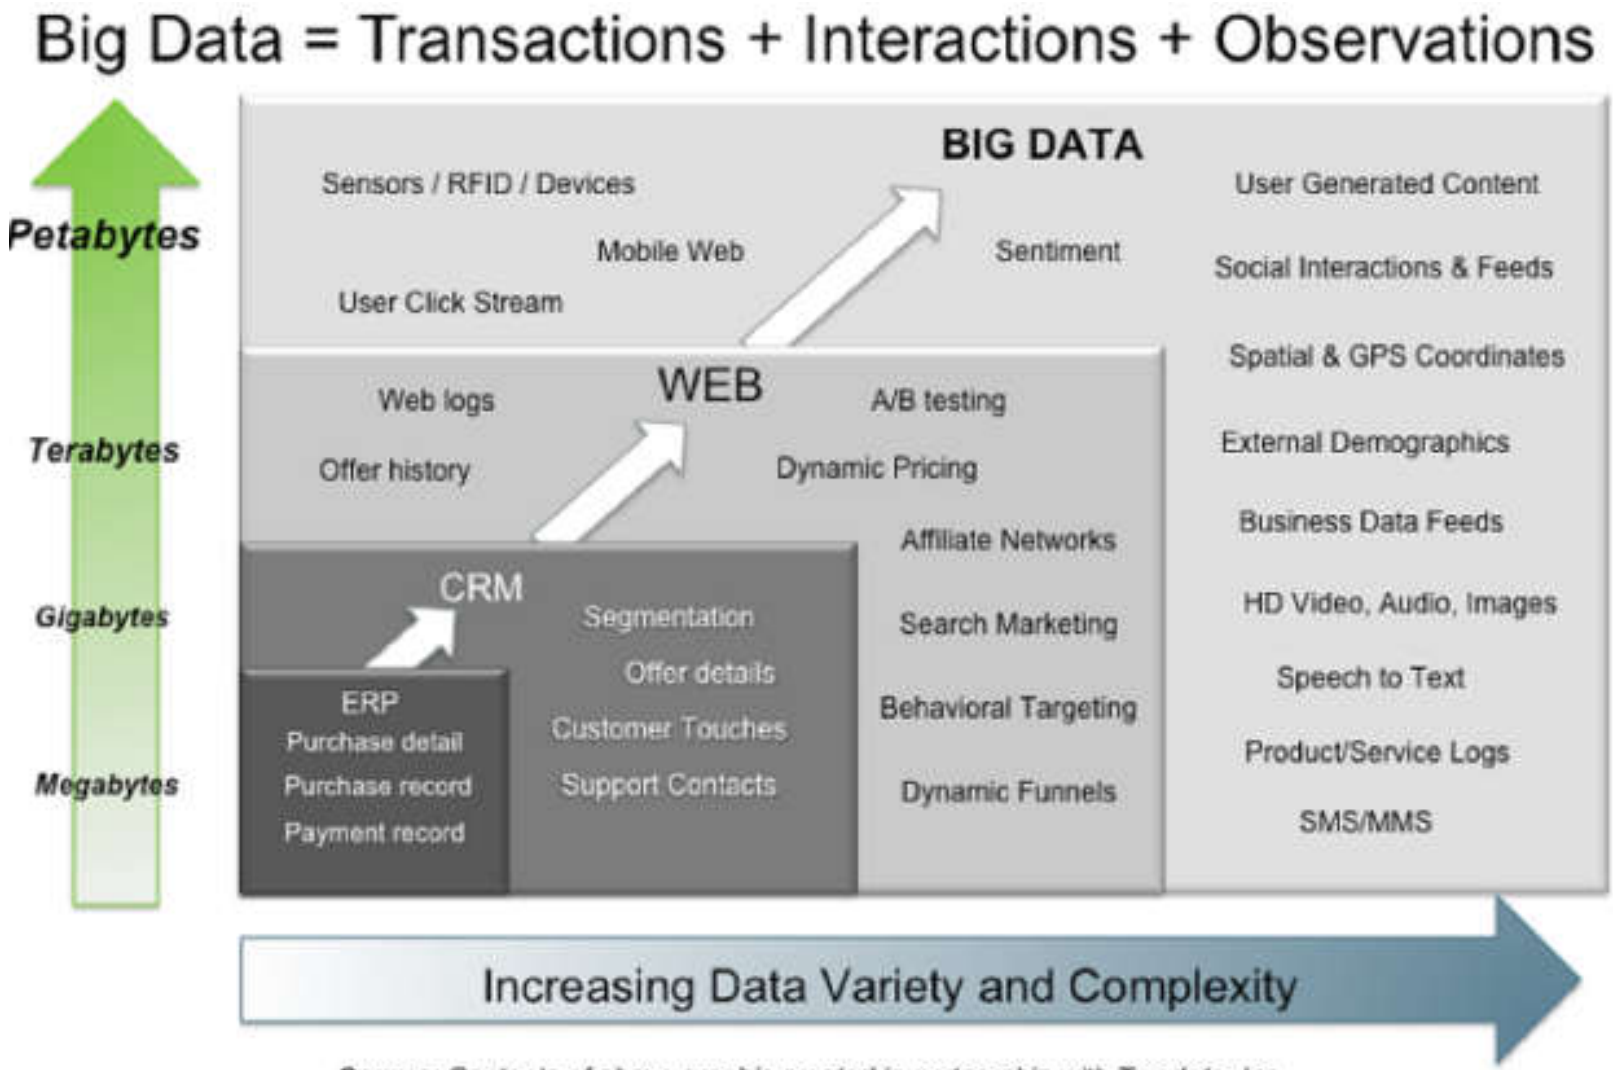
Big data : 3V, 4V, 5V, ?V

- 3V: Volume, Variety, Velocity.
- 4V: Volume, Variety, Velocity, Value.
- 5V: Volume, Variety, Velocity, Value, Veracity.



http://www.astrosurf.com/luxorion/big-data-mining.htm

Entreprise et Big Data



***Source**: Contents of above graphic created in partnership with Teradata, Inc.*

Entreprise et Big Data

-Data Lake-

Forget data warehousing, it's 'data lakes' now

Digital News Asia Mar 31, 2015

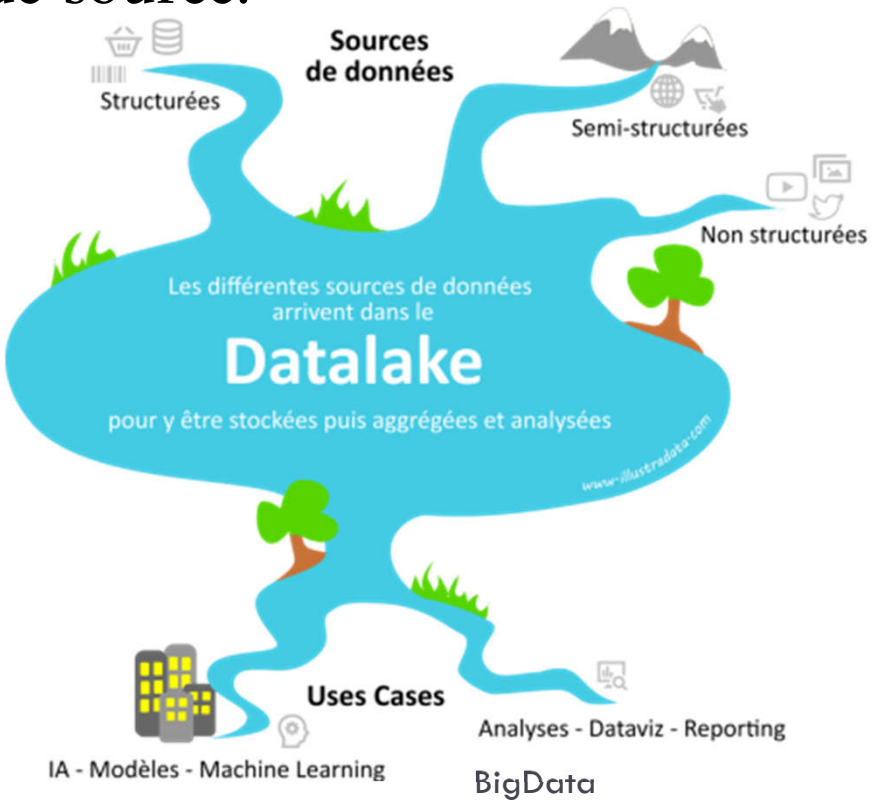
- ***Data Lakes becoming corporate priority because they fill a critical gap***
- ***Federation Business Data Lake simplifies complex task of building a data lake: EMC***



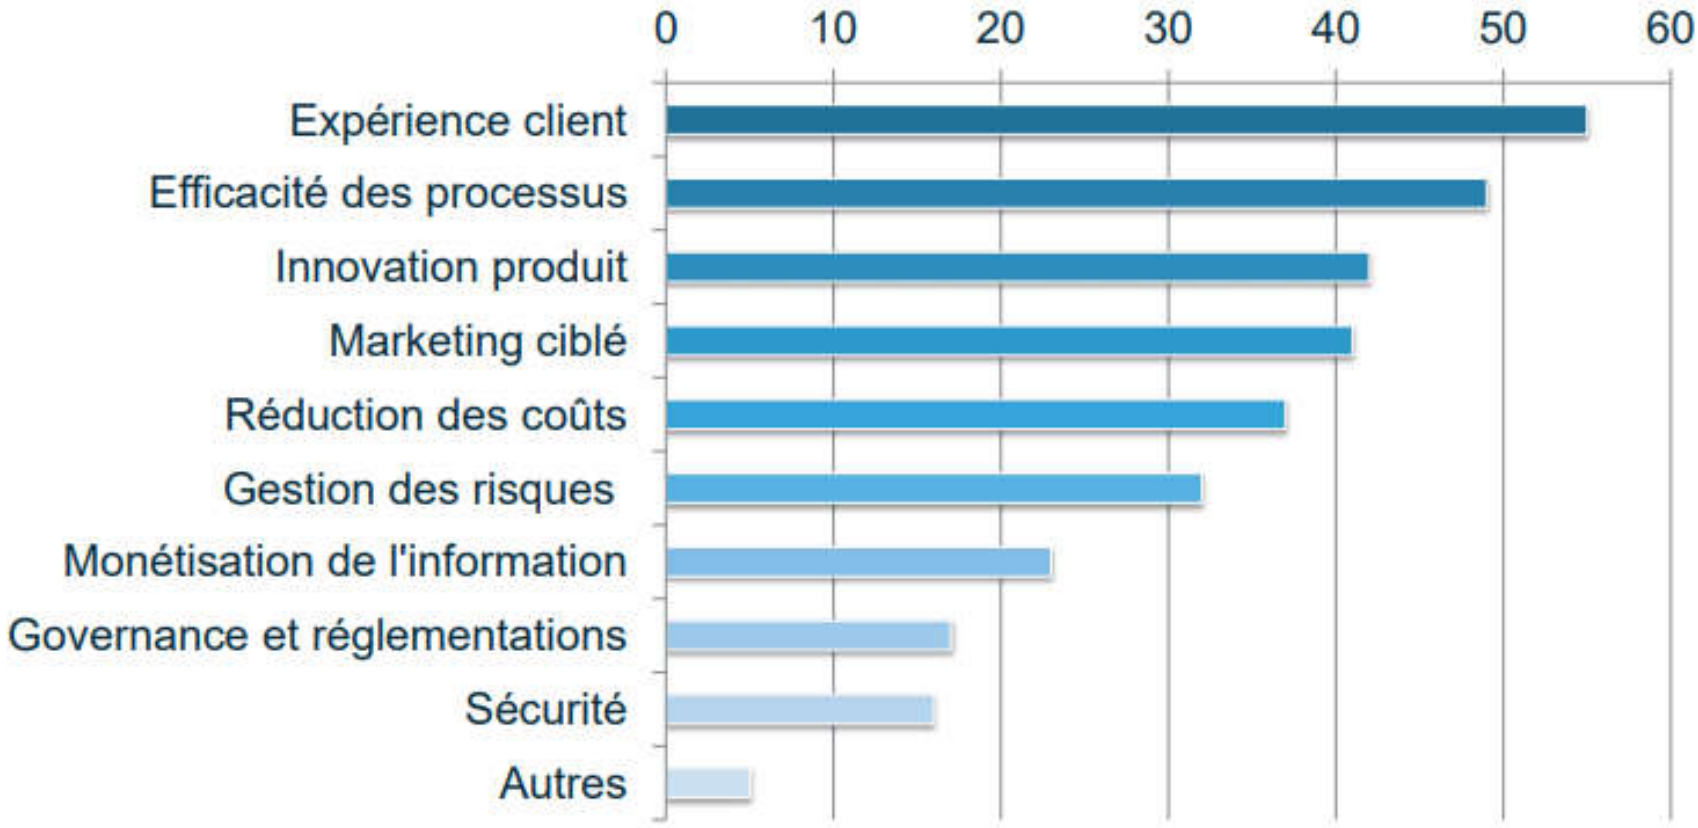
Entreprise et Big Data

-Data Lake-

- Un data lake est un emplacement de stockage centralisé qui contient des big data sous un format brut et granulaire provenant d'un grand nombre de source.



Applications du Big Data: Pour qui, pour quoi?



- La relation client avant tout, puis l'efficacité des processus et l'innovation

Exemples d'application

Crowdsourcing



Sensing



Map data





Computing



Real time traffic info

Travel time forecast/nowcast

Exemples d'applications

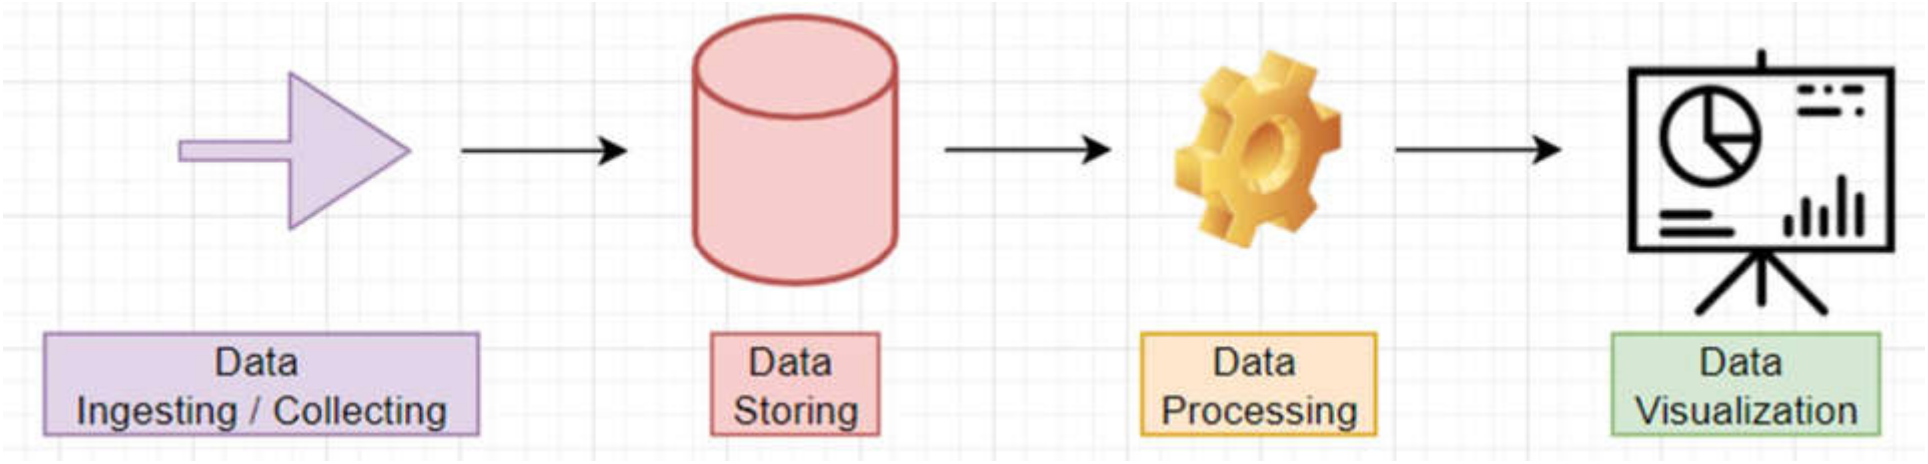
- Recommandations basées sur les données utilisateur:
  - *« There are 33 million different versions of Netflix. » (Joris Evers)*
  - 75% des vidéos regardées viennent des suggestions de Netflix à ses utilisateurs.
- Le Big Data a motivé l'achat des droits (pour 100 million US$) et le tournage de la série House of Cards (popularité de séries similaires, choix du producteur, du réalisateur, des acteurs).
  - Bande annonce personnalisée en fonction du type d'utilisateur.
  - House of Cards a amené 2 millions de nouveaux utilisateurs aux USA et 1 million en dehors des USA.

Exemples d'applications

- PredPol=« Predictive Policing »
  - prédire la probabilité des crimes et délits (nature, localisation à quelques centaines de mètres près, timing à 12h près)
  - base d'apprentissage de 13 millions d'événements
  - Los Angeles: diminution de 33% des agressions
  - Santa Cruz : diminution de 27% des cambriolages en moins d'un an.
- Amazon, Google, Uber , Spotify, Airbnb....
- D'autres applications:
  - Fraude (détection / prévention),
  - Education, santé,
  - Génomique,
  - etc...

Pipeline des données

- Système d'acheminement des donnés d'un point A vers un point B.
- Mis en place par un Data-Engineer.



Challenges du Big Data

- On s'intéresse dans ce cours à deux challenges: **traitement** des données et **stockage**.
- **Traitement:**
  - Paralléliser le calcul sur les machines
  - Framework de traitement distribuée (Hadoop /Spark)
- **Stockage:**
  - Système de fichiers distribué
  - Bases de données (relationnel/NoSQL) distribués

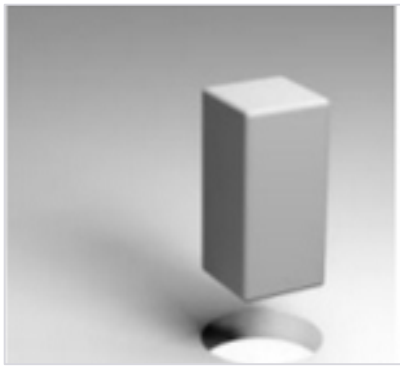
NOSQL: C'est quoi?

- Nom exact: Bases de données non relationnelles.
- Privilégier NOSQL plutôt que NoSQL.



- Ce n'est pas du relationnel, et le contexte d'utilisation n'est donc pas ce lui des SGBDR.
- Ce n'est pas seulement l'opposition à SQL :
  - il s'agit de compléments aux SGBDR pour des besoins spécifiques et non de solutions de remplacement.
  - expérimentations, autres modèles de données très simples, nouveaux besoins, nouveaux outils !
  - logiciels de stockage de données plutôt que SGBD

NOSQL: C'est quoi?



"The whole point of seeking alternatives [to RDBMS systems] is that you need to solve a problem that relational databases are a bad fit for."

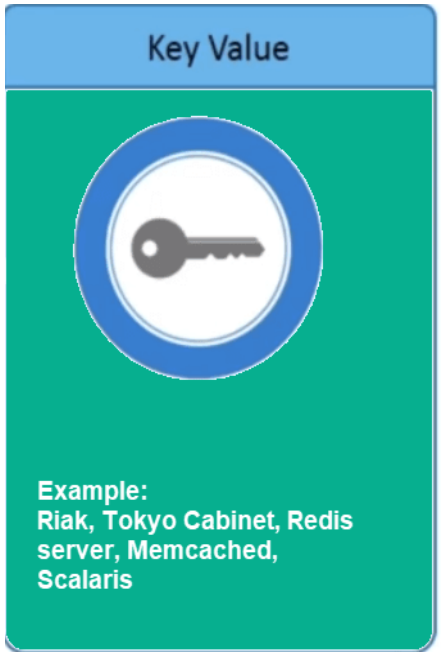
Eric Evans
Rackspace

- Un couple de concepteurs de bases de données entre dans un restaurant NoSQL. Une heure après, ils ressortent sans avoir réussi à manger.
  - Pourquoi?



Types des bases NOSQL

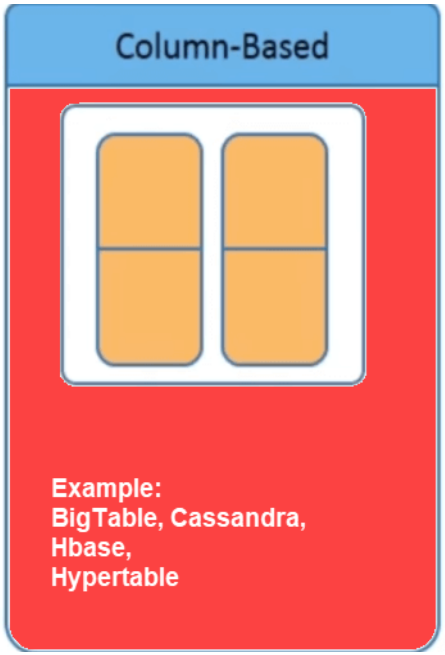
- 4 types de bases NOSQL



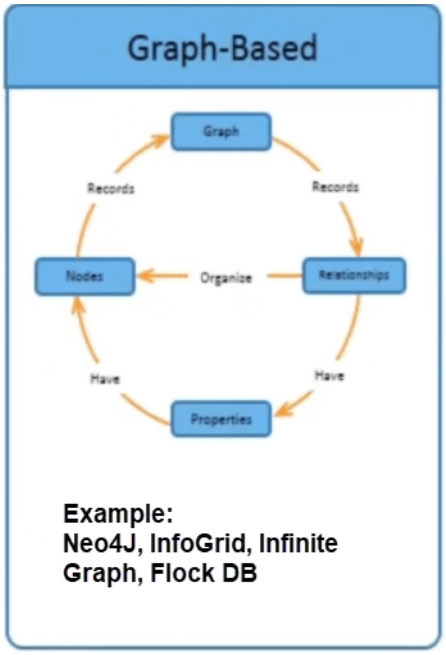
Clé valeur



Orienté document



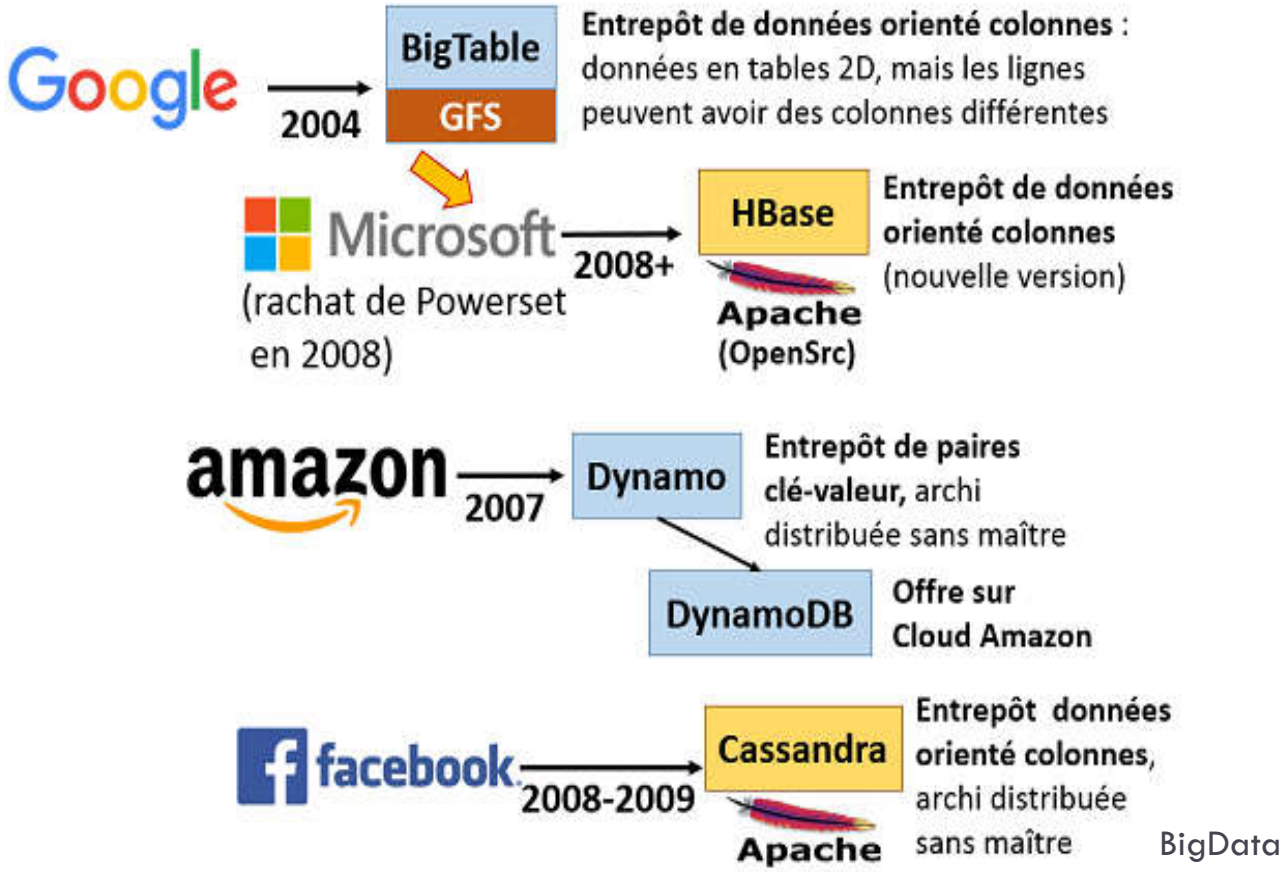
Orienté colonne



Orienté graphe

Big Data et NOSQL

- Les bases de données NoSQL sont des outils Big Data qui permettent de **stocker** et **récupérer** de très gros volumes de données.



Références

- Laurent Jolia-Ferrier, **Big Data - Concepts et mise en œuvre de Hadoop**, Ed Eni, 2014.
- Pirmin Lemberger et al., **Big Data et Machine Learning -Les concepts et les outils de la data science, Ed**, Dunod, 2016.
- P. Lacomme, S. Aridhi, R. Phan, **Bases de données NoSQL et Big Data: Concevoir des bases de données pour le Big Data,** Cours et travaux pratiques Ellipses ~ Technosup, 2/12/2014, 336 p., 9782340002616.
- Rudi Bruchez, L. **Les bases de données NoSQL et le Big Data: Comprendre et mettre en œuvre**, Ed. Eyrolles, 2015.
- Cours Bases de données NOSQL de Raja CHIKY, Institut Mines Télécom: http://perso.isep.fr/rchiky/
- Cours Big Data et NoSQL de Lilia Sfaxi, INSAT, Tunisie: http://liliasfaxi.wixsite.com/liliasfaxi
- https://chewbii.com/
- Chaine Youtube **Tech Wall,** playlist **Hadoop&cie.**

Fin