14. Que fait cette commande HDFS : ***hdfs dfs -get /user/hadoop/data.csv .*** ?

15. Dans la ligne suivante extraite d'un programme Hadoop MapReduce, que signifient **Object** et **IntWritable** dans la déclaration de la classe Mapper ?

public static class TokenizerMapper extends Mapper<Object, Text, Text, IntWritable>

16. La ligne suivante est-elle correcte dans un programme MapReduce en Java ? Si non, corrigez-la.

job.setReducerClass(MyMapper.class);

17. On dispose d'un fichier contenant les notes des étudiants sous la forme :

(IDEtudiant, Matière, Note) comme le montre l'extrait ci-dessous. On souhaite calculer la note maximale de chaque matière.

555F

AVIS IMPORTANT AUX ETUDIANTS

1. Chacune des feuilles de votre copie doit comporter une étiquette code à barres placée à l'endroit indiqué «coller ici votre code à barres».
2. Une copie d'examen comporte une seule «feuille principale» et des «feuilles suites». Sur chacune de vos feuilles, le code à barres est obligatoire.
3. Cette feuille d'examen est strictement personnelle. Elle ne doit comporter aucun signe distinctif. Elle doit être écrite en noir et/ou bleu.
4. Le non respect de l'une de ces recommandations peut faire attribuer la note ZERO à l'épreuve.

NOTE

00	01	02	03	04	05	06	07	08	09	10	11	12	13	14	15	16	17	18	19	20

00	25	50	75

Institut Supérieur d'Informatique et de Mathématiques de Monastir ISIMM

Devoir surveillé – S1 – 2025/2026

Filière : *L3-Info*	**Matière :** **Framework et technologies Big Data**		**Enseignante :** **Asma KERKENI**
Date : 17 / 11 / 2025	Nbr de Crédits : **2**	Coefficient : **1**	**Calculatrice : autorisée** **Documents autorisés : Non**
Durée de l'épreuve : 1h	Régime d'évaluation : **Mixte** EX (70%) + DS (10%) + TP (20%)		**Nombre de pages : 5**

Nom, prénom et signature de l'enseignant correcteur	

Enoncé :

Cet exercice nécessite des réponses concises et précises aux questions posées. Répondez uniquement dans l'espace prévu, en fournissant la réponse attendue. Évitez les explications ou définitions longues.

Barème : 1 point par question

1. Quel est l'intérêt principal de la réplication des blocs des fichiers dans HDFS ?

.....

.....

2. Où sont stockés les métadonnées dans Hadoop ?

.....

.....

3. Que signifie le principe de « *rack-awareness* »

.....

.....

.....

4. Quel composant de HDFS est considéré comme un *SPOF (Single Point Of Failure)* ?

.....

.....

5. Qu'est-ce qu'un cluster Hadoop en haute disponibilité *(HA)* ?

.....

.....

6. Quel est le rôle principal du *Secondary Namenode* ?

.....

.....

7. Quelle propriété essentielle doit posséder un système pour gérer efficacement des données de types différents ?

.....

.....

8. Citez trois facteurs ayant provoqué l'augmentation spectaculaire du volume de données au cours des dernières années.

.....

.....

.....

9. Que signifie le terme "scalabilité" dans le contexte du Big Data ?

.....

.....

.....

10. Donnez des exemples de formats utilisés pour stocker des données semi-structurées dans les systèmes Big Data.

.....

.....

.....

11. En utilisant la conversion décimale (base 10), quel est l'équivalent de 1 Terabyte (TB) en Yottabyte (YB) ?

.....

.....

12. L'IA générative crée de nouvelles données à partir de données existantes. Parmi les 5 V du Big Data, lequel est le plus concerné par le défi de ces données artificielles ?

.....

.....

.....

13. Un fichier de **128 Go** est découpé en blocs de **1 Go**. Le cluster Hadoop dispose de **32** DataNodes, chacun ayant **16 Go** de capacité libre. Quel est le facteur de réplication maximal que l'on peut appliquer à ce fichier sans dépasser la capacité totale des DataNodes ?

SUITE

Coller ici votre
code à barre

S1, Math, 15
S1, Physics, 12
S2, Math, 18
S2, Physics, 16
S3, Math, 10
S3, Physics, 14
S1, Math, 17
S2, Physics, 14
S3, Math, 12

a. Quelle est la clé de regroupement pour ce problème ?

b. Donnez la sortie de la phase Map sur ce fichier.

c. Quel sera le résultat obtenu après la phase de Reduce ?