Institut Supérieur d'Informatique et de Mathématiques de Monastir

ISIMM

Devoir surveillé – S1 – 2024/2025

Filière : *L3-Info*	Matière : Framework et technologies Big Data	Enseignante : Asma KERKENI
	EX (70%) + DS (10%) + TP (20%)	
CORRECTION		Matricule : .....

Enoncé :

Cet exercice nécessite des réponses concises et précises aux questions posées. Répondez uniquement dans l'espace prévu, en fournissant la réponse attendue. Évitez les explications ou définitions longues.

Barème : 1 point par question

1. Quel est l'intérêt principal de la décomposition des fichiers en blocs dans HDFS ?

Paralléliser les traitements, accepter aussi faciliter la distribution et la gestion des fichiers massifs dans un cluster.

2. Où sont stockés les mégadonnées dans Hadoop ?

Les mégadonnées sont stockées sur les DataNodes.

3. Que signifie le principe de « data locality »

Le principe de « data locality » consiste à exécuter les calculs près des données pour réduire les coûts de transfert et améliorer les performances.

4. Quel composant du cluster Hadoop, en cas de panne, rend HDFS entièrement indisponible ?

Le NameNode.

5. Comment appelle-t-on un ensemble de machines qui travaillent ensemble sur une même application distribuée ?

Un cluster.

6. Par quel mécanisme Hadoop assure-t-il la tolérance aux pannes ?

Réplication des données sur plusieurs DataNodes.

7. Quel est le critère essentiel qu'un système doit respecter pour gérer efficacement un volume de données croissant ?

Scalabilité.

8. Un nœud peut-il exécuter plusieurs tâches Map en parallèle lors de l'exécution d'un job MapReduce ?

Oui (s'il dispose de plusieurs slots map).

9. Que signifie le terme "véracité" dans le contexte du Big Data ?

La véracité fait référence à la qualité et à la fiabilité des données utilisées dans le Big Data (accepter aussi : données vrais, exactes, authentiques…)

10. Qu'est-ce qu'un Data Lake?

Un Data Lake est un stockage centralisé qui permet de conserver les big data dans leur format brut, structurées, semi-structurées ou non structurées.

11. Quel est l'équivalent de 1 Zettabyte (ZB) en Terabyte (TB) ?

1 ZB = 10^9 TB dans le système international (base 10)
ou 1 ZB = 1024^9 TB dans le système binaire (base 2). Les deux sont acceptées (préférer le système international pour simplifier les calculs).

12. Dans un système distribué, un DataNode envoie un signal de "heartbeat" toutes les 3 secondes. Combien de signaux le NameNode reçoit-il en 1 minute, si 15 DataNodes sont actifs ?
Chaque DataNode envoie **20 heartbeats par minute** (60 secondes ÷ 3 secondes). Avec 15 DataNodes, le NameNode reçoit **15 × 20 = 300 heartbeats** en 1 minute.
13. Un fichier de 1 To est divisé en blocs de 256 Mo dans HDFS. Sachant que chaque DataNode peut stocker au maximum 200 blocs, combien de DataNodes sont nécessaires pour stocker ce fichier avec une réplication de 3 ?
Calcul dans le système binaire
Nombre de blocs nécessaires pour 1 To : 1 To÷256 Mo=**4096 blocs**
Avec une réplication de 3 : 4096 × 3 = **12 288 blocs.**
Nombre de DataNodes requis : 12288÷200=61,44 soit **62 DataNodes**.
Calcul dans le système international (Les deux sont acceptées.)
Nombre de blocs nécessaires pour 1 To :1 To=10^6 ÷256Mo=**3906blocs**
Avec une réplication de 3 : 3906 blocs×3=**11718 blocs**
Nombre de DataNodes requis : 11718 blocs÷200=58,59 soit **59 DataNodes.**
14. Donnez la commande HDFS qui permet de déplacer un fichier appelé *report.txt* situé dans le répertoire local */home/user* vers le répertoire HDFS */user/reports* ?
hdfs dfs -put /home/user/report.txt /user/reports
15. Donnez la commande qui permet d'exécuter un job MapReduce *WordCount* sur le fichier *report.txt*.
hadoop jar wordcount.jar WordCount /user/reports/report.txt /user/output
16. La ligne suivante est-elle correcte dans un programme MapReduce en Java ? Si non, corrigez-la.
job.setReducerClass(MyReducer.java);
FAUSSE : job.setReducerClass(MyReducer.class);
17. On souhaite extraire, à partir d'un fichier contenant une liste de mots, ceux qui comportent des syllabes répétées plusieurs fois en utilisant le paradigme MapReduce. L'objectif est de collecter, pour chaque syllabe, la liste des mots dans lesquels elle apparaît plus d'une fois.
Exemple de mots avec des syllabes répétées : cocorico, baba, fifi, mama, tata, cocotte, matata, tartat, coconut.
    a. Quelle est la clé de regroupement pour ce problème ?
La syllabe répétée (par exemple co, ba, ri)
    b. Donnez la sortie de la phase Map sur un fichier contenant les mots de l'exemple.
("co", "cocorico"),("ba", "baba"),("fi", "fifi"),("ma", "mama"),("ta", "tata"),("co", "cocotte"),("ta", "matata"),("ta", "tartat"),("co", "coconut")
    c. Quel sera le résultat obtenu après la phase Reduce ?
("co", ["cocorico", "cocotte", "coconut"]),
("ba", ["baba"]),
("fi", ["fifi"]),
("ma", ["mama"]),
("ta", ["tata", "matata", "tartat"])