Institut Supérieur d'Informatique et de Mathématiques de Monastir

ISIMM

Devoir surveillé – S1 – 2024/2025

Filière : *L3-Info*	**Matière : Framework et technologies Big Data**		**Enseignante : Asma KERKENI**
Date : 22 / 11 / 2024	Nbr de Crédits : **2**	Coefficient : **1**	**Calculatrice : autorisée** **Documents autorisés : Non**
Durée de l'épreuve : 1h	Régime d'évaluation : **Mixte** EX (70%) + DS (10%) + TP (20%)		**Nombre de pages : 4**
Nom & Prénom :			**Matricule :** .....
Signature :	**Code confidentiel :**		**Classe :** ..... **N° Place :** .....

NOTE : Répondre directement sur les feuilles de l'examen /

Note ... / 20

Enoncé :

Cet exercice nécessite des réponses concises et précises aux questions posées. Répondez uniquement dans l'espace prévu, en fournissant la réponse attendue. Évitez les explications ou définitions longues.

Barème : 1 point par question

1. Quel est l'intérêt principal de la décomposition des fichiers en blocs dans HDFS ?

.....

.....

2. Où sont stockés les mégadonnées dans Hadoop ?

.....

.....

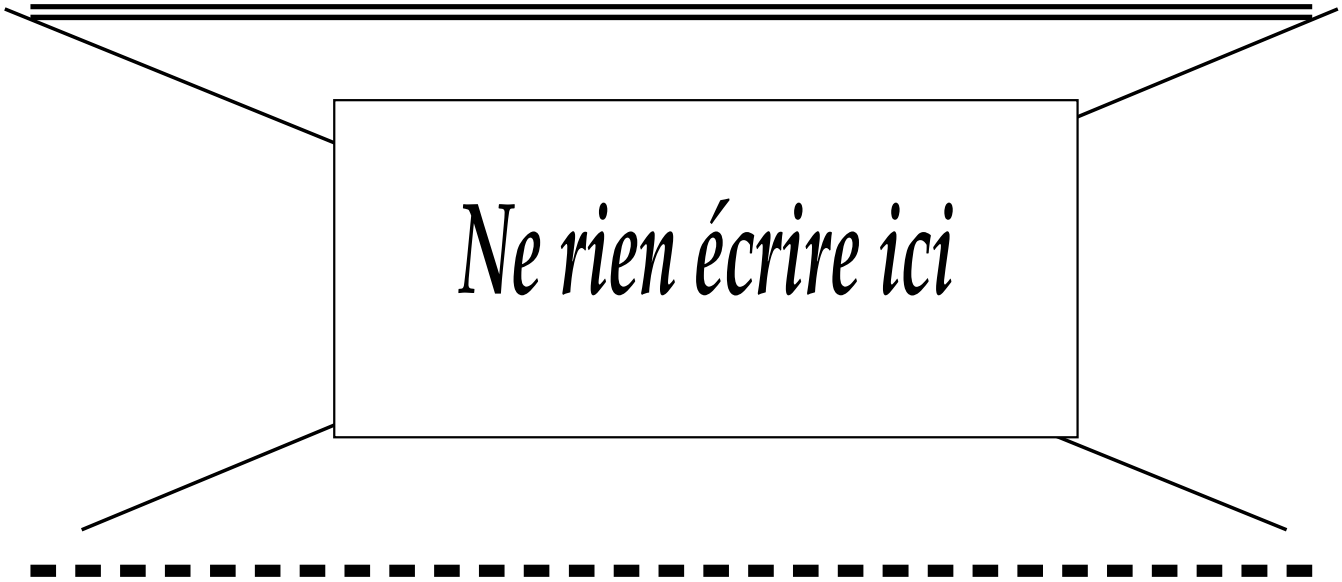
3. Que signifie le principe de « data locality »

.....

.....

.....

4. Quel composant du cluster Hadoop, en cas de panne, rend HDFS entièrement indisponible ?



.....

.....

5. Comment appelle-t-on un ensemble de machines qui travaillent ensemble sur une même application distribuée ?

.....

.....

6. Par quel mécanisme Hadoop assure-t-il la tolérance aux pannes ?

.....

.....

7. Quel est le critère essentiel qu'un système doit respecter pour gérer efficacement un volume de données croissant ?

.....

.....

8. Un nœud peut-il exécuter plusieurs tâches Map en parallèle lors de l'exécution d'un job MapReduce ?

.....

.....

9. Que signifie le terme "véracité" dans le contexte du Big Data ?

.....

.....

.....

10. Qu'est-ce qu'un Data Lake?

.....

.....

.....

11. Quel est l'équivalent de 1 Zettabyte (ZB) en Terabyte (TB) ?

.....

.....

12. Dans un système distribué, un DataNode envoie un signal de "heartbeat" toutes les 3 secondes. Combien de signaux le NameNode reçoit-il en 1 minute, si 15 DataNodes sont actifs ?

.....

.....

.....

13. Un fichier de 1 To est divisé en blocs de 256 Mo dans HDFS. Sachant que chaque DataNode peut stocker au maximum 200 blocs, combien de DataNodes sont nécessaires pour stocker ce fichier avec une réplication de 3 ?

.....

.....

.....

14. Donnez la commande HDFS qui permet de déplacer un fichier appelé *report.txt* situé dans le répertoire local */home/user* vers le répertoire HDFS */user/reports* ?

.....

.....

15. Donnez la commande qui permet d'exécuter un job MapReduce *WordCount* sur le fichier *report.txt*.

.....

.....

16. La ligne suivante est-elle correcte dans un programme MapReduce en Java ? Si non, corrigez-la.

    job.setReducerClass(MyReducer.java);

.....

.....

17. On souhaite extraire, à partir d'un fichier contenant une liste de mots, ceux qui comportent des syllabes répétées plusieurs fois en utilisant le paradigme MapReduce. L'objectif est de collecter, pour chaque syllabe, la liste des mots dans lesquels elle apparaît plus d'une fois.

    Exemple de mots avec des syllabes répétées : cocorico, baba, fifi, mama, tata, cocotte, matata, tartat, coconut.

    a. Quelle est la clé de regroupement pour ce problème ?

.....

.....

    b. Donnez la sortie de la phase Map sur un fichier contenant les mots de l'exemple.

.....

.....

.....

.....

.....

.....

.....

.....

    c. Quel sera le résultat obtenu après la phase Reduce ?

.....

.....

.....

.....

.....

.....

.....

.....