a. Les effets de la transaction sont permanents après validation
b. Les transactions concurrentes n'interfèrent pas entre elles
c. La base reste dans un état cohérent
d. La transaction est indivisible
e. Aucune des réponses précédentes

20. Dans une base de données clé-valeur, les opérations les plus courantes sont :

a. Insert
b. Update
c. Get
d. Join
e. Aucune des réponses précédentes

Exercice 2 : Questions à réponses courtes (5 points)

Cet exercice nécessite des réponses concises et précises aux questions posées. Répondez en fournissant la réponse attendue. Évitez les explications ou définitions longues.

Barème : 1 point par question

1. Expliquez comment le modèle MapReduce permet le traitement parallèle de grands volumes de données dans un environnement distribué.
2. Vous devez mettre à jour un fichier déjà stocké dans HDFS contenant des logs ou des données brutes. Expliquez comment procéder pour modifier ce fichier et quelles limitations vous pourriez rencontrer.
3. Expliquez la différence entre les approches **schema-on-write** et **schema-on-read** dans les systèmes de gestion des données, et indiquez pour quel type de base de données chaque approche est généralement utilisée.
4. Dans les bases de données NoSQL, quelles sont les principales alternatives aux jointures relationnelles classiques ?
5. On considère les descriptions suivantes de systèmes distribués. Classez chaque système selon le théorème CAP (CA, CP ou AP).

a) Un système distribué qui privilégie la cohérence forte et peut refuser des requêtes en cas de partition réseau.
b) Un système hautement disponible qui accepte des incohérences temporaires lors de partitions réseau.
c) Un système centralisé sans tolérance aux partitions réseau.

Bon travail !

Institut Supérieur d'Informatique et de Mathématiques de Monastir ISIMM

Examen -Session de Rattrapage– S1 – 2025/2026

Filière : *3ème L3-Info*	Matière : **Frameworks et technologies Big Data**		Enseignante : **Asma KERKENI**
Date : 26 / 01 / 2026	Nbr de Crédits : **2**	Coefficient : **1**	**Documents non autorisés** **Calculatrice autorisée**
Durée de l'examen : 1h30	Régime d'évaluation : **Mixte** EX (70%) + DS (10%) + TP (20%)		**Nombre de pages : 4**

Exercice 1 : QCM (15 points)

Dans le Q.C.M. suivant, chaque question peut avoir une ou plusieurs bonnes réponses. Veuillez indiquer sur votre feuille de réponses la ou les bonnes réponses pour chaque question.

1. HDFS (Hadoop Distributed File System) est conçu principalement pour :
a. Stocker de très gros fichiers
b. Gérer efficacement un grand nombre de petits fichiers
c. Offrir une tolérance aux pannes
d. Aucune des réponses précédentes

2. Le framework Apache Hadoop :
a. Nécessite du matériel hautement spécialisé
b. Ne fonctionne que sur des systèmes d'exploitation spécifiques
c. Ne fonctionne que dans le cloud
d. Peut fonctionner sur du matériel standard
e. Aucune des réponses précédentes

3. Dans un job MapReduce, quelle étape ne peut pas être optionnelle ?
a. Map
b. Reduce
c. Shuffle and Sort
d. Filter
e. Aucune des réponses précédentes

4. Quel est le rôle principal du modèle MapReduce dans un système Big Data ?
a. Fournir un système de stockage distribué
b. Exécuter des traitements distribués sur de grands volumes de données
c. Gérer la planification des ressources matérielles
d. Aucune des réponses précédentes

5. Le principe de *data locality* dans Hadoop signifie que :
a. Les données sont déplacées vers les nœuds de calcul
b. Les traitements sont déplacés vers les nœuds contenant les données
c. Les données sont toujours stockées sur un seul nœud

d. Les calculs sont centralisés sur le NameNode
e. Aucune des réponses précédentes

6. Le modèle BASE est souvent associé à des systèmes :
a. CA (Cohérence + Disponibilité)
b. CP (Cohérence + Tolérance aux partitions)
c. AP (Disponibilité + Tolérance aux partitions)
d. Des systèmes non distribués
e. Aucune des réponses précédentes

7. Un data lake se caractérise par :
a. Le stockage de données brutes
b. Un schéma défini à l'avance
c. La coexistence de données structurées et non structurées
d. Une forte orientation analytique
e. Aucune des réponses précédentes

8. Le modèle orienté documents est particulièrement adapté lorsque :
a. Les données ont une structure évolutive
b. Les requêtes nécessitent de nombreuses jointures complexes
c. Le schéma est stable et fortement normalisé
d. Les données sont semi-structurées
e. Aucune des réponses précédentes

9. Dans les bases de données NoSQL :
a. Le schéma est vérifié lors de l'écriture des données
b. Le schéma est interprété au moment de la lecture des données
c. Il n'existe jamais de schéma
d. Le schéma est fixe et imposé
e. Aucune des réponses précédentes

10. Dans le contexte des bases de données, un identifiant métier :
a. Est défini par les experts du domaine
b. Est généré automatiquement par le SGBD
c. Est équivalent à un identifiant artificiel
d. Peut être un numéro d'immatriculation ou de carte d'identité
e. Aucune des réponses précédentes

11. Un data warehouse :
a. Est utilisé dans le système de production
b. Est utilisé dans le système décisionnel
c. Agrège les données issues de différents systèmes opérationnels
d. Aucune des réponses précédentes

12. Un data warehouse contient principalement :
a. Des données structurées
b. Des données non structurées

c. Des données brutes non transformées
d. Des données historisées
e. Aucune des réponses précédentes

13. Quel est le principal avantage de la cohérence éventuelle (*eventual consistency*) ?
a. Une latence élevée
b. La possibilité de lire temporairement des données obsolètes
c. Une meilleure disponibilité du système
d. Une cohérence forte à tout instant
e. Aucune des réponses précédentes

14. Pourquoi les systèmes distribués modernes privilégient presque toujours la tolérance aux partitions ?
a. Les partitions réseau sont inévitables
b. Les partitions réseau sont faciles à éliminer
c. Elles améliorent la sécurité
d. Elles garantissent la cohérence
e. Aucune des réponses précédentes

15. Dans le modèle BASE, la lettre S signifie :
a. Le système est strictement cohérent
b. Le système reste disponible même en cas de partition réseau
c. Le système peut être dans un état intermédiaire
d. L'état du système peut évoluer dans le temps
e. Aucune des réponses précédentes

16. La normalisation des bases de données relationnelles consiste à :
a. Réduire la redondance des données
b. Fragmenter les données sur plusieurs nœuds
c. Dupliquer les données pour améliorer les performances
d. Structurer les données pour assurer l'intégrité
e. Aucune des réponses précédentes

17. Le sharding dans les bases de données NoSQL permet de :
a. Répliquer les données sur tous les nœuds
b. Distribuer les données sur plusieurs nœuds
c. Améliorer la montée en charge horizontale
d. Garantir une cohérence forte
e. Aucune des réponses précédentes

18. Pour assurer les propriétés ACID des transactions, on utilise :
a. Les journaux (logs)
b. Les mécanismes de verrouillage (locks)
c. Le sharding
d. La réplication synchrone
e. Aucune des réponses précédentes

19. Dans une transaction ACID, l'isolation garantit que :