Institut Supérieur d'Informatique et de Mathématiques de Monastir ISIMM

Examen -Session Principale– S1 – 2024/2025

Filière : *3ème L3-Info*	**Matière :** **Frameworks et technologies Big Data**		**Enseignante :** **Asma KERKENI**
Date : 13 / 01 / 2025	Nbr de Crédits : **2**	Coefficient : **1**	**Documents non autorisés** **Calculatrice autorisée**
Durée de l'examen : 1h30	Régime d'évaluation : **Mixte** EX (70%) + DS (10%) + TP (20%)		**Nombre de pages : 8**

Exercice 1 : QCM (15 points)

Dans le Q.C.M. suivant, chaque question peut avoir une ou plusieurs bonnes réponses. Veuillez indiquer sur votre feuille de réponses la ou les bonnes réponses pour chaque question.

N.B : Pour chaque question, une réponse juste et deux réponses fausses valent 0.

1. Quel est le rôle principal d'un "Namenode" dans Hadoop ?
   a. Exécuter des tâches MapReduce
   b. Gérer le stockage des données
   c. Assurer la sécurité des données
   d. Gérer les utilisateurs
   e. Aucune des réponses précédentes
2. Dans Hadoop, le rôle principal du JobTracker est :
   a. Stocker les données utilisateur
   b. Gérer les blocs de données sur les DataNodes
   c. Fournir une interface utilisateur
   d. Exécuter des tâches MapReduce
   e. Aucune des réponses précédentes
3. Comment appelle-t-on un ensemble de machines qui travaillent ensemble sur une même application distribuée ?
   a. Grid
   b. Cluster
   c. Network
   d. Server
   e. Aucune des réponses précédentes
4. Dans Hadoop, comment appelle-t-on le processus responsable de l'exécution d'une tâche sur un nœud Worker ?
   a. TaskTracker
   b. JobTracker

c. DataNode
d. ResourceManager
e. Aucune des réponses précédentes

5. Dans MapReduce, le Reducer est chargé de :
   a. Répartir les données entre les nœuds.
   b. Regrouper et consolider les résultats.
   c. Extraire les données des fichiers.
   d. Créer des partitions des données.
   e. Aucune des réponses précédentes.

6. Dans Hadoop, un job représente :
   a. Une tâche spécifique du Mapper.
   b. Une unité de traitement.
   c. Une opération d'entrée/sortie.
   d. Une requête SQL.
   e. Aucune des réponses précédentes.

7. Quel est le rôle des métadonnées dans HDFS ?
   a. Stocker les données utilisateur.
   b. Identifier l'emplacement des blocs de données.
   c. Répliquer les données sur plusieurs nœuds.
   d. Gérer les utilisateurs.
   e. Aucune des réponses précédentes.

8. La réplication dans HDFS est utilisée pour :
   a. Répartir la charge entre les nœuds.
   b. Garantir la disponibilité et la tolérance aux pannes.
   c. Optimiser les performances des requêtes.
   d. Compresser les données.
   e. Aucune des réponses précédentes.

9. Quel est l'objectif de l'étape ***shuffle and sort*** dans Hadoop ?
   a. Réduire les données
   b. Organiser les données pour le traitement
   c. Stocker les données
   d. Exécuter des tâches de map
   e. Aucune des réponses précédentes.

10. Dans un cluster Hadoop, quel est le nombre maximal de tâches Reduce qu'un nœud Worker peut exécuter simultanément ?
    a. Une seule tâche Reduce à la fois.
    b. Autant de tâches Reduce que le nombre de cœurs du nœud.
    c. Autant de tâches Reduce que la mémoire totale disponible sur le nœud.
    d. Un nombre illimité de tâches Reduce.

e. Autant de tâches Reduce que le nombre de slots Reduce configurés pour le nœud Worker.

11. Combien de tâches de map sont nécessaires pour traiter un fichier de 512 Go avec des blocs de 128 Mo ?
    a. 4096
    b. 8192
    c. 2560
    d. 1024
    e. Aucune des réponses précédentes

12. Quels sont les démons responsables de la phase Reduce dans MapReduce ?
    a. JobTracker et TaskTracker
    b. ResourceManager et NodeManager
    c. DataNode et NameNode
    d. TaskTracker et JobTracker
    e. Aucune des réponses précédentes

13. Où sont stockées les mégadonnées dans Hadoop ?
    a. Sur des serveurs locaux
    b. Dans HDFS
    c. Dans des bases de données relationnelles
    d. Sur des disques durs externes
    e. Aucune des réponses précédentes

14. Que signifie le principe de « data locality » ?
    a. Les données sont stockées à proximité des utilisateurs
    b. Les données sont traitées là où elles sont stockées
    c. Les données sont centralisées
    d. Les données sont distribuées uniformément
    e. Aucune des réponses précédentes

15. Quel composant du cluster Hadoop, en cas de panne, rend HDFS entièrement indisponible ?
    a. DataNode
    b. NameNode
    c. ResourceManager
    d. JobTracker
    e. Aucune des réponses précédentes

16. Quel type de base de données est le mieux adapté pour des données non structurées ?
    a. Relationnelle
    b. NoSQL
    c. Graph

d. Hiérarchique
e. Aucune des réponses précédentes

17. Quel est le principal objectif de l'indexation dans une base de données ?
a. Réduire la taille des données
b. Accélérer les requêtes
c. Améliorer la sécurité
d. Diminuer la redondance
e. Aucune des réponses précédentes

18. Dans le contexte du théorème CAP, la disponibilité signifie :
a. Les données sont toujours cohérentes
b. Chaque requête reçoit une réponse valide
c. Les partitions réseau sont évitées
d. Chaque requête reçoit une réponse
e. Aucune des réponses précédentes

19. Quel mécanisme est utilisé pour tolérer les pannes dans les bases NOSQL ?
a. Clustering
b. Réplication
c. Indexation
d. Transaction ACID
e. Aucune des réponses précédentes

20. Dans le modèle BASE des bases de données NoSQL, la cohérence est :
a. Forte
b. Garantie à terme
c. Garantie de manière instantanée
d. N'est pas de tout garantie
e. Aucune des réponses précédentes

21. Quel est l'objectif principal de la réplication dans les bases de données distribuées
a. Améliorer la sécurité
b. Augmenter la disponibilité
c. Réduire la latence
d. Diminuer la taille des données
e. Aucune des réponses précédentes

22. Dans le contexte de NoSQL, que signifie le terme "schema-less" ?
a. Pas de structure de données
b. Structure de données fixe
c. Flexibilité dans la structure des données
d. Aucune structure de données
e. Aucune des réponses précédentes

23. Quel est l'un des principaux inconvénients des bases de données NoSQL ?

a. Scalabilité
b. Complexité des requêtes
c. Coût
d. Sécurité
e. Aucune des réponses précédentes

24. Dans le modèle CAP, un système peut garantir :
a. Cohérence et disponibilité
b. Disponibilité et partitionnement
c. Cohérence et partitionnement
d. Disponibilité, cohérence et partitionnement
e. Aucune des réponses précédentes

25. Les formats de fichier utilisés par Hadoop pour stocker des données ?
a. CSV
b. JSON
c. Parquet
d. TXT
e. Aucune des réponses précédentes

26. Quel est le format de données le plus utilisé dans les bases de données orientées document.
a. XML
b. JSON
c. CSV
d. YAML
e. Aucune des réponses précédentes

27. La normalisation dans les bases de données signifie que :
a. Les données sont stockées en réduisant la redondance et en évitant la duplication.
b. Les données sont fragmentées et distribuées sur plusieurs nœuds pour améliorer les performances.
c. Les données sont stockées sous une forme redondante pour améliorer les performances de lecture et simplifier les requêtes.
d. Les données sont organisées en utilisant des relations complexes entre différentes tables pour garantir l'intégrité référentielle.
e. Aucune des réponses précédentes

28. Quel est l'objectif principal d'une base de données NOSQL ?
a. Garantir une stricte cohérence des données
b. Fournir une structure tabulaire pour toutes les données
c. Gérer des données massives et non structurées.
d. Minimiser les coûts de stockage
e. Aucune des réponses précédentes

29. Quel type de base de données serait la plus adaptée pour stocker les données d'un réseau social caractérisé par un graphe relationnel complexe ?
    a. Relationnelle
    b. Transactionnelle
    c. Datawarehouse
    d. NoSQL
    e. Aucune des réponses précédentes
30. Quel type de base de données est le plus adapté pour fournir des recommandations en temps réel tout en étant scalable ?
    a. Relationnelle
    b. Transactionnelle
    c. Datawarehouse
    d. NoSQL
    e. Aucune des réponses précédentes

Exercice 2: Hadoop Map Reduce (5 points)

Le fichier texte intitulé « **links.txt** », disponible sur HDFS, contient des informations sur des pages web ainsi que leurs liens associés. Ce fichier a une taille totale de **128 To**.

Chaque ligne, composée de trois colonnes séparées par des tabulations, représente une page web avec les éléments suivants :

- **Colonne 1** : la page web source,
- **Colonne 2** : le score attribué par la page source,
- **Colonne 3** : une liste des pages de destination vers lesquelles la page source établit des liens.

Le but est de développer une solution avec **Hadoop Map Reduce** pour calculer le score reçu par chaque page comme illustré par l'exemple suivant.

Entrée				Sortie	
Page A	1	page B, page C, page D	→	Page A	2,5
Page B	2	page A, page C		Page B	2,33
Page C	3	page A, page E		Page C	1,33
Page D	2	page B		Page D	0,33
				Page E	1,5

Détails du calcul :

- Chaque page divise son score par le nombre de destinations vers lesquelles elle pointe. Par exemple, si une page Page A avec un score de 1 pointe vers 3 destinations (Page B, Page C, Page D), elle contribuera 0.33 à chacune de ces destinations.
- Le score total reçu par une page est la somme des contributions reçues de toutes les pages sources qui pointent vers elle.

Questions :

1. Expliquez pourquoi il est nécessaire dans Hadoop de diviser le fichier d'entrée en plusieurs blocs de taille égale (ici 128 Mo) ?
2. Pour ce cluster, le facteur de réplication est égal à 2. Calculer le nombre de tâches Map nécessaires pour traiter ce fichier ?
3. Que pouvez vous dire sur le nombre de tâches Reduce nécessaire pour ce problème ?
4. Illustrer une solution utilisant le modèle de programmation *MapReduce* sur l'exemple.

Bon travail !