

# Bases de données NOSQL et Big Data

## – TP1 : Initiation à Hadoop –

### Objectifs du TP :

Dans ce TP, vous allez travailler sur un cluster Hadoop 3, utiliser et programmer HDFS (Hadoop File System). C'est l'espace de stockage des fichiers distribués. Il ressemble à l'arbre Unix et il y a des commandes très similaires pour manipuler les fichiers et les dossiers. Le but du TP est d'apprendre les concepts et les commandes afin de bien gérer les fichiers sur HDFS.

### Partie 1 : Installation et configuration

Pour déployer le framework Hadoop, nous allons utiliser des conteneurs Docker [<https://www.docker.com/>]. L'utilisation des conteneurs va garantir la consistance entre les environnements de développement et permettra de réduire considérablement la complexité de configuration des machines (dans le cas d'un accès natif) ainsi que la lourdeur d'exécution (si on opte pour l'utilisation d'une machine virtuelle).

Voici les étapes pour déployer le cluster Hadoop en utilisant Docker :

1. Cloner l'image du cluster Hadoop : Pour commencer, vous devez cloner l'image Docker du cluster Hadoop, disponible à l'adresse suivante : <https://github.com/big-data-europe/docker-hadoop>

```
git clone https://github.com/big-data-europe/docker-hadoop
```

2. Utiliser Docker Compose : Une fois l'image du cluster Hadoop clonée, vous pouvez utiliser Docker Compose pour simplifier le déploiement. Il vous suffit de lancer la commande suivante dans votre terminal :

```
Docker compose up -d
```

3. Démarrer le cluster Hadoop : Après avoir exécuté la commande précédente, tous les conteneurs du cluster Hadoop seront démarrés automatiquement. Cela inclut les composants essentiels tels que le namenode, le datanode, le resourcemanager, le nodemanager, et le historyserver.

## **Partie 2 : Commande de HDFS**

### **Rappel : architecture HDFS**

HDFS repose principalement sur deux types de nœuds :

- **NameNode** : gère les métadonnées du système de fichiers et la localisation des blocs.
- **DataNode** : stocke les blocs de données.

Lorsqu'un fichier est chargé dans HDFS, il est découpé en blocs qui peuvent être distribués et répliqués sur plusieurs DataNodes.

Connectez-vous au container du **namenode** en utilisant la commande Docker suivante.

```
docker exec -it namenode bash
```

Le résultat de cette exécution sera le suivant :

```
root@7ea027891999:/#
```

Créer le fichier "**bonjour.txt**" en utilisant la commande suivante :

```
echo "Bonjour Hadoop et HDFS" > bonjour.txt
```

Toutes les commandes interagissant avec le système Hadoop commencent par **hdfs dfs** ou **hadoop fs** (**hdfs dfs** est utilisé avec les versions Hadoop les plus récentes). Ensuite, les options rajoutées sont très largement inspirées des commandes Unix standard.

Dans ce qui suit, vous allez manipuler deux systèmes de fichiers.

- les fichiers et dossiers disponible sur le disque local du conteneur **namenode**, visibles avec **ls**.
- les fichiers et dossiers HDFS, visibles en faisant **hdfs dfs -ls**.

### **Remarque :**

Si pour une raison ou une autre, vous n'arrivez pas à créer un répertoire, avec un message ressemblant à ceci :

```
ls: `.`: No such file or directory,
```

Veiller à construire l'arborescence de l'utilisateur principal (root), comme suit:

```
hdfs dfs -mkdir -p /user/root
```

Voici quelques commandes à essayer rapidement :

- **hdfs dfs -ls /** : affiche ce qu'il y a à la racine HDFS. Vous pouvez descendre inspecter les dossiers que vous voyez. Exemple **hdfs dfs -ls /user**. Il n'y a pas de commande équivalente à **cd**, parce qu'il n'y a pas de notion de dossier courant dans HDFS, donc à chaque fois, il faut remettre le chemin complet. C'est une habitude à prendre.
- **hdfs dfs -ls -R -h /var** : affiche les fichiers des sous-dossiers, avec une taille arrondie en Ko, Mo ou Go (l'option **-h** = *human units* existe aussi sur Unix).

- **hdfs dfs -mkdir dossier** : crée un dossier dans votre espace HDFS. Notez que la taille d'un dossier sera toujours 0.
- Reprenez le fichier appelé "**bonjour.txt**", vérifiez qu'il n'est pas vide.
- Copiez ce fichier sur HDFS par : **hdfs dfs -put bonjour.txt**. Utilisez **hdfs dfs -ls -R** pour vérifier.
- **hdfs dfs -cat bonjour.txt** : affiche le contenu. Il n'y a pas de commande `more` mais vous pouvez faire **hdfs dfs -cat bonjour.txt | more**
- **hdfs dfs -tail bonjour.txt** : affiche le dernier Ko du fichier.
- Supprimez ce fichier de HDFS par **hdfs dfs -rm bonjour.txt**.
- Remettez à nouveau ce fichier par **hdfs dfs -copyFromLocal bonjour.txt** (vérifier avec **hdfs dfs -ls**). Cette commande est similaire à **hdfs dfs -put**.
- **hdfs dfs -chmod go+w bonjour.txt** (vérifiez son propriétaire, son groupe et ses droits avec **hdfs dfs -ls**)
- **hdfs dfs -chmod go-r bonjour.txt** (vérifiez les droits)
- **hdfs dfs -mv bonjour.txt dossier/bonjour.txt** (vérifiez avec **hdfs dfs -ls -R**)
- **hdfs dfs -get dossier/bonjour.txt bien.txt** : transfère le fichier de HDFS vers le local en lui changeant son nom. Cette commande ne serait pas à faire avec de vraies mégadonnées !
- **hdfs dfs -cp dossier/bonjour.txt dossier/bien.txt** (vérifiez)
- **hdfs dfs -count -h /dossier** : affiche le nombre de sous-dossiers, fichiers et octets occupés dans /dossier. Cette commande correspond à peu près à du `-h` dans Unix.
- **hdfs dfs -rm dossier/bonjour.txt** (vérifiez avec **hdfs dfs -ls dossier**).
- **hdfs dfs -rm -r dossier** (vérifiez avec **hdfs dfs -ls**).

### Partie 3 : Création d'une arborescence et téléchargement de fichier

1. Créez une structure de répertoires sur HDFS avec le dossier parent "**TPs**" et le sous-dossier "**data**". Utilisez les commandes HDFS nécessaires pour réaliser cela.
2. Téléchargez le fichier **purchases.txt** à partir de (<https://www.kaggle.com/datasets/dsfelix/purchases.txt>) sur votre machine hôte et le copier vers le container **namenode** puis dans le dossier "**data**" en utilisant la commande **docker cp** dont la syntaxe est la suivante :

**docker cp container:source\_path destination\_path** (pour copier à partir d'un container)

**docker cp source\_path container:destination\_path** (pour copier vers un container)

3. Depuis votre machine hôte, téléchargez le fichier « **pg4300.txt** » du roman « Ulysse » disponible sur <https://www.gutenberg.org/cache/epub/4300/pg4300.txt> directement sur le nœud **namenode** en utilisant la commande **docker exec**. Placer ensuite ce fichier sous le dossier **data** de HDFS.
4. Depuis le container **namenode**, téléchargez le fichier « **pg135.txt** » du roman « Les misérables » disponible à l'URL <https://www.gutenberg.org/cache/epub/135/pg135.txt> . Placer ensuite ce fichier sous le dossier **data** de HDFS.
5. Recherchez une méthode permettant de générer, à partir de **purchases.txt**, un nouveau fichier nommé **purchases\_big.txt** contenant plusieurs répétitions (10 fois) du contenu du fichier original.
6. Utilisez les commandes HDFS pour lister le contenu du répertoire "**data**" sur HDFS, ainsi que pour afficher les informations sur les fichiers téléchargés.
7. Testez et expliquez les commandes suivantes.

- **hdfs dfs -du -h** /TPs/data
- **hdfs dfs -count -h** /TPs/data
- **hdfs fsck** /TPs/data/pg4300.txt -files -blocks -locations

### **Partie 3 : Etat du cluster**

Les services Hadoop génèrent des pages web automatiquement pour permettre de suivre le fonctionnement. Cliquez sur ce lien : <http://localhost:9870/explorer.html#/> pour vous y connecter. La page que vous voyez propose plusieurs liens vers différents services Hadoop.

- Page *Overview* : Dans le tableau *Summary* vous avez l'espace total, l'espace utilisé, l'espace libre, avec des valeurs en %, des liens vers les DataNodes vivants, morts ou en train de se désactiver (*decommissioning nodes*).
- Page *Datanodes* : Vous voyez la capacité et la charge de chaque DataNode. La colonne *Last Contact* indique le nombre de secondes depuis le précédent « battement de cœur » (*heartbeat*) envoyé par le Datanode au Namenode, c'est le terme employé pour un signal périodique de bon fonctionnement. Il y a un contact toutes les 3 secondes. Un Datanode est considéré comme mort lorsqu'il n'a pas donné signe de vie depuis 10 minutes. Vous pouvez rafraîchir pour voir l'évolution.
- Page *Utilities* : un item *Browse the file system* vous permet de parcourir l'arbre des fichiers HDFS,. En cliquant sur le nom d'un fichier, vous aurez des informations sur les blocs et les machines contenant ce fichier. Ne cliquez sur *Download* que pour un petit fichier.

#### **Questions :**

1. Combien de DataNodes sont actuellement actifs ?
2. Quelle est la capacité totale du cluster ?
3. Quelle quantité d'espace est utilisée et quelle quantité est disponible ?
4. Quel est le facteur de réplication observé pour les blocs du fichier **purchases.txt** ?

## **Annexe : Principales Commande HDFS**

Dans la Table 1 nous résumons les commandes les plus utilisées dans Hadoop HDFS. La Liste complète est disponible sur :

<https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-common/FileSystemShell.html>

|                                                 |                                                                      |
|-------------------------------------------------|----------------------------------------------------------------------|
| <code>hadoop fs -ls</code>                      | Afficher le contenu du répertoire racine                             |
| <code>hadoop fs -put file.txt</code>            | Upload un fichier dans hadoop (à partir du répertoire courant linux) |
| <code>hadoop fs -get file.txt</code>            | Download un fichier à partir de hadoop sur votre disque local        |
| <code>hadoop fs -tail file.txt</code>           | Lire les dernières lignes du fichier                                 |
| <code>hadoop fs -cat file.txt</code>            | Affiche tout le contenu du fichier                                   |
| <code>hadoop fs -cat file.txt   less</code>     | Lire le fichier page par page                                        |
| <code>hadoop fs -mv file.txt newfile.txt</code> | Renommer le fichier                                                  |
| <code>hadoop fs -rm newfile.txt</code>          | Supprimer le fichier                                                 |
| <code>hadoop fs -mkdir myinput</code>           | Créer un répertoire                                                  |
| <code>hadoop fs -rm -f -r myinput</code>        | Supprime un répertoire, et son contenu récursivement                 |