Machine Learning · 3e année Génie Logiciel

Chapitre 2 — Préparation des données & analyse exploratoire (EDA)

Séance 1 sur 2 · Types de données, statistiques descriptives, valeurs manquantes, valeurs aberrantes

Dr. Nizar Omheni
ISIMM — Université de Monastir · Année universitaire 2026–2027

Sur des données réelles, une règle de nettoyage naïve peut supprimer près de 80 % des lignes

891

passagers dans le jeu Titanic (copie seaborn-data)

177

âges manquants (19,9 %)

688

valeurs de pont (deck) manquantes (77,2 %)

182

lignes restantes si l'on supprime toute ligne avec âge, deck ou embarked manquant

Avant tout modèle : que faire de ces trous ? A · supprimer les lignes B · compléter les valeurs C · supprimer des colonnes

À la fin de cette séance, vous saurez faire quatre choses

Résultats observables — chacun est pratiqué et vérifié aujourd'hui

1. Classer une variable : continue, discrète, nominale ou ordinale
2. Calculer à la main moyenne, variance et écart-type, et dire si un outil divise par n ou n − 1
3. Choisir et justifier un traitement des valeurs manquantes
4. Détecter les valeurs aberrantes avec la règle IQR et décider quoi en faire

Séance 2

- Encodage des catégories
- Mise à l'échelle
- Corrélation & EDA
- Fuite de données

Rappel du chapitre 1 : pourquoi le jeu de test est-il intouchable ?

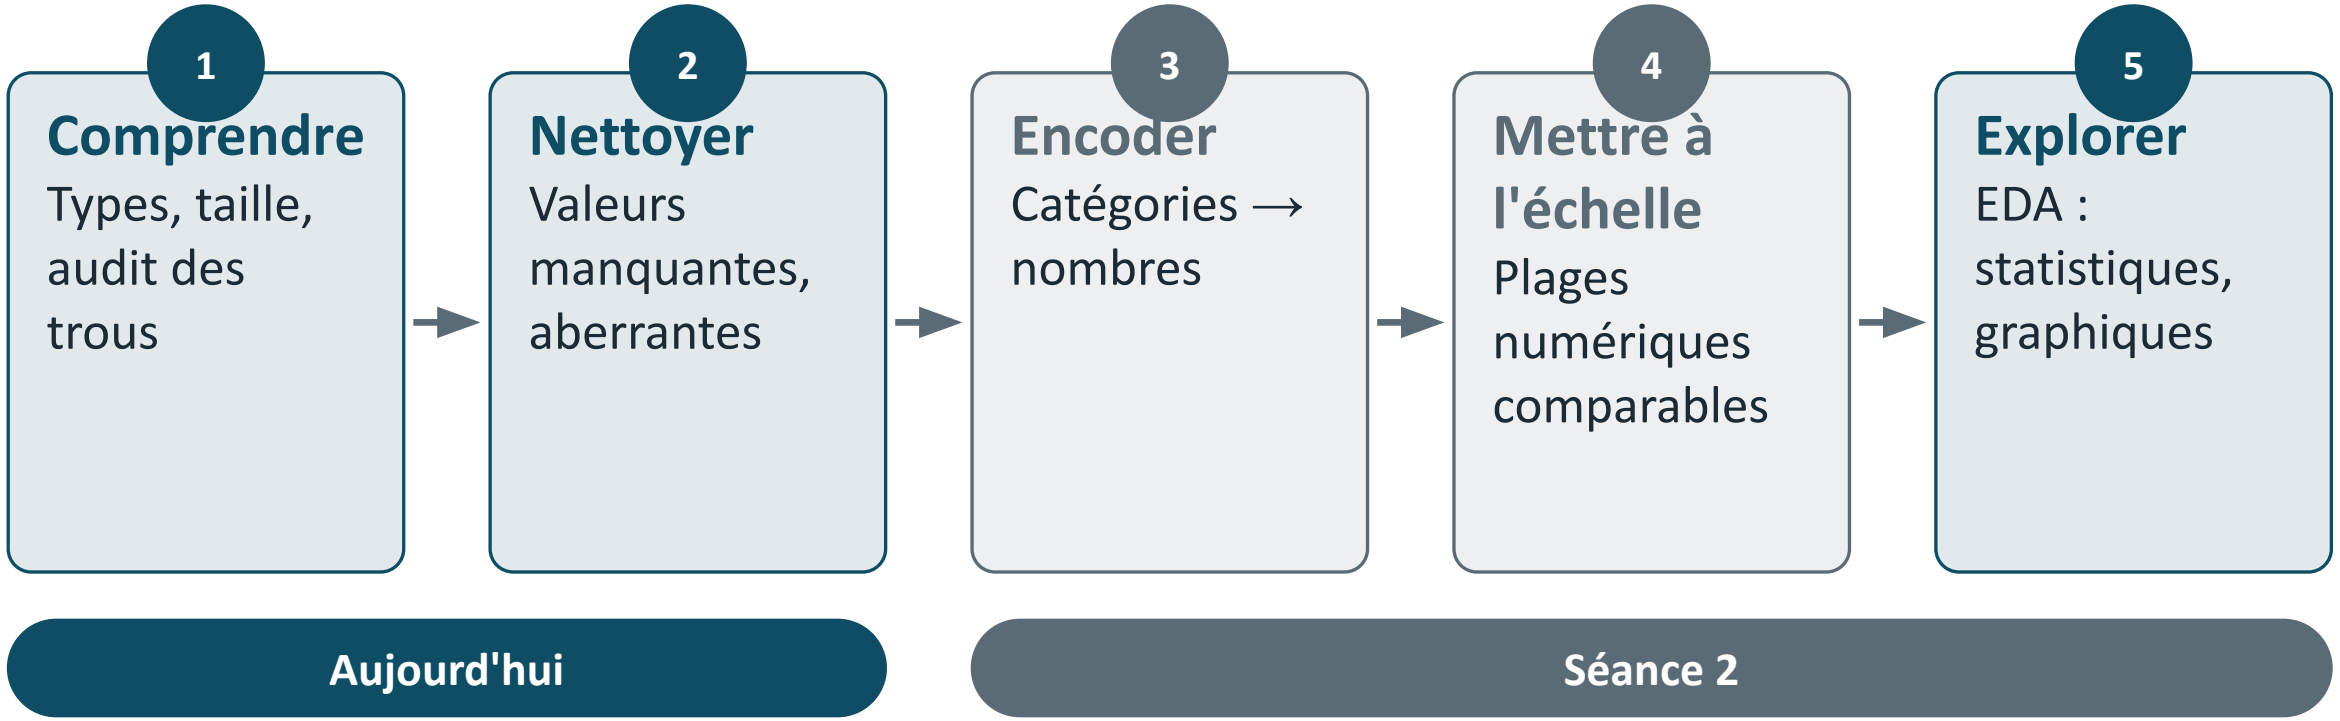
RAPPEL · 1 min · individuel

Pourquoi le jeu de test doit-il rester intact jusqu'à l'évaluation finale ? Écrivez une phrase.

Indice : qu'est-ce que le score de test est censé estimer ?

Réflexion seule pendant 1 minute, puis deux volontaires répondent. Sans notes.

La préparation des données est un pipeline en cinq étapes



Règle du chapitre : séparer d'abord, ajuster chaque étape sur l'apprentissage seulement, puis transformer les deux jeux

PARTIE 1

Connaître ses types de données

Le type d'une variable décide comment on la nettoie, l'encode et la met à l'échelle

Les variables sont numériques ou catégorielles — chaque famille a deux sortes

Numérique · continue
Toute valeur dans un intervalle

Titanic : age, fare (prix du billet)

Numérique · discrète
Comptages (entiers)

Titanic : sibsp, parch (proches à bord)

Catégorielle · nominale
Étiquettes sans ordre

Titanic : sex, embarked (C / Q / S)

Catégorielle · ordinale
Étiquettes avec un ordre significatif

Titanic : classe (1re / 2e / 3e) ; faible < moyen < élevé

Les modèles calculent sur des nombres : les catégorielles doivent être converties, et la manière de le faire encode une hypothèse

À vous : classez six variables

ACTIVITÉ · 2 min · individuel

Quel est le type de chaque variable ?

1 · Taille de T-shirt (S / M / L)	2 · Pays	3 · Satisfaction (1–5 étoiles)
4 · Groupe sanguin	5 · sibsp (proches à bord)	6 · fare (prix du billet)

Montrez des doigts pour chaque item : 1 = continue · 2 = discrète · 3 = nominale · 4 = ordinale

Correction : un chiffre ne rend pas une variable numérique

Variable	Type	Pourquoi
Taille de T-shirt	Ordinale	S < M < L
Pays	Nominale	Pas d'ordre naturel
Satisfaction (étoiles)	**Ordinale**	**Ordonnée ; écarts égaux non garantis**
Groupe sanguin	Nominale	Pas d'ordre naturel
sibsp	Numérique · discrète	Un comptage
fare	Numérique · continue	Tout montant d'un intervalle

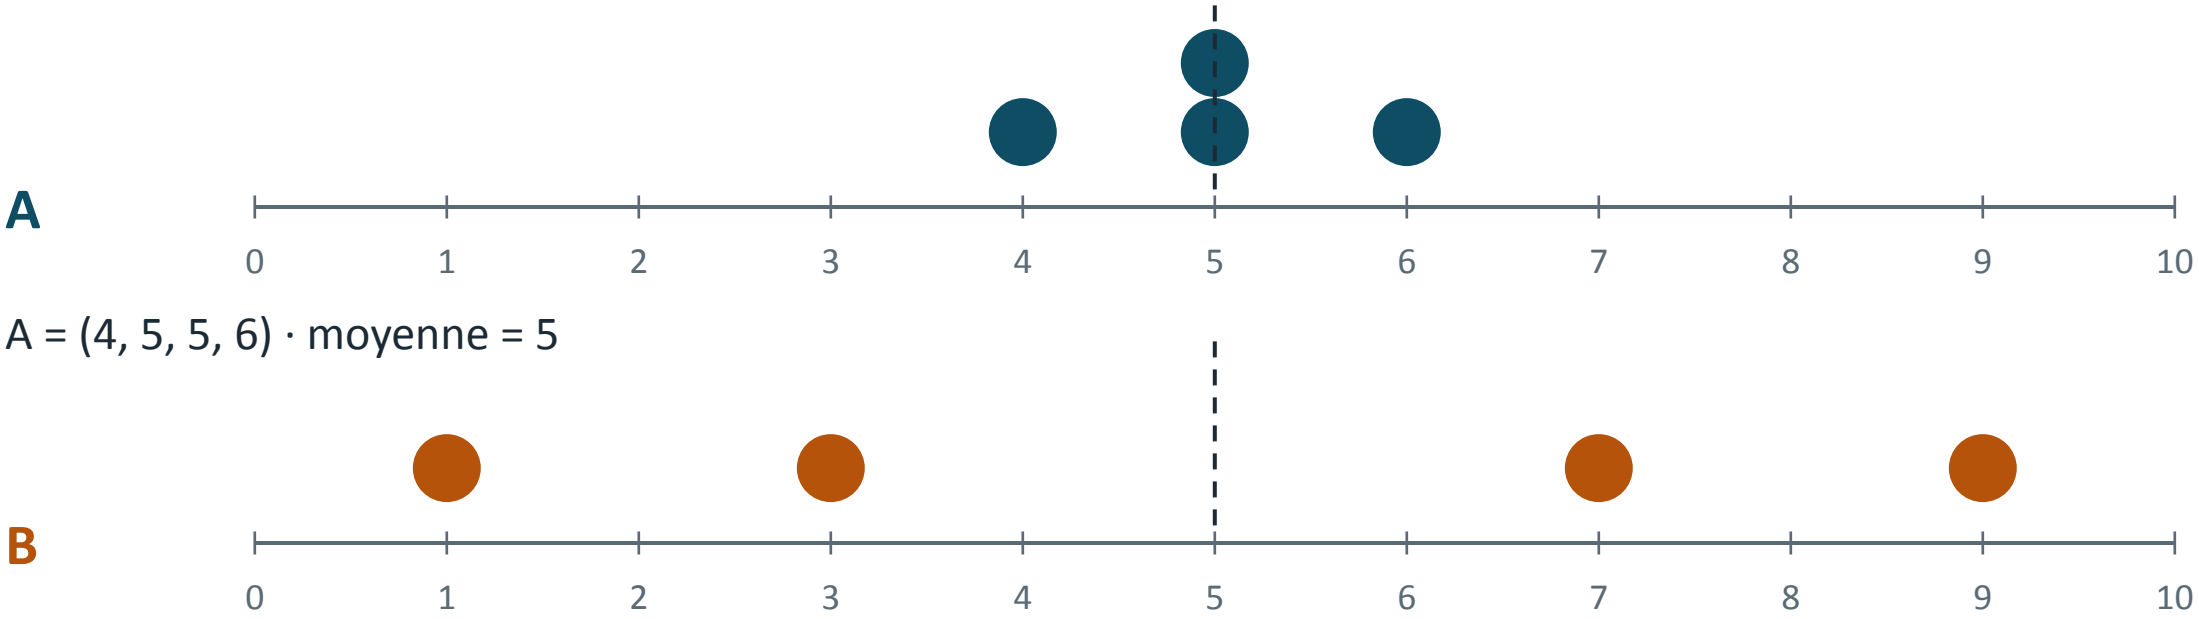
Les étoiles ne se traitent comme des nombres que si l'on suppose l'écart 1→2 égal à l'écart 4→5 — énoncez cette hypothèse

PARTIE 2

Décrire une variable numérique

Centre et dispersion : moyenne, variance, écart-type

Deux jeux de données peuvent avoir la même moyenne et rester très différents



A = (4, 5, 5, 6) · moyenne = 5

B = (1, 3, 7, 9) · moyenne = 5

Question : quel nombre unique capterait la différence entre A et B ?

La moyenne mesure le centre ; la variance et l'écart-type mesurent la dispersion

Moyenne

$$\bar{x} = (1/n) \cdot \Sigma\, x_i$$

Le point d'équilibre des valeurs

Variance (population)

$$\sigma^2 = (1/n) \cdot \Sigma\, (x_i - \bar{x})^2$$

Distance au carré moyenne à la moyenne

Écart-type

$$\sigma = \sqrt{\sigma^2}$$

Retour à l'unité des données (années, dinars…)

Pourquoi le carré ?

Les écarts bruts somment toujours à 0 : les positifs annulent les négatifs.

Le carré les rend positifs et pèse davantage les grands écarts.

Exemple résolu : moyenne et écart-type en trois lignes

Données : x = (2, 4, 4, 4, 5, 5, 7, 9), n = 8. Étape 1 : $\bar{x}$ = 40 / 8 = **5**

									Σ
x_i	2	4	4	4	5	5	7	9	**40**
$x_i - \bar{x}$	−3	−1	−1	−1	0	0	2	4	**0**
$(x_i - \bar{x})^2$	9	1	1	1	0	0	4	16	**32**

Étape 2 : σ^2 = 32 / 8 = **4** Étape 3 : $\sigma = \sqrt{4}$ = **2**

Vérification : les écarts somment à 0 ✓ (vérifié aussi avec NumPy : np.std(x) = 2.0)

Diviser par n ou par n − 1 ? Votre bibliothèque décide en silence

Mêmes données x (n = 8)	Divise par	Résultat
Formule population σ	n	2,000
Formule échantillon s (Bessel)	n − 1	2,138
np.std(x)	n	2,000
pd.Series(x).std()	n − 1	2,138
StandardScaler().fit(X).scale_	n	2,000

Pourquoi n − 1 ?

La moyenne est elle-même estimée sur le même échantillon ; diviser par n − 1 corrige la sous-estimation de la variance qui en résulte.

Règle : connaître le ddof de son outil.

Vérifié par exécution avec NumPy 2.5.3, pandas 3.0.5, scikit-learn 1.9.1 — à revérifier après une mise à jour majeure

À vous : mesurez la dispersion du jeu B

MINI-CALCUL · 3 min · individuel, sur papier

B = (1, 3, 7, 9). Calculez la moyenne et l'écart-type de population σ.

Réutilisez le tableau à trois lignes : $x_i \cdot x_i - \bar{x} \cdot (x_i - \bar{x})^2$

Laissez σ sous forme de racine si vous n'avez pas de calculatrice

Comparez ensuite avec votre voisin pendant 30 secondes avant la correction.

Correction : même moyenne, mais B est environ 4,5 fois plus dispersé que A

					Σ
x_i	1	3	7	9	**20**
$x_i - \bar{x}$	−4	−2	2	4	**0**
$(x_i - \bar{x})^2$	16	4	4	16	**40**

$\bar{x} = 20 / 4 = \mathbf{5}$ $\sigma^2 = 40 / 4 = \mathbf{10}$ $\sigma = \sqrt{10} \approx \mathbf{3,16}$

Pour A = (4, 5, 5, 6) : $\sigma = \sqrt{0,5} \approx 0,71 \rightarrow$ rapport ≈ 4,5. C'est le nombre qui répond à la question du graphique à points.

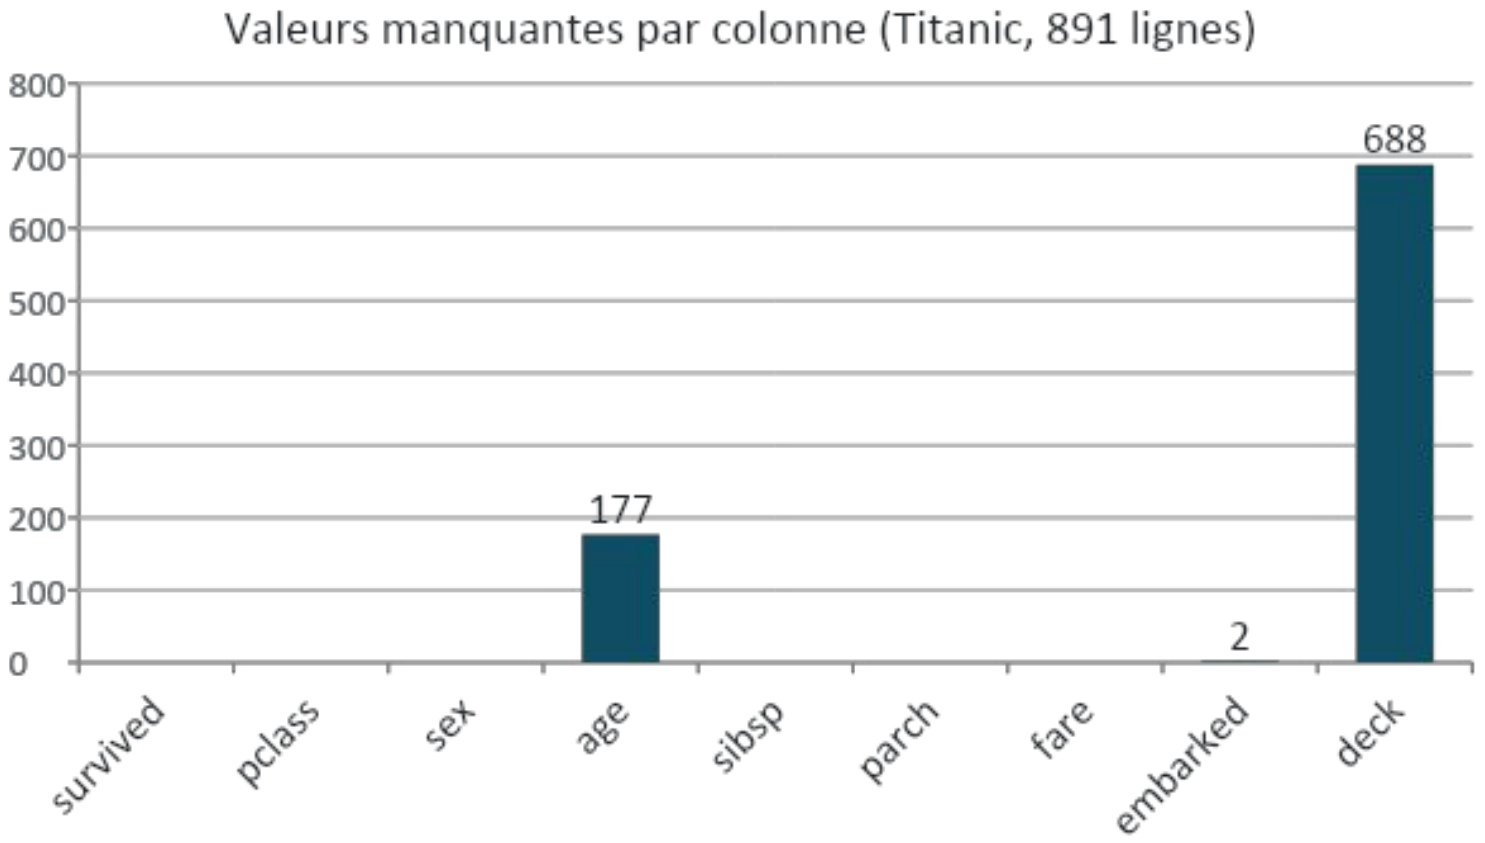
Donnez la dispersion avec la moyenne : une moyenne seule cache à quel point elle est typique

PARTIE 3

Traiter les valeurs manquantes

Auditer d'abord, puis supprimer ou imputer — et justifier le choix

Les manques sont inégaux : une colonne est presque vide, une autre à peine touchée



En part des 891 lignes

deck : 77,2 %

age : 19,9 %

embarked : 0,2 % (2 lignes)

Ligne d'audit : df.isna().sum()

Trois options face à un trou — chacune a un coût

Supprimer les lignes

Quand : très peu de lignes touchées

Coût : données perdues ; biais si les lignes manquantes diffèrent des autres

Titanic : dropna sur 3 colonnes garde 182 / 891

Supprimer la colonne

Quand : la colonne est presque vide

Coût : le signal qu'elle portait est perdu

Titanic : deck, 77,2 % manquant

Imputer (compléter)

Quand : manque modéré

Numérique : médiane ou moyenne

Catégorielle : valeur la plus fréquente ou catégorie « Missing »

Coût : déforme la distribution

Imputation = remplacer une valeur manquante par une valeur estimée. Cette valeur est calculée sur les données : elle est apprise

Prédisez : quelle valeur de remplacement est la plus plausible ?

PRÉDICTION · 1 min · vote

Prix de billets synthétiques : 7, 8, 8, 9, 10, ?, 250. Une valeur manque. Quelle valeur de remplacement décrit le mieux un passager typique ?

A · la moyenne des six valeurs connues

B · la médiane des six valeurs connues

Un doigt pour A, deux pour B. Décidez avant de calculer.

Un prix extrême tire la moyenne ; la médiane reste du côté des passagers typiques

48,67

Moyenne = 292 / 6 — supérieure à 5 des 6 prix connus

8,5

Médiane = (8 + 9) / 2 — le milieu des valeurs triées

Pourquoi

La moyenne utilise la taille de 250 ; la médiane n'utilise que sa position (c'est « le plus grand »).

Règle pratique

Colonne numérique asymétrique → médiane. À peu près symétrique → la moyenne convient.

L'imputation a des limites à connaître avant de l'utiliser

Pic artificiel

Remplir 177 âges avec une seule valeur rend 19,9 % des lignes identiques ; un modèle peut s'y accrocher.

L'absence peut être une information

Si le fait de manquer porte un signal, ajouter une colonne indicatrice, p. ex. age_was_missing (0/1).

Trous catégoriels

Compléter par la catégorie la plus fréquente, ou créer une catégorie explicite « Missing ».

La valeur de remplacement est apprise

La calculer sur l'apprentissage seulement — jamais sur tout le jeu (séance 2).

À vous : décidez pour chaque colonne du Titanic

ACTIVITÉ · 3 min · binômes

Pour chaque colonne : supprimer des lignes, supprimer la colonne ou imputer (avec quelle valeur) ? Justifiez en une phrase.

age · numérique · 19,9 % manquant

deck · catégorielle · 77,2 % manquant

embarked · nominale · 2 lignes manquantes (S 644 · C 168 · Q 77)

Discutez avec votre voisin ; trois binômes présenteront chacun une décision.

Correction : des décisions ciblées conservent les 891 passagers

Colonne	Décision	Justification
age	Imputer la médiane (+ age_was_missing optionnel)	80 % des valeurs présentes ; médiane robuste à l'asymétrie
deck	Supprimer la colonne (ou garder « Missing » comme catégorie pour la tester)	77,2 % vide : imputer reviendrait surtout à inventer
embarked	Imputer la valeur la plus fréquente « S »	Seulement 2 lignes ; S = 644 / 889 connues (72,4 %)

Retour au vote d'ouverture : supprimer toute ligne incomplète gardait 182 passagers ; décider colonne par colonne en garde 891

PARTIE 4

Détecter les valeurs aberrantes et décider

Une valeur extrême est une question, pas automatiquement une erreur

Prix du Titanic : quelques valeurs très élevées tirent la moyenne loin au-dessus de la médiane

14,45

prix médian

32,20

prix moyen

512,33

prix maximal (n = 891)

Erreur
Valeur impossible, p. ex. âge = 250 ans → corriger ou supprimer

Rare mais réelle
Valeur extrême valide, p. ex. un billet très cher → en général garder

Autre population
Un groupe différent mélangé → l'étudier à part

Deux règles de détection : les barrières IQR et le z-score

Quartiles et écart interquartile

$$\mathrm{IQR} = Q_3 - Q_1$$

Q1 = 25e centile, Q3 = 75e centile : les 50 % centraux des données

Règle IQR (barrières de Tukey)

$$x < Q_1 - 1{,}5 \cdot \mathrm{IQR} \quad \text{ou} \quad x > Q_3 + 1{,}5 \cdot \mathrm{IQR}$$

Utilise les quartiles : les aberrantes déplacent à peine les barrières

Règle du z-score

$$|z| > 3 \quad \text{avec} \quad z = (x - \bar{x}) / \sigma$$

Adaptée aux données à peu près en cloche

Limites

1,5 et 3 sont des conventions, pas des lois.

Une valeur extrême gonfle σ lui-même, ce qui peut la cacher à la règle du z-score.

Exemple résolu : la règle IQR signale 250 et rien d'autre

Synthétiques : 7, 8, 8, 9, 10, 12, 250 (n = 7)

Étape	Valeur
Q1 (25e centile)	8
Q3 (75e centile)	11
IQR = Q3 − Q1	3
Barrière basse 8 − 1,5×3	3,5
Barrière haute 11 + 1,5×3	**15,5**

Les conventions diffèrent

Le défaut de NumPy et pandas (interpolation linéaire) donne Q3 = 11.

D'autres conventions donnent Q3 = 10 ou 12 → barrière haute 13 ou 18.

Même verdict ici ; un point limite peut changer.

Verdict : 250 > 15,5 → signalé ; toutes les autres valeurs sont dans [3,5 ; 15,5]

Une fois détectée, choisir parmi quatre actions — avec la connaissance du domaine

Garder

Valeur réelle et pertinente

Préférer des outils robustes (médiane, IQR)

Plafonner (winsoriser)

Remplacer par la barrière ou un centile élevé

Garde la ligne, limite son influence

Supprimer

Seulement une erreur avérée

Documenter quoi et pourquoi

Transformer

p. ex. log pour des données positives asymétriques

fare du Titanic contient des zéros → log(1 + x)

La détection est automatique ; la décision ne l'est pas. Notez la décision pour qu'elle soit reproductible

Vérification finale : vrai ou faux ?

VÉRIFICATION · 3 min · individuel

Pouce levé = vrai, pouce baissé = faux — vote item par item au compte de 3.

1 · Une valeur aberrante est toujours une erreur de saisie.

2 · Pour une colonne asymétrique à droite, la médiane est moins affectée par les extrêmes que la moyenne.

3 · Sur les mêmes données, pandas .std() et np.std() renvoient la même valeur par défaut.

4 · Supprimer toute ligne contenant une valeur manquante est toujours un choix sûr.

Correction de la vérification finale

#	Réponse	Pourquoi
1	Faux	Elle peut être rare mais réelle, ou venir d'une autre population ; vérifier avant d'agir
2	Vrai	La médiane dépend des positions, pas de l'ampleur de la plus grande valeur
3	Faux	pandas divise par n − 1 (ddof = 1), NumPy par n (ddof = 0) : 2,138 contre 2,000
4	Faux	Sur le Titanic, cela gardait 182 lignes sur 891 et peut biaiser le reste

Ce qu'il faut retenir de la séance 1

- Le type décide du traitement : un chiffre n'est pas forcément numérique
- Donner une dispersion avec chaque moyenne ; savoir si l'outil divise par n ou n − 1
- Valeurs manquantes : auditer, puis décider colonne par colonne — lignes, colonne ou imputation
- Données asymétriques : la médiane résiste mieux aux extrêmes que la moyenne
- Aberrantes : détecter avec une règle (IQR), décider avec le domaine, documenter

Séance 2

- Encodage des catégories
- Mise à l'échelle
- Corrélation & EDA sur le Titanic
- Fuite de données : pourquoi chaque valeur de remplacement et chaque échelle viennent de l'apprentissage

Références et données utilisées dans cette séance

- Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley. — boîtes à moustaches et barrières à 1,5 × IQR
- McKinney, W. (2022). Python for Data Analysis (3e éd.). O'Reilly. Édition web en libre accès : wesmckinney.com/book
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An Introduction to Statistical Learning with Applications in Python. Springer. doi:10.1007/978-3-031-38747-0
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830
- Données : jeu Titanic distribué dans le dépôt seaborn-data (github.com/mwaskom/seaborn-data), titanic.csv, 891 lignes × 15 colonnes

Tous les chiffres de ces diapositives ont été recalculés en exécutant Python (NumPy 2.5.3, pandas 3.0.5, scikit-learn 1.9.1) sur ce fichier. Les exemples synthétiques sont signalés comme tels.