Machine Learning · 3e année Génie Logiciel

Chapitre 2 — Préparation des données & analyse exploratoire (EDA)

Séance 2 sur 2 · Encodage, mise à l'échelle, corrélation & EDA, fuite de données

Nizar Omheni
ISIMM — Université de Monastir · Année universitaire 2026–2027

Échauffement : trois questions de la séance 1

RÉCUPÉRATION · 4 min · individuel, sans notes

Répondez sur papier.

1 · Moyenne et écart-type de population de (2, 2, 6, 6) ?

2 · Un prix manque dans une colonne asymétrique à droite. Moyenne ou médiane pour le compléter ? Pourquoi ?

3 · Écrivez la barrière haute de la règle IQR.

Récupérer sans notes renforce davantage la mémoire que relire.

Correction de l'échauffement

#	Réponse	Raisonnement
1	$\bar{x} = 4$, $\sigma = 2$	Écarts $-2, -2, 2, 2 \rightarrow$ somme des carrés $16 \rightarrow \sigma^2 = 16/4 = 4$
2	Médiane	Robuste aux extrêmes (fare du Titanic : moyenne 32,20, médiane 14,45)
3	$Q_3 + 1{,}5 \cdot \text{IQR}$	Avec $\text{IQR} = Q_3 - Q_1$

À la fin de cette séance, vous saurez faire quatre choses

Chacune est pratiquée et vérifiée dans l'évaluation finale

1. Encoder des variables nominales et ordinales sans inventer d'ordre
2. Standardiser ou normaliser (min–max) une variable, et choisir selon le contexte
3. Calculer covariance et r de Pearson, et lire les résultats d'EDA comme des hypothèses
4. Expliquer la fuite de données et l'éviter : séparer, ajuster sur l'apprentissage, transformer les deux

Rappel séance 1

- Types de données
- Moyenne, variance, écart-type
- Valeurs manquantes
- Aberrantes (IQR)

PARTIE 1

Encoder les catégories en nombres

Un modèle ne sait pas calculer « Cherbourg − Southampton »

Encodage one-hot : une colonne binaire par catégorie, aucun ordre inventé

Variable nominale embarked ∈ {C, Q, S}

Passager	embarked	embarked_C	embarked_Q	embarked_S
1	S	0	0	1
2	C	1	0	0
3	Q	0	1	0
4	S	0	0	1

Propriétés

k catégories ⟶ k colonnes

Exactement un 1 par ligne

Toutes les catégories sont à égale distance

Mêmes noms de colonnes que OneHotEncoder de scikit-learn (vérifié)

Encodage ordinal : des codes entiers qui préservent un ordre réel

Variable ordinale size $\in \{S < M < L\}$

size	size_code
S	0
M	1
L	2

Ce qu'il suppose

Un ordre existe : S < M < L ✓

Pour un modèle linéaire, aussi des pas égaux : S⟶M compte autant que M⟶L

La classe du Titanic (1re/2e/3e) est ordonnée ; le pipeline du chapitre l'encode en one-hot, ce qui évite de supposer des pas égaux — les deux choix se défendent

Trois erreurs d'encodage qui trompent un modèle en silence

✘ Codes ordinaux sur une nominale

C = 0, Q = 1, S = 2 dit à un modèle linéaire que Q est entre C et S, et que S − C = 2 × (Q − C). Rien de cela n'est vrai.

✘ One-hot sur des milliers de catégories

Des milliers de codes postaux ⟶ des milliers de colonnes creuses. Regrouper les catégories rares ou utiliser une autre stratégie (chapitres ultérieurs).

⚠ Catégorie inconnue en prédiction

Une catégorie absente de l'apprentissage apparaît en production. Dans le pipeline du chapitre, handle_unknown="ignore" l'encode par des zéros.

L'encodage est une hypothèse sur la variable : one-hot = pas d'ordre ; ordinal = ordre (et, pour un modèle linéaire, pas égaux)

À vous : choisissez un encodage

ACTIVITÉ · 2 min · binômes

Quel encodage pour chaque variable ?

1 · Jour de la semaine (lun … dim)

2 · Code postal (des milliers de valeurs distinctes)

3 · Niveau d'études (primaire < secondaire < supérieur)

4 · Mode de paiement (carte / espèces / mobile)

Doigts : 1 = one-hot · 2 = ordinal · 3 = ni l'un ni l'autre directement (autre stratégie)

Correction : le sens de la variable décide de l'encodage

Variable	Encodage	Pourquoi
Jour de la semaine	One-hot (1)	Son ordre est cyclique (dimanche → lundi) : des entiers 0–6 éloignent dimanche de lundi
Code postal	Aucun directement (3)	Forte cardinalité : regrouper (p. ex. par région) ou autre stratégie
Niveau d'études	Ordinal (2)	Un ordre réel existe
Mode de paiement	One-hot (1)	Nominale, peu de catégories

Des encodages cycliques (p. ex. sinus/cosinus du jour) existent pour les variables périodiques — option avancée, inutile aujourd'hui

PARTIE 2

Mettre les variables numériques à des échelles comparables

Standardisation et normalisation min–max

Sans mise à l'échelle, changer une simple unité change le plus proche voisin

Passagers synthétiques : A (22 ans, 7,25) · B (60 ans, 8,05) · C (23 ans, 70,00). Distance euclidienne depuis A :

Âge exprimé en…	d(A, B)	d(A, C)	Plus proche
années	38,0	62,8	**B**
mois	456,0	63,9	**C**

Mêmes passagers, même information — seule l'unité de l'âge a changé.

Leçon

La variable de plus grande amplitude numérique domine la distance — pas la plus importante.

Sensibles : kNN, k-means, SVM, descente de gradient. Insensibles : arbres de décision.

Deux remises à l'échelle courantes, toutes deux apprises sur l'apprentissage

Standardisation (z-score)

$$z_i = (x_i - \mu) / \sigma$$

Résultat : moyenne 0, écart-type 1 ; pas d'intervalle fixe

Normalisation min–max

$$x'_i = (x_i - x_{min}) / (x_{max} - x_{min})$$

Résultat : intervalle [0, 1] sur l'apprentissage

Statistiques ajustées

μ, σ, x_{min}, x_{max} sont calculés sur les données → sur l'apprentissage seulement.

Des valeurs de test peuvent alors sortir de [0, 1] — c'est normal.

scikit-learn : StandardScaler (z-score, σ de population) et MinMaxScaler — chacun avec fit sur l'apprentissage, transform sur les deux

Exemple résolu : standardiser et normaliser trois âges

Âges : 20, 30, 40 ⟶ $\mu = 30$, $\sigma = \sqrt{(200 / 3)} \approx 8{,}165$

	20	30	40
z-score $(x - 30) / 8{,}165$	−1,22	0	1,22
min–max $(x - 20) / 20$	0	0,5	1

Vérification : les z-scores ont une moyenne de 0 ✓ et les valeurs min–max couvrent [0, 1] ✓

Lire un z-score

z = 1,22 signifie 1,22 écart-type au-dessus de la moyenne.

L'unité (années) disparaît.

Une seule valeur extrême peut écraser toutes les autres valeurs standardisées

Prix synthétiques : 8, 9, 10, 250 ⟶ $\mu = 69{,}25$, $\sigma \approx 104{,}36$

	8	9	10	250
z-score	−0,59	−0,58	−0,57	**1,73**
log, puis z-score	−0,66	−0,57	−0,50	**1,73**

z-score : les trois prix ordinaires finissent à moins de 0,02 les uns des autres.

log d'abord : leur écart est environ 8 fois plus grand (0,15) — le modèle peut encore les distinguer.

Options

Transformation log (données positives ; log(1 + x) s'il y a des zéros)

Mise à l'échelle robuste (médiane et IQR)

Plafonner d'abord la valeur extrême

À vous : quelle préparation choisiriez-vous ?

ACTIVITÉ · 2 min · binômes

Choisissez une mise à l'échelle (ou aucune) et justifiez-la.

a · Intensités de pixels entre 0 et 255

b · Revenu des ménages, fortement asymétrique à droite, en entrée d'un kNN

c · Variables numériques d'un arbre de décision

Deux binômes présentent leur réponse ; les autres approuvent ou objectent.

Correction : les données et le modèle décident de la mise à l'échelle

a · Pixels → min–max
Bornes connues et fixes (0–255) : diviser par 255 ramène à [0, 1].

b · Revenu → log(1 + x), puis standardiser
Le log réduit l'asymétrie ; la standardisation met ensuite le revenu au même niveau que les autres variables pour les distances.

c · Arbre → pas de mise à l'échelle
Un arbre coupe sur des seuils d'une variable à la fois ; une remise à l'échelle monotone ne change pas les coupes possibles.

La mise à l'échelle n'est pas un rituel : l'appliquer quand le modèle utilise des distances ou des gradients, et choisir la formule selon la forme des données

PARTIE 3

Mesurer les relations et explorer les données

Covariance, r de Pearson, et lecture des résultats d'EDA comme des hypothèses

La covariance donne le sens d'une relation ; le r de Pearson donne sa force

Covariance

$$\mathrm{Cov}(x, y) = (1/n) \cdot \Sigma\,(x_i - \bar{x})(y_i - \bar{y})$$

> 0 : varient ensemble · < 0 : en sens opposé · dépend des unités

Corrélation de Pearson

$$r = \mathrm{Cov}(x, y) \,/\, (\sigma_x \cdot \sigma_y) \quad \in [-1, 1]$$

Sans unité : ±1 relation linéaire parfaite · 0 pas de relation linéaire

Lire r avec prudence

r ne mesure que l'association linéaire.

Corrélation n'est pas causalité.

Exemple résolu : covariance et r pour cinq points

$x = (1, 2, 3, 4, 5)$, $y = (2, 4, 5, 4, 5) \longrightarrow \bar{x} = 3, \bar{y} = 4$

						Σ
$\mathbf{x_i - \bar{x}}$	−2	−1	0	1	2	**0**
$\mathbf{y_i - \bar{y}}$	−2	0	1	0	1	**0**
produit	4	0	0	0	2	**6**

Cov = 6 / 5 = **1,2** $\quad \sigma_x = \sqrt{2} \approx 1{,}414 \quad \sigma_y = \sqrt{1{,}2} \approx 1{,}095$

r = 1,2 / (1,414 × 1,095) ≈ **0,77** → relation linéaire positive assez forte (NumPy np.corrcoef : 0,7746 ✓)

r = 0 ne veut pas dire « sans lien », et r ≠ 0 ne veut pas dire « cause »

Contre-exemple : $y = x^2$

$x = (-2, -1, 0, 1, 2) \longrightarrow y = (4, 1, 0, 1, 4)$

r = 0 exactement, alors que y est entièrement déterminé par x.

La relation est réelle mais non linéaire.

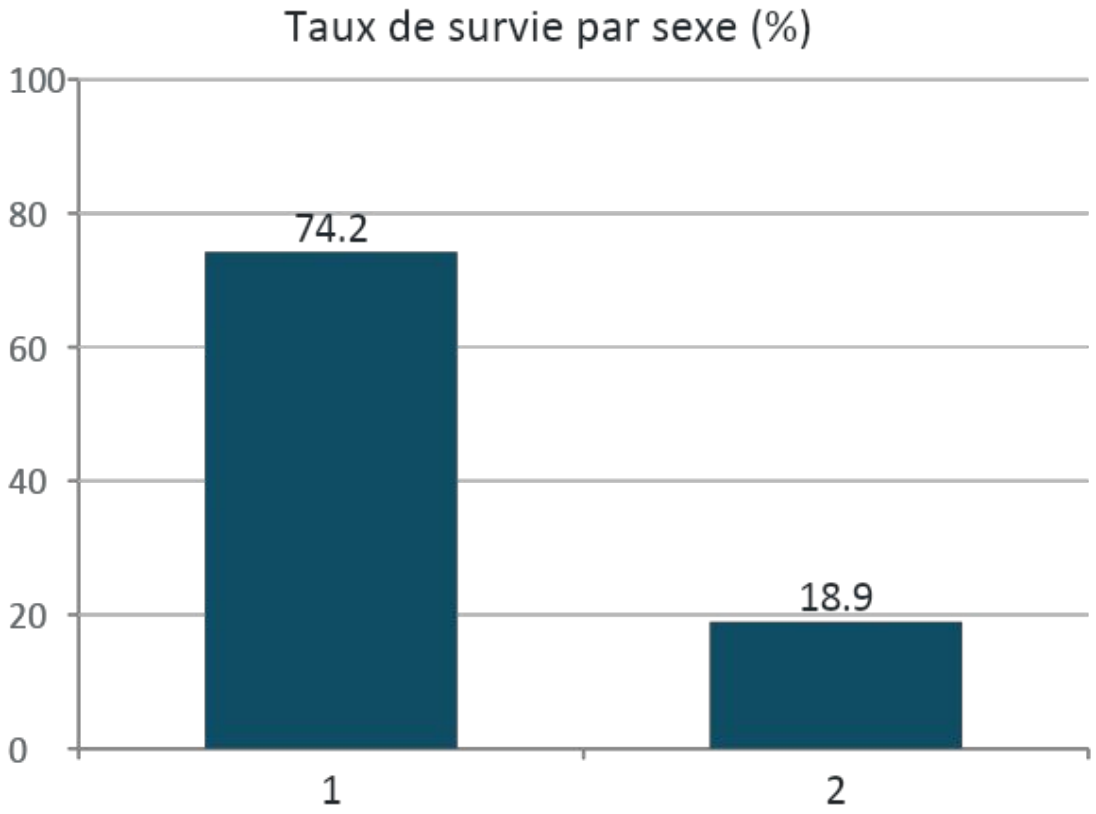
Corrélation ≠ causalité

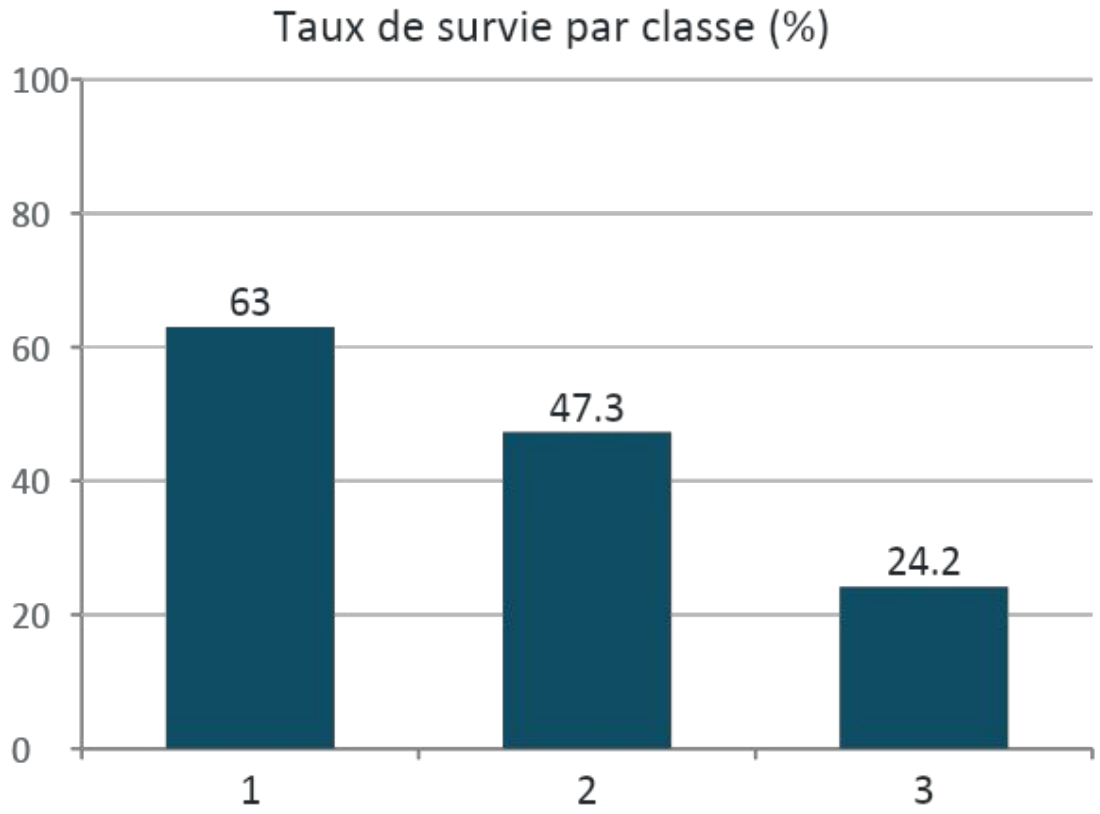
Deux variables peuvent varier ensemble parce qu'un troisième facteur agit sur les deux, ou par coïncidence.

Les résultats d'EDA sont des hypothèses à tester, pas des conclusions.

Avant de croire une corrélation, tracer les données : un nuage de points révèle des courbes que r ne voit pas

EDA sur le Titanic : la survie diffère fortement selon le sexe et la classe





Survie globale : 38,4 % (342 / 891). Ces écarts sont un vrai signal dans ce jeu — et une question d'équité pour un chapitre ultérieur

Discutez : payer plus cher cause-t-il la survie ?

r de Pearson avec survived

Variable	r
fare	0,26
parch	0,08
age	−0,08
sibsp	−0,04

Binômes · 2 min

fare a la plus forte corrélation avec la survie parmi ces variables numériques.

Peut-on conclure qu'un billet plus cher a causé la survie ? Qu'est-ce qui pourrait expliquer cette corrélation ?

Prix médian par classe : 1re 60,29 · 2e 14,25 · 3e 8,05

PARTIE 4

Éviter la fuite de données

La règle qui garde honnêtes tous les chiffres de ce chapitre

Fuite de données : une information indisponible en prédiction s'infiltre dans l'apprentissage

- Définition : toute information indisponible au moment de la prédiction — surtout les statistiques du test — qui influence l'apprentissage
- Effet : l'évaluation devient trop optimiste
- Trois formes fréquentes :
  - des lignes de test servent à calculer une statistique de prétraitement
  - une variable contient la cible de façon déguisée
  - des choix de modélisation faits en regardant le test

Conséquence

Un excellent score de test…

…puis des résultats décevants en production — parce que le test n'était pas une répétition honnête.

Sur le Titanic, inclure les lignes de test change la valeur de remplacement de l'âge

29,0

âge médian calculé sur l'apprentissage

28,0

âge médian calculé sur les 891 lignes (apprentissage + test)

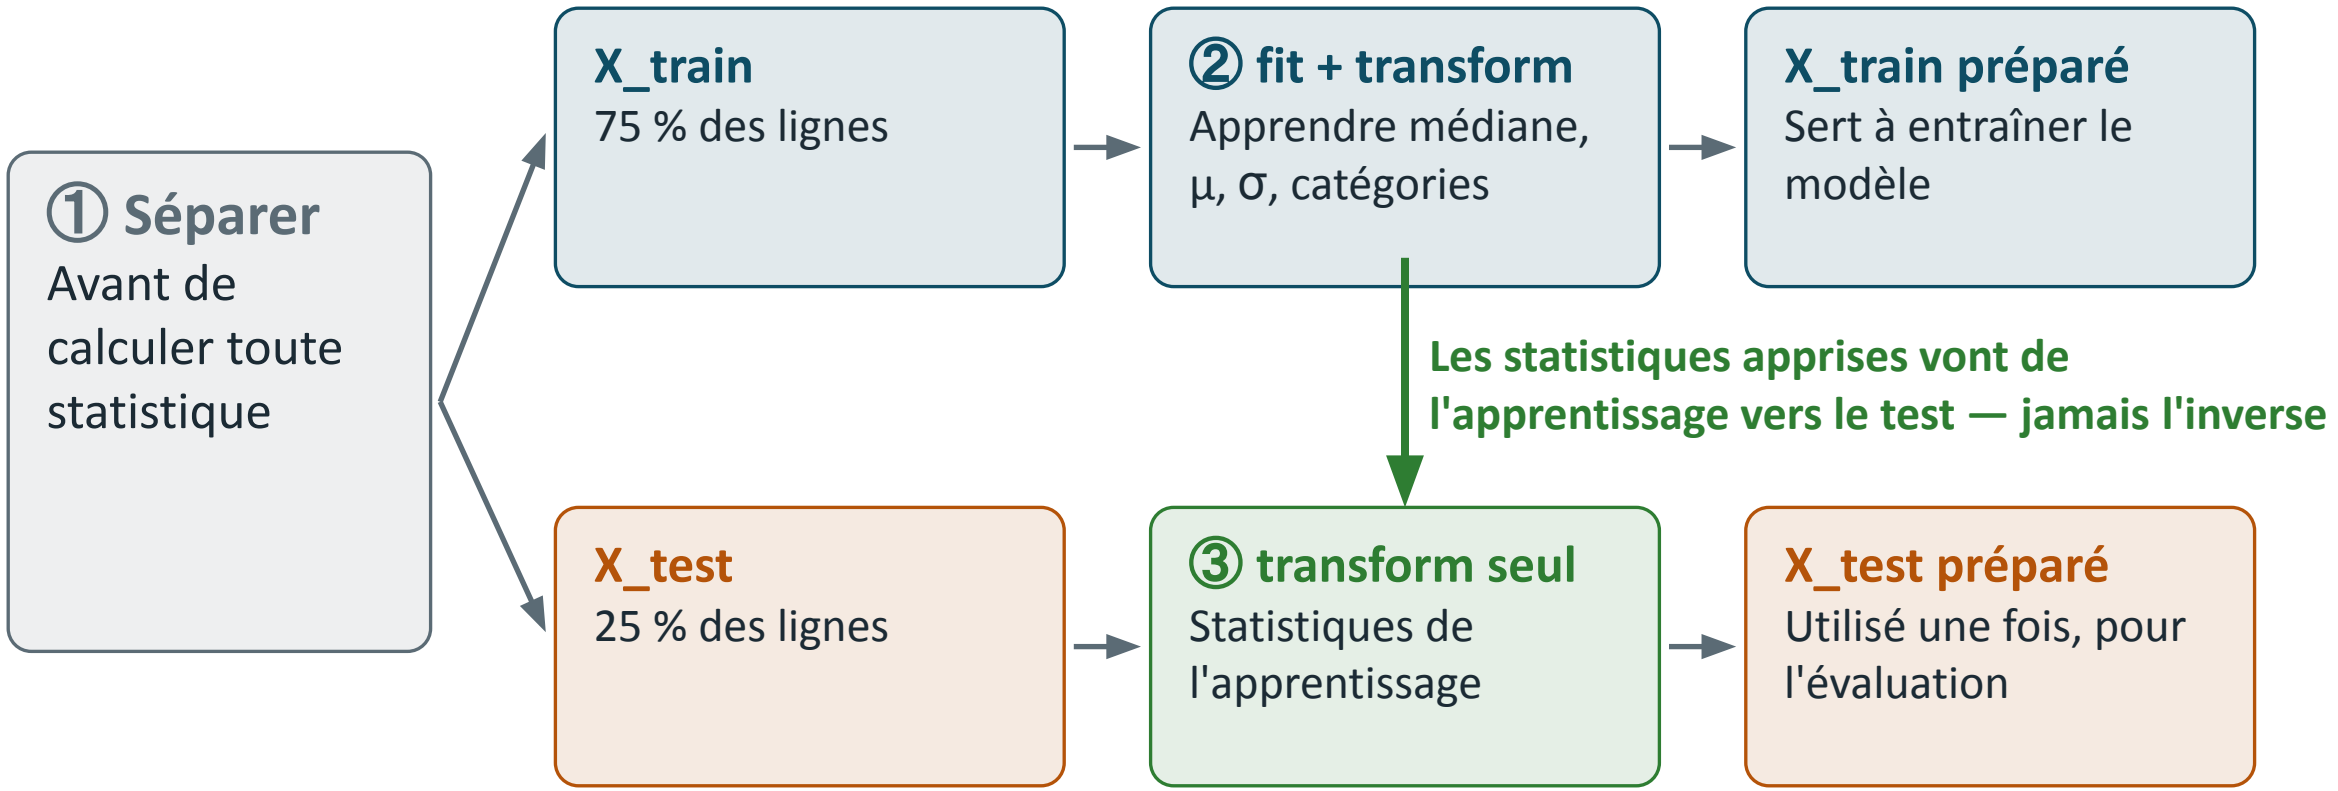
Cadre

Séparation du chapitre : 75 / 25, stratifiée sur survived, random_state = 42 (exécuté)

Signification

Petit écart ici, mais les lignes de test ont bien influencé une valeur apprise. Il en va de même pour toute statistique ajustée : moyennes, σ, catégories.

L'ordre sans fuite : séparer d'abord, ajuster sur l'apprentissage, transformer les deux



Le test n'influence jamais une statistique ajustée : c'est exactement ce qu'imposent fit_transform(X_train) puis transform(X_test)

Trouvez le bug : ce code paraît correct mais fuit

ACTIVITÉ · 2 min · binômes

Trouvez la ligne qui fuit et expliquez la conséquence.

```
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.25, random_state=42)
```

Levez la main quand votre binôme a trouvé le numéro de ligne (1–7).

Correction : séparer d'abord, puis ajuster le scaler sur l'apprentissage seulement

```
# BUG (ligne 5) : fit_transform(X) a vu
# toutes les lignes : μ et σ contiennent le test.

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42)
scaler = StandardScaler()
# ajuster sur l'apprentissage seulement
X_train_s = scaler.fit_transform(X_train)
# seulement transformer le test
X_test_s = scaler.transform(X_test)
```

Au lab

Pipeline et ColumnTransformer regroupent imputation, encodage et mise à l'échelle dans un seul objet ajusté : le bon ordre devient le défaut.

Traitement complet : chapitre 12.

La fuite se cache aussi dans les variables et dans les habitudes

Cible déguisée

Le fichier Titanic de seaborn contient une colonne alive (yes/no).

Elle est identique à survived sur les 891 lignes (vérifié) → à supprimer avant l'apprentissage.

Regarder le test

Explorer le jeu de test et laisser ce qu'on y voit orienter ses choix est aussi une fuite.

Faire l'EDA sur l'apprentissage.

Écart entraînement–production

La production doit appliquer le même prétraitement ajusté.

Sauvegarder le préprocesseur ajusté avec le modèle ; valider les entrées (catégories inconnues, plages).

Pour chaque variable et chaque statistique : la connaîtrais-je au moment de prédire, à partir de l'apprentissage seulement ?

Évaluation finale : quatre questions

ÉVALUATION · 4 min · individuel

Q1. Vous ajustez StandardScaler sur tout le jeu, puis séparez. Conséquence ?

A · Le score de test peut être trop optimiste

B · Le modèle ne peut pas s'entraîner

C · Rien ne change

Q2. Meilleur encodage de embarked (C / Q / S) pour un modèle linéaire ?

A · Codes ordinaux 0 / 1 / 2

B · One-hot

C · Supprimer la colonne

Q3. Le r de Pearson entre deux variables vaut 0,02. On peut conclure…

A · qu'elles sont sans lien

B · qu'il n'y a pas de relation linéaire ; une non linéaire est possible

C · que l'une ne cause pas l'autre

Q4. Que faut-il calculer sur l'apprentissage seulement ?

A · La médiane utilisée pour l'imputation

B · La moyenne et le σ du scaler

C · A et B

Montrez 1, 2 ou 3 doigts pour A, B ou C, question par question, au compte de 3.

Correction de l'évaluation finale

Q	Réponse	Pourquoi
1	A	μ et σ du scaler ont utilisé les lignes de test : fuite, évaluation optimiste
2	B	embarked est nominale : des codes ordinaux inventeraient un ordre
3	B	r ne mesure que l'association linéaire (rappel : $y = x^2$, $r = 0$)
4	C	Toute statistique ajustée s'apprend sur l'apprentissage, puis s'applique au test

Ce qu'il faut retenir du chapitre 2

- Séparer d'abord, ajuster sur l'apprentissage, transformer les deux — pour toute statistique apprise
- One-hot pour les nominales ; codes ordinaux seulement pour un ordre réel
- Mettre à l'échelle pour les modèles à distances ou gradients ; log ou échelle robuste si les aberrantes dominent
- r de Pearson : association linéaire seulement, jamais une preuve de causalité
- La fuite se cache aussi dans les variables (alive) et les habitudes (regarder le test)

Ensuite : le lab

- Auditer et préparer le vrai fichier Titanic avec pandas
- Construire le pipeline ColumnTransformer
- Mesurer l'écart dû à la fuite (exercice avancé 1)

Références et données utilisées dans ce chapitre

- Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. ACM Transactions on Knowledge Discovery from Data. doi:10.1145/2382577.2382579
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An Introduction to Statistical Learning with Applications in Python. Springer. doi:10.1007/978-3-031-38747-0
- McKinney, W. (2022). Python for Data Analysis (3e éd.). O'Reilly. Édition web en libre accès : wesmckinney.com/book
- Géron, A. Hands-On Machine Learning with Scikit-Learn and PyTorch. O'Reilly (édition 2025 — confirmer l'année de l'exemplaire cité)
- Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley
- Données : titanic.csv du dépôt seaborn-data (github.com/mwaskom/seaborn-data), 891 lignes × 15 colonnes

Chiffres recalculés en exécutant Python (NumPy 2.5.3, pandas 3.0.5, scikit-learn 1.9.1). Les exemples synthétiques sont signalés comme tels.