Institut Supérieur d'Informatique et de Mathématiques de Monastir

Devoir Surveillé — Machine Learning

Licence 3 – Génie Logiciel

Dr. OMHENI Nizar

Durée : 1 heure

Instructions

— Cet examen comporte **10 questions de réflexion** (questions ouvertes).
— Répondez de manière **structurée et justifiée** en vous appuyant sur les concepts du cours.
— **Clarté et logique** sont essentielles — la longueur n'est pas le critère principal.
— **Utilisez des exemples concrets** pour illustrer vos réponses.
— Vous pouvez répondre soit en français ou en anglais.
— Aucun document n'est autorisé.

Question 1 (2 points) :

Expliquez pourquoi la définition d'Arthur Samuel du Machine Learning (*"donner aux ordinateurs la capacité d'apprendre sans être explicitement programmés"*) est plus pertinente qu'une approche basée uniquement sur des règles (if-then-else) pour résoudre un problème complexe comme la détection d'objets dans une image.

Question 2 (2 points) :

Vous travaillez sur un projet de prédiction de prix immobilier. Votre collègue a d'abord appliqué StandardScaler sur l'ensemble du dataset, puis effectué un split train/test 80/20. Identifiez le problème et expliquez ses conséquences sur les performances du modèle.

Question 3 (2.5 points) :

Un dataset contient 3 variables avec des valeurs manquantes :
— Variable A : 3% de manquant
— Variable B : 25% de manquant
— Variable C : 60% de manquant
Proposez une stratégie différente pour chacune, en justifiant votre choix selon le contexte métier et les types de données.

Question 4 (2.5 points) :

Dans un dataset de salaires d'employés, vous détectez avec la méthode IQR un outlier : un CEO gagnant 2 millions d'euros par an (alors que la médiane est 50 000€). Faut-il supprimer cet outlier ? Justifiez en expliquant pourquoi le contexte métier change la décision par rapport à une approche statistique pure.

Question 5 (2.5 points) :

Un modèle de régression linéaire prédisant le prix d'une voiture à partir de l'âge et du kilométrage obtient un $R^2 = 0.45$ sur le test set. Proposez au moins 2 techniques de feature engineering pour améliorer ce modèle, en expliquant le mécanisme par lequel elles capturent de la non-linéarité.

Question 6 (2.5 points) :

Comparez les trois techniques de binning (Equal-width, Equal-frequency, Custom/Expert-based) en termes de :

— Avantages et inconvénients
— Contexte d'utilisation optimal
— Impact sur le modèle et l'interprétabilité

Donnez un exemple concret d'application pour chacune.

Question 7 (2.5 points) :

Vous devez classer automatiquement des avis clients (positifs/négatifs) pour un restaurant. Expliquez pourquoi utiliser des bigrams + TF-IDF est supérieur à un modèle basé uniquement sur les unigrams (mots individuels). Donnez un exemple concret où les bigrams capturent une nuance que les unigrams manqueraient.

Question 8 (3.5 points) :

Vous êtes data scientist chez une banque. Votre mission : créer un modèle de scoring de crédit (prédire si un client remboursera son crédit : oui/non) en utilisant 500 variables d'un CRM complexe.

Décrivez votre approche complète du pipeline ML, depuis le preprocessing jusqu'à la sélection finale des features, en intégrant les concepts du cours. Pour chaque étape, justifiez vos choix.

Conseils pour bien répondre aux questions :

1. **Structurez vos réponses** : Introduction → Développement → Conclusion
2. **Justifiez toujours** : "Pourquoi ?" est plus important que "Quoi ?"
3. **Donnez des exemples** : Concret > Théorique
4. **Considérez le contexte métier** : Les données n'existent pas dans le vide
5. **Montrez votre réflexion** : Même une réponse partiellement correcte avec bon raisonnement est valorisée