Institut Supérieur d'Informatique et de Mathématiques de Monastir Université de Monastir			
Épreuve	Devoir surveillé (DS)	**Module**	Machine Learning
Niveau / filière	3e année Licence — Génie Logiciel	**Responsable**	Dr. Nizar Omheni
Année universitaire	2026–2027	**Durée**	1 h
Note maximale	20 points	**Pages**	9 pages
Date	12 / 11 / 2026		

Consignes

- Documents, calculatrice, téléphone et tout appareil électronique **interdits**. Les calculs sont conçus pour être faits à la main ; une racine carrée peut rester sous la forme $\sqrt{a}$.
- L'épreuve comporte **40 questions à choix multiple**. Pour chaque question, **une seule** proposition parmi A, B, C, D est correcte dans les conditions de l'énoncé.
- Barème : bonne réponse = 0,5 point ; réponse fausse, absente ou plusieurs réponses sélectionnées = 0 point. Aucune pénalité. Total : $40 \times 0{,}5 = 20$ points.
- Sauf mention contraire, « écart-type de population » signifie division par n.

Partie I — Introduction au machine learning (questions 1 à 15)

Q1. Un service de streaming veut recommander des films. Selon la définition de Mitchell (tâche T, performance P, expérience E), que représente **E** ?

A. L'historique des notes que les utilisateurs ont déjà données aux films

B. La proportion de films recommandés qui sont effectivement regardés

C. L'ensemble des fonctions candidates parcourues par l'algorithme

D. Recommander à chaque utilisateur des films susceptibles de lui plaire

Q2. Quelle affirmation sur les relations entre IA, machine learning (ML) et deep learning (DL) est correcte ?

A. Tout système d'IA apprend son comportement à partir de données

B. Tout modèle de DL relève du ML, et un système expert à règles écrites à la main relève de l'IA sans relever du ML

C. Un arbre de décision appris sur des données relève du DL

D. Le ML est un sous-ensemble du DL

Q3. Lequel de ces scénarios relève de l'apprentissage **semi-supervisé** ?

A. Prédire le prix d'un appartement à partir de 5 000 ventes dont le prix est connu

B. Regrouper des clients en segments sans aucune étiquette

C. Un agent apprend à jouer en recevant une récompense à chaque partie gagnée

D. Entraîner un classifieur avec 1 000 radiographies annotées par des médecins et 100 000 radiographies non annotées

Q4. Lequel de ces problèmes est une tâche de **régression** ?

A. Prédire le nombre de minutes de retard d'un vol

B. Prédire si un vol aura plus de 15 minutes de retard (oui / non)

C. Prédire la compagnie aérienne d'un vol à partir de ses caractéristiques

D. Regrouper les vols en profils similaires sans étiquette

Q5. En apprentissage supervisé, l'**espace des hypothèses** $\mathcal{H}$ (hypothesis space) désigne :

A. L'ensemble des couples (x_i, y_i) disponibles pour l'apprentissage

B. La valeur y_i que l'on cherche à prédire

C. L'ensemble des fonctions candidates parmi lesquelles l'algorithme cherche f_θ

D. La mesure de l'écart entre une prédiction et la vraie valeur

Q6. Un modèle de régression prédit $\hat{y} = (4, 5, 0, 6)$ pour des valeurs réelles $y = (3, 5, 2, 6)$ sur les 4 exemples d'apprentissage. Avec la perte quadratique, le **risque empirique** (perte moyenne) vaut :

A. 0,75

B. 1,25

C. 1,67

D. 5

Q7. Pourquoi estime-t-on le **risque espéré** (true risk) d'un modèle sur un jeu de test ?

A. Il porte sur toute la distribution $\mathcal{P}$ et ne peut pas être calculé ; des données jamais vues à l'apprentissage en donnent une estimation honnête

B. Parce que l'entraînement consiste à minimiser l'erreur sur le jeu de test

C. Parce que le risque empirique est toujours supérieur au risque espéré

D. Parce que le jeu de test contient plus d'exemples que le jeu d'apprentissage

Q8. Dans la séparation apprentissage / validation / test, quel est le rôle du jeu de **validation** ?

A. Comparer des choix de modélisation (p. ex. la valeur de k d'un k-NN) pour fixer les hyperparamètres

B. Apprendre les paramètres θ du modèle

C. Fournir le score final honnête rapporté à la fin du projet

D. Remplacer le jeu de test lorsque celui-ci est trop petit

Q9. Un modèle obtient une exactitude de 0,99 sur l'apprentissage et de 0,71 sur le test. Quel est le diagnostic le plus probable ?

A. Bonne généralisation : 0,71 reste un score élevé

B. Le jeu de test a forcément été utilisé pendant l'entraînement

C. Surapprentissage : le modèle a mémorisé l'apprentissage et généralise mal

D. Sous-apprentissage : le modèle est trop simple

Q10. Sur un problème à deux classes équilibrées, un modèle obtient 0,52 en apprentissage et 0,50 en test. Quel est le diagnostic le plus probable ?

A. Bonne généralisation, puisque les deux scores sont proches

B. Surapprentissage : l'écart entre apprentissage et test est trop grand

C. Sous-apprentissage : le modèle fait à peine mieux que le baseline de classe majoritaire (≈ 0,50)

D. Fuite de données entre apprentissage et test

Q11. La classe majoritaire du jeu d'apprentissage est A. Le jeu de test contient 200 exemples : 130 de classe A, 50 de classe B et 20 de classe C. Quelle est l'exactitude de test du baseline de classe majoritaire ?

A. 0,25

B. 0,33

C. 0,35

D. 0,65

Q12. Dans un jeu de transactions, 2 % sont frauduleuses. Un modèle prédit « non frauduleuse » pour toutes les transactions. Que vaut son exactitude et que faut-il en conclure ?

A. 98 % ; le modèle est excellent et peut être déployé

B. 50 % ; un modèle constant obtient toujours 50 % sur deux classes

C. 98 % ; il ne détecte aucune fraude : l'exactitude est trompeuse sur des classes déséquilibrées

D. 2 % ; le modèle fait pire que le hasard

Q13. Un filtre anti-spam entraîné en 2022 voit ses performances chuter en 2026 alors que son code n'a pas changé : les spammeurs ont modifié leurs messages. Quelle hypothèse est la plus directement violée ?

- **A.** La séparation disjointe des jeux d'apprentissage et de test
- **B.** La stationnarité : la distribution $\mathcal{P}$ reste à peu près stable pendant l'utilisation du modèle
- **C.** La reproductibilité obtenue en fixant random_state
- **D.** L'existence d'un baseline de référence

Q14. Pourquoi passe-t-on `random_state=42` à `train_test_split` ?

- **A.** Pour réserver 42 % des données au test
- **B.** Pour obtenir la même séparation, donc un résultat reproductible, à chaque exécution
- **C.** Pour améliorer l'exactitude du modèle
- **D.** Pour garantir que les proportions de classes sont identiques dans les deux jeux

Q15. Après `dummy = DummyClassifier(strategy="most_frequent").fit(X_tr, y_tr)`, que renvoie `dummy.score(X_te, y_te)` ?

- **A.** Le nombre d'exemples de test appartenant à la classe majoritaire
- **B.** L'exactitude obtenue en prédisant la classe la plus fréquente de y_te
- **C.** L'exactitude obtenue en prédisant, pour chaque ligne de test, la classe la plus fréquente de y_tr
- **D.** L'exactitude du baseline sur les données d'apprentissage

Partie II — Types de données, statistiques descriptives, valeurs manquantes et aberrantes (questions 16 à 28)

Q16. Laquelle de ces variables est **catégorielle ordinale** ?

- **A.** La nationalité
- **B.** Le nombre d'enfants
- **C.** La mention au baccalauréat (passable < assez bien < bien < très bien)
- **D.** La taille en centimètres

Q17. Un jeu de données contient le **code postal** des clients (p. ex. 5000, 5019, 1002). De quel type de variable s'agit-il ?

- **A.** Catégorielle nominale
- **B.** Numérique discrète
- **C.** Numérique continue
- **D.** Catégorielle ordinale

Q18. Pour x = (3, 5, 7, 9, 11), quel est l'**écart-type de population** σ (division par n) ?

A. 2,4

B. √8

C. √10

D. 8

Q19. Pour x = (2, 4, 6, 8), quelle valeur renvoie `pd.Series(x).std()` avec les paramètres par défaut ?

A. √5

B. √(20/3)

C. 5

D. 20/3

Q20. Pourquoi la formule de l'écart-type d'échantillon divise-t-elle par n − 1 plutôt que par n ?

A. Pour que les écarts à la moyenne somment à zéro

B. Parce que la plus grande valeur est exclue du calcul

C. Pour que l'écart-type soit toujours un nombre entier

D. Parce que la moyenne est estimée sur le même échantillon, ce qui fait sous-estimer la variance si l'on divise par n

Q21. Une colonne catégorielle « ancien_employeur » est vide sur 85 % des lignes ; les autres colonnes sont presque complètes. Quelle décision est la plus défendable ?

A. Imputer par la moyenne de la colonne

B. Supprimer la colonne, ou tester une catégorie explicite « Missing »

C. Supprimer toutes les lignes où elle manque

D. Imputer par la catégorie la plus fréquente

Q22. Dans une colonne de prix (en dinars), une valeur manque ; les six valeurs connues sont 6, 7, 7, 9, 11, 300. Quelle valeur de remplacement est la plus appropriée ?

A. La médiane, soit 8

B. Le mode, soit 7

C. La médiane, soit 7

D. La moyenne, soit environ 56,7

Q23. Pourquoi peut-on ajouter une colonne indicatrice `age_was_missing` (0 / 1) en imputant l'âge ?

A. Parce que le fait même qu'une valeur manque peut porter une information utile au modèle

B. Pour pouvoir supprimer ensuite les lignes imputées

C. Pour que la médiane d'imputation soit calculée sur tout le jeu de données

D. Parce que scikit-learn refuse une colonne imputée sans indicateur

Q24. Une colonne a Q1 = 20 et Q3 = 32. Selon la règle IQR (barrières à 1,5 × IQR), laquelle de ces valeurs est signalée comme aberrante ?

A. 3

B. 45

C. 49

D. 51

Q25. Pourquoi la règle du z-score ($|z| > 3$) peut-elle ne pas signaler une valeur très extrême ?

A. Parce que le z-score est calculé à partir des quartiles

B. Parce que la limite 3 est une loi mathématique qui ne tolère aucune exception

C. Parce que le z-score ne s'applique qu'aux variables catégorielles

D. Parce que la valeur extrême gonfle elle-même σ, ce qui réduit son propre z-score

Q26. Une variable a une moyenne de 50 et un écart-type de 4. Pour la valeur x = 64, quel est le z-score et la valeur est-elle signalée par la règle $|z| > 3$?

A. $z = 3{,}5$; signalée

B. $z \approx 0{,}29$; non signalée

C. $z = 14$; signalée

D. $z = 3{,}5$; non signalée

Q27. Dans un jeu de réservations d'hôtel, un séjour à 9 000 DT est signalé par la règle IQR. Après vérification, il s'agit d'une suite présidentielle réellement réservée par un client du même type que les autres. Quelle est l'action la plus appropriée ?

A. Supprimer la colonne des prix

B. Remplacer la valeur par la moyenne de la colonne

C. Supprimer la ligne, puisque toute valeur signalée est une erreur

D. Garder la ligne, éventuellement la plafonner ou utiliser des outils robustes, et documenter la décision

Q28. Une colonne de montants est positive, très asymétrique à droite, et contient des zéros. Quelle transformation permet de réduire l'asymétrie ?

A. x^2

B. $\log(1 + x)$

C. $\log(x)$

D. La normalisation min–max

Partie III — Encodage, mise à l'échelle, corrélation et fuite de données (questions 29 à 40)

Q29. Une variable nominale « moyen_paiement » prend 4 valeurs : carte, espèces, chèque, mobile. Après un encodage **one-hot**, on obtient :

A. 4 colonnes binaires, avec exactement un 1 par ligne

B. 2 colonnes contenant le code binaire de 0 à 3

C. 1 colonne contenant les codes 0, 1, 2, 3

D. 3 colonnes, avec deux 1 par ligne

Q30. On encode « ville » □ {Tunis, Sousse, Sfax} par 0, 1, 2 avant une régression linéaire. Quel est le problème ?

A. Trois catégories produiraient trop de colonnes

B. Le modèle ne peut pas s'entraîner sur des entiers

C. Aucun problème : une régression linéaire accepte n'importe quel entier

D. Le modèle suppose que Sousse est « entre » Tunis et Sfax et que Sfax − Tunis = 2 × (Sousse − Tunis), ce qui n'a pas de sens

Q31. Une variable « identifiant_produit » compte 12 000 valeurs distinctes. Quelle stratégie d'encodage est la plus appropriée ?

A. Ni one-hot ni ordinal directement : regrouper les catégories rares ou utiliser une autre stratégie

B. Un one-hot à 12 000 colonnes

C. Un encodage ordinal de 0 à 11 999

D. Standardiser directement l'identifiant

Q32. Un MinMaxScaler ajusté sur l'apprentissage a trouvé $x_{min} = 10$ et $x_{max} = 60$. Quelle valeur transformée obtient une valeur de test $x = 70$?

A. 0,86

B. 1

C. 1,2

D. 1,4

Q33. Sur l'apprentissage, une variable « taille » a $\mu = 170$ cm et $\sigma = 10$ cm. Quel z-score la standardisation donne-t-elle à un individu de test mesurant 185 cm ?

A. −1,5

B. 0,15

C. 1,5

D. 15

Q34. Pour lequel de ces modèles une mise à l'échelle monotone des variables numériques ne change-t-elle pas les coupes possibles ?

A. Les k plus proches voisins (kNN)

B. Un SVM

C. k-means

D. Un arbre de décision

Q35. Trois individus sont décrits par (âge, score) : A = (20 ans, 100), B = (30 ans, 100), C = (20 ans, 112). Avec la distance euclidienne sans mise à l'échelle, quel est le plus proche voisin de A lorsque l'âge est exprimé en années, puis lorsqu'il est exprimé en mois ?

A. C, puis C

B. B, puis B

C. B, puis C

D. C, puis B

Q36. Pour x = (1, 2, 3) et y = (1, 3, 2), quel est le coefficient de corrélation de Pearson r ? (Utiliser des formules cohérentes, toutes en 1/n.)

A. 0,33

B. 0,5

C. 0,75

D. 1

Q37. Sur des données mensuelles fictives, on mesure r = 0,8 entre les ventes de glaces et le nombre de noyades. Quelle conclusion est la plus correcte ?

A. Vendre des glaces provoque des noyades

B. Il existe une association linéaire positive forte ; un troisième facteur (p. ex. la chaleur) peut expliquer les deux — c'est une hypothèse à tester

C. 80 % des noyades sont expliquées par la vente de glaces

D. Il n'y a pas de relation, puisque r est inférieur à 1

Q38. Quel enchaînement permet de standardiser les données sans fuite et de façon cohérente entre apprentissage et test ?

- **A.** train_test_split ; puis scaler.fit_transform(X_train) ; puis scaler.fit_transform(X_test)
- **B.** scaler.fit_transform(X) ; puis train_test_split
- **C.** train_test_split ; puis scaler.fit(X_test) ; puis transformer les deux jeux
- **D.** train_test_split ; puis scaler.fit_transform(X_train) ; puis scaler.transform(X_test)

Q39. Une équipe calcule, sur l'ensemble des données, la médiane d'imputation de l'âge puis la moyenne et l'écart-type d'un StandardScaler, et sépare apprentissage et test seulement ensuite. Laquelle de ces étapes constitue une fuite de données ?

- **A.** Seulement l'imputation, car la standardisation ne change pas l'ordre des valeurs
- **B.** Seulement le scaler, car la médiane est robuste aux extrêmes
- **C.** Les deux : toute statistique ajustée doit être apprise sur l'apprentissage seulement
- **D.** Aucune des deux, car ces statistiques n'utilisent pas la cible

Q40. Pour prédire si un client va résilier son abonnement, un jeu de données contient la variable « date_de_resiliation » (vide pour les clients restés actifs). Que faut-il en faire ?

- **A.** Imputer les dates manquantes par la médiane
- **B.** L'encoder en one-hot avant l'apprentissage
- **C.** La garder, car elle sera sans doute la variable la plus corrélée à la cible
- **D.** La supprimer : elle contient la cible de façon déguisée et n'est pas connue au moment de prédire