Question 13

En régression linéaire, un objectif fréquent est la minimisation de la MSE (Mean Squared Error). Minimiser cette fonction consiste à :

A. Maximiser la corrélation entre les features

B. Minimiser la somme des écarts absolus $|f(x_i) - y_i|$

C. Minimiser la moyenne des carrés des écarts $\sum_i (f(x_i) - y_i)^2/n$ sur le dataset

D. Maximiser la variance des prédictions

Question 14

Pourquoi la MSE pénalise-t-elle plus fortement les erreurs importantes que l'erreur absolue moyenne ?

A. Parce qu'elle utilise la valeur absolue

B. Parce qu'elle élève les erreurs au carré

C. Parce qu'elle ignore les outliers

D. Parce qu'elle est calculée uniquement sur le test set

Question 15

L'optimiseur dans un algorithme supervisé a pour rôle principal :

A. Choisir la structure du modèle automatiquement

B. Définir la fonction de perte

C. Chercher les paramètres qui minimisent l'objectif choisi

D. Normaliser les données d'entrée

Question 16

Considérons un modèle linéaire entraîné sur un dataset de patients (BMI → risque de diabète) qui généralise mal sur de nouveaux patients. Une cause probable est :

A. Le modèle est trop expressif et sur-apprend les patterns

B. Les données d'entraînement et de test suivent des distributions différentes

C. La MSE est toujours nulle sur le training set

D. Le modèle n'a pas de paramètres

Question 17

On veut évaluer la qualité d'un modèle sur de nouvelles données. Quelle pratique respecte la « règle d'or » concernant le test set ?

A. Utiliser le test set pour tuner les hyperparamètres, puis rapporter la performance dessus

B. Fusionner training et test, puis découper à nouveau après préprocessing

C. Garder le test set de côté, ne l'utiliser qu'une fois pour l'évaluation finale

D. Utiliser le test set pour choisir les features, puis le réutiliser pour mesurer la performance

EXAMEN – Machine Learning

40 Questions à Choix Multiple

Durée : 1h30

Dr. OM HENI Nizar–ISIMM

Génie Logiciel – 3ème Année

22 décembre 2025

Instructions :

- Répondez sur la feuille d'examen fournie en indiquant le numéro de la question et la lettre de votre réponse (A, B, C ou D).
- Pour chaque question, une seule réponse est correcte.
- Lisez attentivement les énoncés. Une bonne compréhension est essentielle.

Question 1

Dans un système de filtrage de spam, on dispose d'un historique d'e-mails étiquetés « spam » ou « non spam ». Quel cadre d'apprentissage décrit le mieux ce problème ?

A. Non supervisé

B. Supervisé – classification

C. Supervisé – régression

D. Renforcement

Question 2

On veut estimer le prix d'un appartement à partir de sa surface, de sa localisation et de son âge. Le type de tâche est :

A. Classification binaire

B. Régression supervisée

C. Clustering

D. Apprentissage par renforcement

Question 3

Dans un algorithme de clustering appliqué à des données clients sans labels, le but principal est :

A. Minimiser l'erreur entre prédiction et label

B. Maximiser la probabilité des actions récompensées

C. Découvrir une structure ou des groupes dans les données

D. Apprendre une politique optimale

Question 4

Un système de recommandation qui apprend en continu à partir des nouvelles interactions utilisateurs (flux de données) illustre le mieux :

A. Apprentissage batch (hors ligne)

B. Apprentissage en ligne (online learning)

C. Apprentissage semi-supervisé

D. Apprentissage non supervisé

Question 5

On dispose d'un très grand volume de données de streaming en temps réel. Pourquoi un algorithme de type batch learning peut-il être problématique ?

A. Il est toujours moins précis qu'un modèle en ligne

B. Il ne peut pas être entraîné plusieurs fois

C. Il nécessite de tout réentraîner à partir de zéro pour intégrer les nouvelles données

D. Il ne supporte pas les données numériques

Question 6

Dans un système d'instance-based learning (type k-NN), la généralisation se fait principalement :

A. Par apprentissage d'un modèle explicite durant l'entraînement

B. En mémorisant les exemples et en comparant chaque nouvelle instance aux exemples stockés

C. En optimisant explicitement une fonction de coût analytique

D. En explorant un environnement et recevant des récompenses

Question 7

Quel énoncé décrit correctement un système de model-based learning ?

A. Il ne stocke aucun exemple d'entraînement

B. Il stocke tous les exemples et ne construit pas de modèle explicite

C. Il construit un modèle paramétré à partir des données pour faire des prédictions

D. Il ne peut pas être utilisé pour la régression

Question 8

Dans un contexte de semi-supervised learning appliqué à la reconnaissance de visages dans des photos, le rôle typique de l'utilisateur (humain) est :

A. Annoter exhaustivement toutes les images

B. Ne fournir aucun label, tout est découvert automatiquement

C. Fournir quelques labels par personne pour aider à nommer des clusters découverts automatiquement

D. Choisir les hyperparamètres sans jamais regarder les données

Question 9

Un agent d'apprentissage par renforcement qui apprend à jouer à un jeu vidéo reçoit à chaque épisode :

A. Une matrice de confusion

B. Un ensemble de labels corrects

C. Un flux de récompenses positives ou négatives

D. Une partition en clusters prédéfinis

Question 10

Lorsqu'on évalue un système de machine learning, pourquoi insiste-t-on sur la « généralisation » ?

A. Parce qu'on veut surtout minimiser le temps d'entraînement

B. Parce qu'on veut maximiser la taille du modèle

C. Parce qu'on veut de bonnes performances sur des données jamais vues

D. Parce que les performances sur le training set suffisent à juger le modèle

Question 11

Dans le cadre du dataset $D = \{(x_i, y_i)\}_{i=1}^{n}$, quelle interprétation est correcte ?

A. Chaque x_i est un label et chaque y_i un vecteur de caractéristiques

B. Chaque (x_i, y_i) est un exemple d'entraînement composé d'un input et d'une cible

C. $\{x_i\}$ est le jeu de test et $\{y_i\}$ le jeu de validation

D. D ne contient que des inputs

Question 12

La matrice de caractéristiques $X \in \mathbb{R}^{n \times d}$ d'un problème supervisé contient :

A. n observations et d features par observation

B. d observations et n features par observation

C. Un vecteur de labels et un vecteur de prédictions

D. Un vecteur de paramètres du modèle

Question 33

Le principal inconvénient de K-Means, même après une bonne normalisation, est :

A. Il ne converge jamais

B. Il suppose des clusters plutôt sphériques et dépend d'une initialisation qui peut conduire à des minima locaux

C. Il ne peut pas être utilisé au-delà de 100 points

D. Il détecte automatiquement le bon nombre de clusters

Question 34

Le clustering hiérarchique offre un avantage spécifique par rapport à K-Means :

A. Il est plus rapide sur de très grands jeux de données

B. Il produit un dendrogramme qui visualise la hiérarchie complète des clusters

C. Il ne nécessite pas de mesure de distance

D. Il est insensible aux choix d'hyperparamètres

Question 35

DBSCAN est particulièrement adapté lorsque :

A. On connaît précisément le nombre de clusters

B. Les clusters ont des formes très variées et on souhaite identifier explicitement les points aberrants

C. Les données sont parfaitement linéaires

D. On veut absolument des clusters de tailles identiques

Question 36

Par rapport à K-Means, un modèle de type Gaussian Mixture (GMM) se distingue principalement par :

A. Une assignation « dure » (hard) de chaque point à un seul cluster

B. Une assignation probabiliste (« soft ») de chaque point aux différents clusters

C. L'absence totale de paramètres

D. Le fait qu'il ne nécessite jamais de normalisation

Question 37

Dans PCA, que signifie dire que la première composante principale explique, par exemple, 45 % de la variance ?

A. Que 45 % des points sont projetés sur cette composante

B. Qu'en moyenne, 45 % des features sont supprimées

C. Que cette direction explique 45 % de la variabilité totale des données

D. Qu'il reste 45 % de dimensions après la réduction

Question 18

Pour un problème de classification binaire fortement déséquilibré (classe positive très rare), quelle pratique est la plus adaptée ?

A. Utiliser uniquement l'accuracy pour évaluer le modèle

B. Ignorer les exemples minoritaires lors de l'entraînement

C. Utiliser des métriques comme F1-score ou ROC AUC en plus de l'accuracy

D. Forcer les deux classes à avoir le même nombre d'exemples en supprimant les majoritaires sans réflexion

Question 19

Dans un problème supervisé, le sur-apprentissage (overfitting) se manifeste typiquement par :

A. Une faible erreur sur train et sur test

B. Une forte erreur sur train et sur test

C. Une faible erreur sur train mais une erreur élevée sur test

D. Une forte erreur sur train mais faible sur test

Question 20

Dans un pipeline complet de projet ML, à quel stade la phase de prétraitement (nettoyage, normalisation, encodage) intervient-elle ?

A. Après le déploiement, uniquement si les résultats sont mauvais

B. Avant la sélection et l'entraînement du modèle

C. Uniquement sur le test set

D. Uniquement pour les modèles de deep learning

Question 21

Les valeurs manquantes de type MCAR (« Missing Completely At Random ») peuvent, dans certains cas, être gérées par :

A. Suppression aléatoire de la moitié des lignes complètes

B. Suppression des lignes concernées, car le manque est indépendant des données

C. Remplacement systématique par zéro

D. Ignorance totale sans aucune vérification

Question 22

Pour un attribut numérique très asymétrique avec quelques outliers extrêmes, une stratégie raisonnable est :

A. Utiliser systématiquement une normalisation MinMax $[0, 1]$

B. Utiliser une standardisation, sans se soucier des outliers

C. Utiliser un transformeur de type Yeo-Johnson ou Box-Cox pour rapprocher la distribution de la normalité

D. Diviser simplement par le maximum

Question 23

La détection d'outliers par la méthode de l'IQR (Interquartile Range) repose sur :

A. Une hypothèse de distribution parfaitement gaussienne
B. Un seuil basé sur la médiane et l'écart interquartile
C. Une estimation de la probabilité de chaque point
D. Une classification supervisée des points extrêmes

Question 24

Dans un contexte métier, pourquoi n'est-il pas toujours souhaitable de supprimer les outliers détectés ?

A. Parce qu'ils sont toujours des erreurs de saisie
B. Parce qu'ils peuvent porter une information critique (par exemple, vrais cas de fraude)
C. Parce qu'ils ralentissent obligatoirement l'entraînement
D. Parce qu'ils n'affectent jamais le modèle

Question 25

Concernant la normalisation/standardisation :

A. Il faut toujours « fit » le scaler sur l'ensemble train+test pour avoir de meilleures statistiques
B. On fit le scaler sur le training set, puis on applique « transform » sur train, validation et test
C. On fit et transform uniquement sur le test set
D. La standardisation est inutile si on utilise des modèles linéaires

Question 26

La fuite de données (data leakage) en prétraitement survient notamment lorsque :

A. On effectue un split train/test avant toute transformation
B. On ajuste (fit) les transformeurs (ex. StandardScaler) sur tout le dataset puis on split
C. On applique les mêmes transformeurs appris sur train aux données de test
D. On utilise une validation croisée

Question 27

Pour une variable catégorique nominale avec beaucoup de modalités rares, une stratégie d'encodage raisonnable est :

A. One-hot encoding sans aucun regroupement des catégories
B. Regrouper les modalités rares en une catégorie « Other » avant One-Hot
C. Encodage ordinal en respectant un ordre alphabétique
D. Suppression pure et simple de la variable

Question 28

Le target encoding sur une variable catégor de haute cardinalité consiste à :

A. Remplacer chaque catégorie par une valeur aléatoire
B. Remplacer chaque catégorie par la moyenne de la variable cible associée à cette catégorie
C. Remplacer chaque catégorie par sa fréquence dans le dataset
D. N'utiliser aucune information de la cible

Question 29

Pour un dataset de maisons (features mixtes numériques/catégoriques) destiné à une régression, quel ordre de prétraitement est le plus cohérent ?

A. Split train/test → traitement valeurs manquantes → encodage catégoriel → scaling des features numériques
B. Scaling de toutes les colonnes → suppression des valeurs manquantes → split train/test
C. Encodage avant split, scaling uniquement sur test
D. Aucun prétraitement n'est nécessaire

Question 30

Quel est le principal risque si l'on ne traite pas correctement les doublons et incohérences dans les données de training ?

A. Les temps d'entraînement seront trop courts
B. Le modèle sera trop simple et sous-apprendra
C. Les estimations de performance seront biaisées et le modèle pourra apprendre des patterns erronés
D. Il sera impossible de calculer la fonction de coût

Question 31

Dans un problème de clustering clients en segments marketing, une mesure de distance mal adaptée (par exemple Euclidienne sur des features non normalisées) peut conduire à :

A. Une convergence plus rapide vers une meilleure solution
B. Des clusters qui reflètent essentiellement l'échelle de certaines variables dominantes
C. Une invariance totale aux unités des variables
D. Des clusters identiques à ceux obtenus avec une distance mieux choisie

Question 32

Pour K-Means, normaliser les features avant l'algorithme est particulièrement important parce que :

A. K-Means ne fonctionne qu'avec des features entières
B. La distance euclidienne est dominée par les variables à grande échelle
C. La distance euclidienne est invariante par changement d'échelle
D. Le nombre de clusters K est modifié par la normalisation

Question 38

PCA est typiquement utilisé pour :

A. Créer des labels artificiels pour un problème supervisé

B. Réduire la dimension tout en conservant un maximum de variance pour visualisation ou prétraitement

C. Remplacer le clustering dans tous les cas

D. Corriger automatiquement tous les outliers

Question 39

Après avoir appliqué PCA pour réduire à 2 dimensions un dataset initialement de grande dimension, on souhaite effectuer un clustering. Une bonne pratique est :

A. Utiliser K-Means directement sur les deux composantes principales

B. Revenir aux données originales et ignorer les composantes principales

C. Appliquer DBSCAN sur les labels de PCA

D. Évaluer le clustering uniquement sur la reconstruction d'erreur de PCA

Question 40

Lorsqu'on choisit le nombre de composantes en PCA pour garder au moins 95 % de variance expliquée, on :

A. Sélectionne simplement les 2 premières composantes

B. Utilise la somme cumulée des ratios de variance expliquée jusqu'à atteindre 0.95

C. Choisit un nombre de composantes égal au nombre de features initiales

D. Prend le nombre de composantes égal au nombre d'exemples

Fin de l'examen