EXAMEN MACHINE LEARNING

Destiné aux étudiants de 3ème année Génie Logiciel

Dr. Nizar OM HENI

Session Contrôle 2026

INSTRUCTIONS AUX ÉTUDIANTS

- **Durée :** 1h30
- **Nombre de questions :** 40 QCM
- **Documentation :** Aucune
- **Notation :** Chaque question = 0.5 point, score max = 20 points

Choisissez la bonne réponse pour les questions suivantes. Répondez sur une feuille séparée (pas sur cette feuille).

Question 1 : Vous disposez d'un dataset de 1000 patients avec leurs caractéristiques médicales (âge, tension, glycémie) et le diagnostic réel (diabétique/non-diabétique). Vous entraînez un modèle pour prédire les nouveaux cas. Quel paradigme d'apprentissage utilisez-vous ?

A. Apprentissage non supervisé
B. Apprentissage supervisé
C. Apprentissage par renforcement
D. Semi-apprentissage supervisé

Question 2 : Un algorithme k-NN stocke tous les exemples d'entraînement en mémoire et effectue des prédictions en cherchant les k voisins les plus proches. Quel type d'apprentissage décrit cela ?

A. Model-based learning
B. Eager learning
C. Instance-based learning
D. Batch learning

Question 3 : Vous avez un dataset de photos non étiquetées et un petit nombre de photos labellisées (chat/chien). Vous les combinez pour entraîner un modèle. Quelle approche appliquez-vous ?

A. Supervised learning uniquement
B. Unsupervised learning uniquement
C. Semi-supervised learning
D. Reinforcement learning

Question 4 : En apprentissage supervisé, votre modèle obtient une erreur de 2% sur l'ensemble d'entraînement mais 15% sur l'ensemble de test. Quel problème principal décrit cette situation ?

A. Underfitting

B. Overfitting
C. Data leakage
D. Imbalanced dataset

Question 5 : Pour un problème de régression (prédire le prix de maisons), vous utilisez d'abord 80% des données pour l'entraînement, puis 20% pour le test. Quel risque faites-vous courir ?

A. Vous n'utilisez pas assez de données
B. Vous n'avez pas de validation set pour ajuster les hyperparamètres
C. Le modèle sera trop simple
D. Vous évaluez le modèle sur des données déjà vues durant l'entraînement

Question 6 : Quelle est la différence conceptuelle majeure entre apprentissage batch et online learning ?

A. Batch utilise plus de données que online learning
B. Online learning met à jour le modèle progressivement avec de nouvelles données
C. Batch learning est plus lent que online learning
D. Online learning nécessite plus de mémoire RAM

Question 7 : Vous comparez deux systèmes : l'un utilise des règles hard-codées (if-then), l'autre apprend à partir d'exemples. Pour déterminer les objets sur une route (voitures, piétons), quel système est plus scalable ?

A. Le système basé sur des règles
B. Le système basé sur le machine learning
C. Les deux sont équivalents
D. Cela dépend du nombre d'objets à détecter

Question 8 : Trois composantes d'apprentissage supervisé sont essentielles. Laquelle complète cette liste : Dataset + Learning Algorithm + ?

A. Computational power
B. Predictive model
C. Validation set
D. Feature engineering

Question 9 : Dans un dataset, vous observez que 8% des valeurs manquent dans la colonne "Revenus" et ces absences sont distribuées aléatoirement. Quel type de manque décrit cela ?

A. MCAR (Missing Completely At Random)
B. MAR (Missing At Random)
C. MNAR (Missing Not At Random)
D. Outlier

Question 10 : Vous devez imputer 25% de valeurs manquantes dans une colonne numérique "Âge". Quelle stratégie est la plus robuste face aux outliers ?

A. Moyenne arithmétique
B. Médiane
C. Mode
D. Deletion (suppression complète)

Question 11 : Vous détectez des outliers en utilisant la méthode IQR (Q1-1.5× IQR, Q3+1.5×IQR). Une valeur dépasse Q3+1.5×IQR. Qu'en déduisez-vous ?

A. C'est forcément une erreur de saisie
B. C'est un point de données anormal selon IQR, mais il peut être légitime contextuellement
C. Le dataset est de mauvaise qualité
D. Vous devez utiliser Z-score à la place

Question 12 : Après imputation des valeurs manquantes, vous appliquez StandardScaler sur TOUT votre dataset (train + test), puis vous splitez en train/test. Quel problème crée cela ?

A. Aucun, c'est la bonne approche
B. Data leakage : les statistiques du test influencent le scaler
C. Le modèle sera trop simple
D. Vous perdez trop d'informations

Question 13 : Pour normaliser des features avec une plage [0, 100] avec MinMaxScaler, le résultat sera dans quel intervalle ?

A. [-1, 1]
B. [0, 1]
C. [0, 100]
D. Dépend de la distribution

Question 14 : Vous utilisez RobustScaler au lieu de StandardScaler. Quel avantage principal offre-t-il ?

A. Il est plus rapide computationnellement
B. Il normalise mieux les distributions skewées
C. Il est insensible aux outliers (utilise médiane et IQR)
D. Il garantit une distribution normale

Question 15 : Vous avez une variable catégorique "Ville" avec 1000 catégories différentes. Appliquer One-Hot Encoding créerait 1000 nouvelles colonnes. Qu'appelle-t-on ce problème ?

A. Overfitting
B. Curse of dimensionality
C. Data leakage
D. Underfitting

Question 16 : Pour une variable ordinale "Niveau d'éducation" (Primaire < Collège < Lycée < Licence < Master), quel encodage est approprié ?

A. One-Hot Encoding
B. Target Encoding
C. Ordinal Encoding avec l'ordre [0, 1, 2, 3, 4]
D. Label Encoding aléatoire

Question 17 : Pour prédire le prix d'une maison, vous créez une nouvelle feature "Surface × Qualité". Quel type de feature engineering est cela ?

A. Polynomial features
B. Interaction features
C. Polynomial interactions
D. Target encoding

Question 18 : Un modèle linéaire ne peut capturer que des relations linéaires. Vous créez deux colonnes supplémentaires : "Age^2" et "Age^3". Quel est l'objectif ?

A. Réduire le surapprentissage
B. Augmenter la complexité et permettre aux modèles linéaires de capturer des relations non-linéaires
C. Normaliser les données
D. Détecter les outliers

Question 19 : Vous appliquez Binning avec la méthode "equal-width" à la variable "Revenu" (0-100k€, 4 bins). Quel risque majeur existe-t-il ?

A. Les bins auront une distribution déséquilibrée si les données ne sont pas uniformes
B. Le binning perdra trop d'informations
C. Cela augmente la dimensionnalité excessivement
D. Les bins ne seront pas orthogonaux

Question 20 : Vous utilisez plutôt la méthode "equal-frequency" (quantiles). Quel avantage procure-t-elle par rapport à "equal-width" ?

A. Elle est plus rapide computationnellement
B. Chaque bin contient approximativement le même nombre d'observations
C. Elle crée automatiquement des patterns linéaires
D. Elle supprime les outliers

Question 21 : L'impact du feature engineering sur la performance finale d'un modèle est estimé à :

A. 10-20%
B. 30-40%
C. Jusqu'à 90%
D. Négligeable (l'algorithme importe plus)

Question 22 : Lors de la sélection de features avec la méthode "Wrapper" (par ex. RFE), quelle approche est utilisée ?

A. Évaluer l'importance statistique de chaque feature indépendamment (Filter)
B. Entraîner le modèle avec différentes sous-ensembles de features et évaluer la performance
C. Extraire automatiquement les composantes principales (PCA)
D. Supprimer itérativement les features les moins informatives

Question 23 : La méthode "Embedded" de sélection de features (par ex. via coefficients de régression logistique) offre quel avantage vs "Filter" ?

A. Elle est plus rapide
B. Elle considère l'interaction entre features via le modèle lui-même
C. Elle ne produit jamais de surapprentissage
D. Elle nécessite moins de données

Question 24 : Dans PCA, si les 3 premières composantes expliquent 95% de la variance totale, vous décidez de garder ces 3 composantes et d'en supprimer les autres. Quel est l'objectif principal ?

A. Réduire le surapprentissage
B. Réduire la dimensionnalité en perdant peu d'informations
C. Améliorer l'interprétabilité du modèle
D. Normaliser les données

Question 25 : Vous utilisez une Régression Linéaire simple pour prédire le prix immobilier. Vous observez une relation très courbe (non-linéaire) dans les données. Que pouvez-vous faire ?

A. Augmenter la taille du dataset
B. Ajouter des polynomial features (Age^2, Age^3...) pour transformer le problème en régression linéaire multivariée
C. Abandonner la régression linéaire pour un modèle non-paramétrique
D. Réduire le nombre de features

Question 26 : Pour un problème de classification binaire (spam/non-spam), vous entraînez une Régression Logistique. Quel est le rôle de la fonction sigmoid ?

A. Transformer les probabilités en classes discrètes (0 ou 1)
B. Normaliser les features
C. Transformer un score linéaire en probabilité [0, 1]
D. Réduire le surapprentissage

Question 27 : Un modèle SVM (Support Vector Machine) maximise la marge entre les classes. En cas de données non séparables linéairement, quel concept permet au SVM de les classifier ?

A. Regularization parameter C
B. Kernel trick (noyau)
C. Feature scaling
D. Cross-validation

Question 28 : Vous décidez d'utiliser k-Nearest Neighbors (k-NN) avec k=1. Quel risque majeur en découle ?

A. Underfitting
B. Overfitting (le modèle mémorise les données d'entraînement)
C. Instabilité numérique
D. Convergence lente

Question 29 : Un arbre de décision (Decision Tree) se compose de nuds, branches et feuilles. Quel critère de split est typiquement utilisé pour les problèmes de classification ?

A. Variance résiduels (comme en régression)
B. Gini index ou Information Gain (entropie)
C. Nombre de features
D. Taille du dataset

Question 30 : Vous entraînez un Random Forest avec 100 arbres. Quel mécanisme rend cette ensemble method plus robuste qu'un seul arbre ?

A. Chaque arbre vote, la majorité décide (bagging)
B. Les arbres sont entraînés séquentiellement pour corriger les erreurs
C. Les arbres utilisent différents kernels
D. Les features sont normalisées différemment pour chaque arbre

Question 31 : La méthode Gradient Boosting entraîne les modèles séquentiellement. Quel est l'objectif ?

A. Paralléliser l'entraînement pour plus de vitesse
B. Chaque nouveau modèle apprend des résidus (erreurs) du modèle précédent
C. Augmenter aléatoirement la diversité
D. Appliquer une régularisation L1/L2

Question 32 : Pour comparer deux modèles de classification (Decision Tree vs Logistic Regression), quelle métrique est la plus informative si le dataset est déséquilibré (ex : 95% classe A, 5% classe B) ?

A. Accuracy (précision globale)
B. Precision, Recall, ou F1-score
C. Nombre d'hyperparamètres
D. Temps d'entraînement

Question 33 : En clustering avec K-Means, vous définissez k=3. L'algorithme initialise aléatoirement 3 centroïdes. Quel risque découle d'une mauvaise initialisation ?

A. Le modèle convergera toujours vers le même résultat
B. Le modèle converge vers un optimum local plutôt que global
C. Les features seront normalisées de façon inconsistante
D. Les données ne seront jamais assignées aux clusters

Question 34 : Pour évaluer la qualité d'un clustering K-Means sans labels vrais (apprentissage non supervisé), quel indice est approprié ?

A. Accuracy (nécessite des labels)
B. Silhouette Score ou Davies-Bouldin Index
C. F1-score
D. AUC-ROC

Question 35 : Vous effectuez un clustering hiérarchique sur 1000 points. Quel est le principal avantage par rapport à K-Means ?

A. K-Means ne fonctionne pas pour de grandes données
B. Hiérarchique produit un dendrogramme permettant de visualiser les relations imbriquées
C. Hiérarchique converge toujours vers l'optimum global
D. Hiérarchique ne nécessite pas de normalisation

Question 36 : En PCA, vous standardisez vos données AVANT d'appliquer PCA. Pourquoi cette étape est-elle cruciale ?

A. Pour augmenter la variance totale
B. Afin que les variables avec grandes échelles ne dominent pas la définition des composantes
C. Pour garantir une distribution gaussienne
D. Pour réduire le temps de calcul

Question 37 : Vous appliquez PCA et observez que les 5 premières composantes expliquent 99% de la variance. Pouvez-vous supprimer les autres composantes sans perte significative d'information ?

A. Non, car cela introduirait du surapprentissage
B. Oui, car elles n'expliquent que 1% de la variance (probablement du bruit)
C. Cela dépend du nombre de features originales
D. Non, car chaque composante apporte une information unique

Question 38 : Dans la détection d'anomalies (unsupervised), vous utilisez l'Isolation Forest. Quel principe fonde cet algorithme ?

A. Grouper les points normaux et marquer les groupes isolés comme anomalies
B. Isoler les anomalies progressivement (elles sont plus faciles à isoler que les points normaux)
C. Utiliser des arbres de décision inversés
D. Calculer la distance euclidienne à tous les autres points

Question 39 : Vous disposez de deux modèles : Model A (Accuracy = 92%, mais pas interprétable, temps prédiction = 5ms) et Model B (Accuracy = 88%, très interprétable, temps = 0.1ms). Vous devez le déployer en production pour un système d'alerte médicale en temps réel. Quel modèle choisissez-vous et pourquoi ?

A. Model A car il a meilleure accuracy
B. Model B car c'est un compromis : interprétabilité acceptable pour un système médical + latence très faible pour temps réel
C. Ni l'un ni l'autre, créer un ensemble
D. Model B uniquement pour l'interprétabilité

Question 40 : Vous préparez un rapport pour un client non-technique sur les performances de votre modèle ML. Parmi ces affirmations, laquelle reflète CORRECTEMENT votre responsabilité éthique et pédagogique ?

A. "Le modèle a 95% d'accuracy, il est parfait !"
B. "Le modèle a 95% d'accuracy sur les données de test, mais nécessite un suivi périodique et peut produire faux négatifs dans 5% des cas. Les décisions critiques doivent impliquer un expert humain."
C. "Le modèle utilise du machine learning, donc il apprend seul et s'améliore toujours."
D. "L'accuracy est la seule métrique importante."