RÉPUBLIQUE TUNISIENNE
INSTITUT SUPÉRIEUR D'INFORMATIQUE ET DE MATHÉMATIQUES DE MONASTIR
3e année

Vocabulaire essentiel du Machine Learning

Chapitre 1 1 Concepts fondamentaux

Terme anglais	Équivalent français	Définition et utilisation
Artificial Intelligence (AI)	Intelligence artificielle (IA)	Domaine des systèmes capables de réaliser des tâches associées à l'intelligence ; utile pour le raisonnement, la recherche et la planification.
Machine Learning (ML)	Apprentissage automatique	Branche de l'IA qui apprend un comportement à partir de données ; utilisée pour la prédiction et la classification.
Deep Learning (DL)	Apprentissage profond	Partie du ML fondée sur des réseaux de neurones multicouches ; utilisée notamment pour images, sons et langage.
Rule-based Program	Programme à base de règles	Système dont les conditions sont écrites à la main ; adapté lorsque les règles sont explicites et stables.
Learned Model	Modèle appris	Composant dont le comportement est inféré à partir des exemples ; utile lorsque les règles sont complexes.
Pattern	Motif / régularité	Relation récurrente dans les données, exploitée pour prédire ou classer.
Training	Entraînement	Phase durant laquelle les paramètres d'un modèle sont appris à partir des données.
Retraining	Réentraînement	Nouvel apprentissage sur des données mises à jour, par exemple si les comportements changent.
Task (T)	Tâche	Objectif à réaliser, p. ex. reconnaître les emails indésirables ; élément de la définition de Mitchell.
Performance (P)	Performance	Mesure du succès du programme sur sa tâche ; sert à évaluer les progrès.
Experience (E)	Expérience	Exemples ou données dont apprend le programme ; élément de la définition de Mitchell.

Chapitre 1 2 Paradigmes d'apprentissage

Terme anglais	Équivalent français	Définition et utilisation
Supervised Learning	Apprentissage supervisé	Apprendre une correspondance entre x et y à partir de données étiquetées ; classification et régression.
Unsupervised Learning	Apprentissage non supervisé	Découvrir des structures sans étiquettes ; segmentation des clients et réduction de dimension.
Semi-supervised Learning	Apprentissage semi-supervisé	Exploiter peu de données étiquetées et beaucoup de données non étiquetées ; utile si l'annotation coûte cher.
Reinforcement Learning	Apprentissage par renforcement	Un agent agit et reçoit des récompenses ; utilisé en robotique et dans les jeux.
Labeled Data	Données étiquetées	Exemples pour lesquels la réponse attendue est connue ; nécessaires au supervisé.
Unlabeled Data	Données non étiquetées	Exemples sans réponse cible connue ; utiles pour le non supervisé ou le semi-supervisé.
Agent	Agent	Entité qui choisit des actions ; notamment en apprentissage par renforcement.
Reward	Récompense	Signal reçu après une action ; guide l'apprentissage par renforcement.
Mapping x → y	Correspondance x → y	Relation entre les entrées et les sorties que le modèle supervisé cherche à apprendre.

Chapitre 1 3 Données et modèles

Terme anglais	Équivalent français	Définition et utilisation
Dataset	Jeu de données	Collection D des observations servant à apprendre ou évaluer un modèle.
Sample	Échantillon / observation	Une observation du jeu de données, par exemple une fleur Iris.
Instance	Instance	Autre terme pour désigner une observation individuelle.
Feature	Caractéristique / variable explicative	Propriété mesurable utilisée en entrée, par exemple longueur d'un pétale.
Feature Vector	Vecteur de caractéristiques	Liste des d caractéristiques d'une observation x_i ; entrée d'un modèle.

Label	Étiquette	Valeur réelle associée à une observation, souvent sa classe.
Target	Variable cible	Valeur y que l'on souhaite prédire.
Input	Entrée	Données x fournies au modèle pour obtenir une prédiction.
Output	Sortie	Résultat du modèle, notamment sa prédiction.
Model	Modèle	Fonction fθ qui associe une sortie à une entrée.
Hypothesis	Hypothèse	Fonction candidate envisageable pour expliquer les données.
Hypothesis Space	Espace des hypothèses	Ensemble $\mathcal{H}$ des fonctions candidates dans lequel l'algorithme cherche un modèle.
Learning Algorithm	Algorithme d'apprentissage	Procédure qui sélectionne ou ajuste un modèle en utilisant les données.
Parameter (θ)	Paramètre (θ)	Valeur interne apprise pendant l'entraînement du modèle.
Hyperparameter	Hyperparamètre	Choix de configuration non appris directement par fit, tel que k pour k-NN ; réglé sur validation.
Prediction (ŷ)	Prédiction (ŷ)	Valeur calculée par un modèle à partir de x.
Truth / True Value	Valeur réelle	Valeur y servant de référence pour apprécier l'erreur de la prédiction.

Chapitre 1 4 Tâches supervisées

Terme anglais	Équivalent français	Définition et utilisation
Classification	Classification	Prédire une catégorie discrète ; par exemple spam/non-spam ou espèce d'Iris.
Regression	Régression	Prédire une grandeur continue ; par exemple un prix ou une température.
Class	Classe	Catégorie possible pour la sortie d'une classification.
Categorical Target	Cible catégorielle	Variable y à valeurs discrètes ; caractérise une tâche de classification.
Continuous Target	Cible continue	Variable y numérique continue ; caractérise une tâche de régression.
Classifier	Classifieur	Modèle qui prédit la classe d'une observation.
Separability	Séparabilité	Degré auquel les classes occupent des régions distinctes dans l'espace des caractéristiques.
k-Nearest Neighbors (k-NN)	k plus proches voisins	Modèle exploitant les k observations les plus proches ; exemple du premier vrai modèle du chapitre.
Majority Class	Classe majoritaire	Classe la plus fréquente du jeu d'entraînement ; sert à une baseline.
Imbalanced Classes	Classes déséquilibrées	Classes dont les fréquences sont très différentes ; l'accuracy peut être trompeuse.

Chapitre 1 5 Perte, risque et généralisation

Terme anglais	Équivalent français	Définition et utilisation
Loss Function	Fonction de perte	Mesure l'écart d'une prédiction ŷ à la vérité y ; utilisée pour entraîner le modèle.
Squared Error	Erreur quadratique	Perte de régression $(y - \hat{y})^2$; pénalise fortement les grands écarts.
Empirical Risk	Risque empirique	Moyenne des pertes sur les données d'entraînement ; quantité minimisée à l'apprentissage.
Expected Risk	Risque espéré	Perte moyenne sur la distribution de données réelle ; objectif de généralisation.
True Risk	Risque réel	Autre expression pour le risque espéré, estimé grâce à des données non vues.
Empirical Risk Minimization (ERM)	Minimisation du risque empirique	Choisir θ de façon à réduire la perte moyenne observée sur l'entraînement.
Training Error	Erreur d'entraînement	Erreur mesurée sur les exemples ayant servi à ajuster le modèle.
True Error	Erreur réelle	Erreur du modèle sur la distribution cible, généralement inconnue exactement.
Generalization	Généralisation	Capacité du modèle à réussir sur de nouvelles observations de même origine.
Overfitting	Surapprentissage	Mémorisation excessive de l'entraînement ; bon score train mais mauvais score sur données nouvelles.
Underfitting	Sous- apprentissage	Modèle incapable d'apprendre correctement même les données d'entraînement.

Chapitre 1 6 Train, validation et test

Terme anglais	Équivalent français	Définition et utilisation
Data Split	Partitionnement des données	Division du jeu en ensembles distincts pour l'apprentissage et l'évaluation.
Training Set	Ensemble d'entraînement	Partie des données servant à apprendre les paramètres θ.
Validation Set	Ensemble de validation	Partie utilisée pour régler les choix de modèle et les hyperparamètres.
Test Set	Ensemble de test	Partie conservée intacte jusqu'à l'évaluation finale ; estime la performance sur données non vues.
Unseen Data	Données non vues	Observations absentes de l'entraînement ; nécessaires à une estimation honnête.
Hold-out	Mise en réserve	Mise de côté d'une portion de données pour l'évaluation indépendante.
Disjoint Sets	Ensembles disjoints	Ensembles sans observations communes, pour éviter de biaiser l'évaluation.
Fit / Model Fitting	Ajustement / entraînement	Opération apprenant les paramètres du modèle sur train.
Tune	Ajuster les hyperparamètres	Comparer des choix de configuration sur les données de validation.
Hyperparameter Tuning	Réglage des hyperparamètres	Choix d'hyperparamètres selon leur score de validation.
Predict	Prédire	Calculer des sorties pour des entrées, sans réentraîner le modèle.
Inference	Inférence	Utiliser le modèle appris pour produire des prédictions.
Score	Score	Résultat numérique d'une métrique mesurant la qualité des prédictions.
Evaluation	Évaluation	Mesure des performances, idéalement sur un ensemble de test indépendant.

Chapitre 1 7 Baselines et métriques

Terme anglais	Équivalent français	Définition et utilisation
Baseline	Modèle de référence	Stratégie élémentaire à dépasser pour montrer qu'un modèle apprend quelque chose d'utile.
Majority-class Baseline	Référence par classe majoritaire	Toujours prédire la classe la plus fréquente du train ; référence de classification.
Mean Baseline	Référence par la moyenne	Toujours prédire la moyenne de y sur train ; référence de régression.
DummyClassifier	Classifieur naïf de référence	Estimateur scikit-learn mettant en œuvre une stratégie simple comme most_frequent.
Accuracy	Exactitude / taux de bonnes classifications	Nombre de prédictions correctes / nombre total ; à interpréter avec prudence si classes déséquilibrées.
Classification Accuracy	Taux de classification correcte	Accuracy appliquée à une tâche de classification.
Performance Metric	Métrique de performance	Indicateur chiffré de qualité permettant de comparer les modèles.
Test Accuracy	Accuracy sur le test	Accuracy calculée une seule fois sur le jeu de test final.
Training Accuracy	Accuracy sur l'entraînement	Accuracy sur les données d'apprentissage ; ne suffit pas pour juger la généralisation.
Positive Class	Classe positive	Classe d'intérêt, par exemple la fraude ; sa rareté peut rendre l'accuracy insuffisante.
Metric–Goal Mismatch	Inadéquation métrique–objectif	Métrique choisie qui mesure mal le besoin réel, p. ex. accuracy pour détecter des fraudes rares.

Chapitre 1 8 Outils et méthodes de travail

Terme anglais	Équivalent français	Définition et utilisation
Data Loading	Chargement des données	Lecture et importation des observations dans l'environnement Python.
Preprocessing	Prétraitement	Opérations préparant les caractéristiques avant l'apprentissage.
Data Validation	Validation des données	Contrôles de qualité et de conformité avant de passer au modèle.
Scaling	Mise à l'échelle	Transformation des variables numériques ; à ajuster sur train pour éviter les fuites.

Train-Test Split	Découpage entraînement-test	Séparation en données d'ajustement et de test indépendant.
Stratification	Stratification	Découpage préservant approximativement la proportion de chaque classe.
Random Seed	Graine aléatoire	Valeur initialisant des opérations pseudo-aléatoires pour reproduire l'expérience.
random_state	État aléatoire	Paramètre Python/scikit-learn permettant de rendre les découpages reproductibles.
Reproducibility	Reproductibilité	Capacité à obtenir les mêmes résultats dans les mêmes conditions.
Pipeline	Chaîne de traitement	Enchaînement de préparation, modèle et prédiction dans une procédure contrôlée.
Separation of Concerns	Séparation des responsabilités	Organiser distinctement chargement, prétraitement, modélisation et évaluation.
Data Versioning	Versionnement des données	Tracer les versions des données et leurs changements.
Versioned Model	Modèle versionné	Artifact entraîné auquel une version est associée pour assurer le suivi.
scikit-learn	Bibliothèque scikit-learn	Bibliothèque Python de modèles et outils d'apprentissage automatique.
NumPy	Bibliothèque NumPy	Outil Python pour calculs et tableaux numériques.
Pandas	Bibliothèque Pandas	Outil Python pour les données tabulaires.
Estimator	Estimateur	Objet scikit-learn proposant notamment la méthode fit.
.fit(X, y)	Méthode d'entraînement	Apprendre le modèle à partir des caractéristiques X et cibles y.
.predict(X)	Méthode de prédiction	Produire les prédictions pour les observations X.
.score(X, y)	Méthode de score	Calculer la métrique par défaut de l'estimateur pour X et y.

Chapitre 1 9 Erreurs et hypothèses

Terme anglais	Équivalent français	Définition et utilisation
Data Leakage	Fuite de données	Informations de validation/test introduites dans l'entraînement ; ex. scaling avant split.
Distribution Shift	Changement de distribution	Les nouvelles données ne suivent plus la distribution d'entraînement ; performances potentiellement dégradées.
Garbage In, Garbage Out (GIGO)	Mauvaises données, mauvais résultats	Principe selon lequel les données défectueuses compromettent même un bon modèle.
Failure Mode	Mode de défaillance	Façon typique dont un système peut échouer ; utile pour anticiper les risques.
i.i.d. (Independent and Identically Distributed)	Indépendantes et identiquement distribuées	Hypothèse d'observations indépendantes issues de la même distribution.
Representative Data	Données représentatives	Données d'apprentissage correspondant bien à la population d'utilisation.
Stationarity	Stationnarité	Stabilité approximative de la distribution pertinente pendant l'usage du modèle.
Probability Distribution	Distribution de probabilité	Loi décrivant les probabilités des observations ; notée $\mathcal{P}$ dans le cours.
Learnable Signal	Signal apprenable	Relation réelle entre caractéristiques et cible que le modèle peut exploiter.
Correlation	Corrélation	Association statistique entre variables, qui ne prouve pas la causalité.
Causation	Causalité	Lien de cause à effet, distinct d'une simple association.
Association	Association	Relation observée entre variables, sans preuve qu'une cause l'autre.
Uncertainty	Incertitude	Limite ou variabilité liée à une prédiction ; à communiquer lors de l'interprétation.
Production Data	Données de production	Données rencontrées par le modèle dans son utilisation réelle.

Chapitre 1 10 Notations et paramètres Python

Terme anglais	Équivalent français	Définition et utilisation
X — Feature Matrix	Matrice des caractéristiques	Contient les caractéristiques des observations fournies au modèle.
y — Target Vector	Vecteur cible	Contient les vraies valeurs à prédire.
x_i — Feature Vector	Vecteur de caractéristiques	Caractéristiques de l'observation i.
y_i — True Label	Étiquette réelle	Valeur attendue associée à l'observation i.
$\hat{y}$ — Predicted Value	Valeur prédite	Prédiction réalisée par le modèle.
f_θ — Parameterized Model	Modèle paramétré	Fonction prédictive dépendant des paramètres θ.
θ — Parameters	Paramètres	Valeurs apprises à partir du train.
$\mathcal{H}$ — Hypothesis Space	Espace des hypothèses	Ensemble des fonctions candidates.
D — Dataset	Jeu de données	Ensemble des couples (x_i, y_i).
L(y, ŷ) — Loss	Perte	Mesure de l'écart entre valeur prédite et réelle.
R_{emp} — Empirical Risk	Risque empirique	Moyenne des pertes observées sur train.
R(f) — Expected Risk	Risque espéré	Perte moyenne sur la distribution $\mathcal{P}$.
$\mathcal{P}$ — Data Distribution	Distribution des données	Loi probabiliste des observations.
test_size	Taille du test	Proportion de données réservée au test lors du découpage.
stratify	Stratifier	Option maintenant les proportions des classes pendant le découpage.
n_neighbors	Nombre de voisins	Nombre k utilisé par k-NN.
most_frequent	Le plus fréquent	Stratégie du DummyClassifier prédisant toujours la classe majoritaire.

Chapitre 2 Préparation des données et analyse exploratoire

Vocabulaire de la séance 1 sur 2 : types de données, statistiques descriptives, valeurs manquantes et valeurs aberrantes.

Chapitre 2 1 Préparation des données et types

Terme anglais	Équivalent français	Définition et utilisation
Data Preparation	Préparation des données	Ensemble des opérations qui rendent les données utilisables avant l'entraînement : audit, nettoyage, encodage et mise à l'échelle.
Exploratory Data Analysis (EDA)	Analyse exploratoire des données	Examen des distributions, statistiques et graphiques pour comprendre un jeu de données et repérer des problèmes.
Data Audit	Audit des données	Contrôle initial des types, dimensions, valeurs absentes et incohérences avant de choisir un traitement.
Numerical Variable	Variable numérique	Variable exprimant une quantité mesurable ou un comptage ; sa nature détermine les statistiques possibles.
Continuous Variable	Variable continue	Variable pouvant prendre des valeurs dans un intervalle, par exemple l'âge ou le prix du billet.
Discrete Variable	Variable discrète	Variable représentant un comptage, généralement entier, par exemple le nombre de proches à bord.
Categorical Variable	Variable catégorielle	Variable décrivant des modalités, telles que le pays ou la classe d'un billet.
Nominal Variable	Variable nominale	Catégories sans ordre naturel, par exemple groupe sanguin ou port d'embarquement.
Ordinal Variable	Variable ordinale	Catégories possédant un ordre significatif, comme faible, moyen, élevé ; les écarts ne sont pas forcément égaux.
Category Encoding	Encodage des catégories	Conversion des modalités en nombres selon une méthode adaptée à la nature de la variable ; annoncée pour la séance 2.
Data Cleaning	Nettoyage des données	Correction ou traitement des valeurs problématiques afin de limiter les erreurs d'analyse.

Chapitre 2 2 Statistiques descriptives et dispersion

Terme anglais	Équivalent français	Définition et utilisation
Descriptive Statistics	Statistiques descriptives	Indicateurs résumant une distribution : moyenne, médiane, variance ou écart-type.
Mean / Arithmetic Mean	Moyenne arithmétique	Somme des valeurs divisée par leur nombre ; mesure le centre mais réagit fortement aux valeurs extrêmes.
Median	Médiane	Valeur centrale des données triées ; souvent préférable à la moyenne en présence d'une forte asymétrie.
Dispersion	Dispersion	Degré d'étalement des observations autour d'une valeur centrale ; complète la moyenne.
Variance	Variance	Moyenne des écarts au carré par rapport à la moyenne ; mesure la dispersion en unités au carré.
Standard Deviation	Écart-type	Racine carrée de la variance ; mesure la dispersion dans la même unité que les données.
Population Standard Deviation	Écart-type de population	Écart-type calculé en divisant la somme des carrés des écarts par n ; comportement par défaut de np.std.
Sample Standard Deviation	Écart-type d'échantillon	Écart-type corrigé calculé avec n − 1 ; comportement par défaut de pandas Series.std.
Bessel's Correction	Correction de Bessel	Utilisation de n − 1 au lieu de n pour estimer sans biais la variance d'une population à partir d'un échantillon.
Degrees of Freedom (ddof)	Correction des degrés de liberté	Paramètre précisant le diviseur n − ddof ; np.std utilise ddof=0 et pandas Series.std utilise ddof=1.
Skewed Distribution	Distribution asymétrique	Distribution dont une queue est plus longue ; une forte valeur peut déplacer la moyenne loin de la médiane.
Central Tendency	Tendance centrale	Position typique des données, résumée notamment par leur moyenne ou médiane.

Chapitre 2 3 Valeurs manquantes et imputation

Terme anglais	Équivalent français	Définition et utilisation
Missing Value	Valeur manquante	Valeur absente dans une observation ; à examiner avant tout nettoyage.
Missingness Rate	Taux de valeurs manquantes	Proportion de données absentes dans une colonne ; aide à décider de l'imputation ou de la suppression.
Missing-Value Audit	Audit des valeurs manquantes	Comptage par colonne des valeurs absentes, par exemple avec df.isna().sum().
Row Deletion / Listwise Deletion	Suppression de lignes incomplètes	Retrait des observations comportant des données absentes ; peut faire perdre beaucoup de données.
Column Dropping	Suppression de colonne	Retrait d'une variable trop incomplète ou peu utile ; fait aussi perdre l'information qu'elle portait.
Imputation	Imputation	Remplacement d'une valeur manquante par une valeur calculée ou une catégorie explicite.
Mean Imputation	Imputation par la moyenne	Remplacement des valeurs numériques absentes par la moyenne estimée sur Train ; sensible aux extrêmes.
Median Imputation	Imputation par la médiane	Remplacement par la médiane de Train ; adaptée aux colonnes numériques asymétriques.
Most-Frequent Imputation	Imputation par la modalité fréquente	Remplacement des catégories absentes par la modalité la plus courante dans Train.
Missing Category	Catégorie « Missing »	Modalité distincte indiquant qu'une valeur catégorielle était absente.
Missingness Indicator	Indicateur de valeur manquante	Colonne binaire (0/1) signalant l'absence d'une valeur ; utile si cette absence apporte une information.
Artificial Peak	Pic artificiel	Accumulation de valeurs identiques introduite par une imputation répétée, susceptible de déformer la distribution.

Chapitre 2 4 Valeurs aberrantes et mesures robustes

Terme anglais	Équivalent français	Définition et utilisation
Outlier	Valeur aberrante	Observation exceptionnellement éloignée ; elle peut être une erreur ou une valeur rare mais réelle.
Extreme Value	Valeur extrême	Observation très grande ou très petite, qui n'est pas nécessairement invalide.
Robust Statistic	Statistique robuste	Indicateur peu influencé par les valeurs extrêmes, comme la médiane et les quartiles.
Percentile	Centile	Seuil au-dessous duquel se trouve une proportion donnée des observations.
Quartile (Q1, Q3)	Quartile (Q1, Q3)	Q1 et Q3 correspondent respectivement aux 25e et 75e centiles ; ils encadrent la moitié centrale.
Interquartile Range (IQR)	Écart interquartile	Différence Q3 − Q1 ; mesure robuste de la dispersion centrale.
Tukey Fences / IQR Rule	Barrières de Tukey / règle IQR	Signale les valeurs sous Q1 − 1,5 × IQR ou au-dessus de Q3 + 1,5 × IQR.
Z-score	Score standardisé z	Écart d'une valeur à la moyenne mesuré en écarts-types : z = (x − moyenne)/écart-type.
Outlier Detection	Détection des valeurs aberrantes	Repérage des observations atypiques par une règle comme IQR ou |z| > 3 ; ne décide pas automatiquement de les supprimer.
Winsorization / Capping	Winsorisation / plafonnement	Remplacement des valeurs extrêmes par une limite choisie pour réduire leur influence sans enlever la ligne.
Log Transformation	Transformation logarithmique	Transformation utile pour certaines distributions positives asymétriques ; log(1+x) convient aussi aux zéros.
Domain Knowledge	Connaissance du domaine	Compréhension du contexte nécessaire pour décider si une observation extrême est plausible.
Documented Decision	Décision documentée	Trace écrite du traitement appliqué et de sa justification, pour faciliter la reproductibilité.