TD n° 1 — Des données brutes à une évaluation honnête

Sujet étudiant

Établissement	ISIMM — Institut Supérieur d'Informatique et de Mathématiques de Monastir, Université de Monastir
Niveau	3e année ingénieur — Génie Logiciel
Module	Machine Learning
Chapitres	Ch. 1 — Introduction au Machine Learning · Ch. 2 — Préparation des données et analyse exploratoire
Durée	90 minutes
Année universitaire	2026–2027

Dr. Nizar OM HENI — Responsable du cours

Objectifs d'apprentissage

À la fin de ce TD, vous devez être capable de :

1. formuler un problème d'apprentissage (tâche T, performance P, expérience E), identifier son paradigme et le type de tâche (classification ou régression) ;
2. classer une variable (continue, discrète, nominale, ordinale) à partir de son sens et non de son stockage ;
3. calculer moyenne, médiane, variance et écart-type, et dire si un outil divise par n ou par $n-1$;
4. détecter des valeurs aberrantes (règle IQR, z-score), expliquer l'effet de masquage et justifier une décision ;
5. choisir un encodage et une mise à l'échelle adaptés au modèle, et mesurer leur effet sur une distance ;
6. calculer et interpréter covariance et corrélation de Pearson, sans conclure à une causalité ;
7. repérer une fuite de données, comparer un modèle à une baseline et écrire un protocole sans fuite.

Prérequis

- Chapitre 1 : vocabulaire (exemple, variable, cible, modèle), séparation apprentissage / validation / test, baseline de la classe majoritaire.
- Chapitre 2 : sections 2 à 5 des notes de cours.
- Mathématiques : notation $\sum$, racine carrée, moyenne.

Consignes et ressources autorisées

- Travail individuel ou en binôme, sur papier. **Calculatrice autorisée.** Pas d'ordinateur.
- Les notes de cours ne sont **pas** autorisées pendant la recherche, sauf indication de l'enseignant.
- Arrondir les résultats à **2 décimales**, sauf indication contraire. Détailler les calculs : la démarche est notée.
- Toutes les données de ce TD sont **fictives** et construites à des fins pédagogiques.
- **Convention de quantile** (identique au cours) : sur n valeurs triées numérotées à partir de 0, le quantile d'ordre p est situé à la position $h = (n-1)\,p$; on interpole linéairement entre les deux valeurs voisines.

Contexte commun

L'opérateur fictif **TuniCom** veut prédire si un client va **résilier** son abonnement le mois prochain. Chaque ligne de son jeu de données décrit un client :

Colonne	Description	Exemple
`age`	âge du client (années)	34
`ancienete_mois`	nombre de mois depuis la souscription	27
`nb_appels_support`	nombre d'appels au support dans le mois	3
`forfait`	Basic, Standard ou Premium	Standard
`gouvernorat`	gouvernorat de résidence (24 valeurs possibles)	Monastir
`mode_paiement`	carte, espèces ou mobile	mobile
`satisfaction`	note d'enquête, de 1 à 5 étoiles	4
`code_postal`	code postal du domicile	5000
`facture`	facture mensuelle (TND)	47,5
`resilie`	le client a-t-il résilié ? (oui / non)	non

Exercice 1 — Cadrer le problème et typer les variables

Objectif : formuler le problème TuniCom avec le vocabulaire du chapitre 1 et classer correctement des variables. **Durée :** 9 min · **Difficulté :** facile · **Barème :** 2,5 pts

Q1.1 (0,75 pt) Pour la prédiction de `resilie` :
(a) donner la tâche T, une mesure de performance P et l'expérience E ;
(b) préciser le paradigme d'apprentissage et s'il s'agit de classification ou de régression, en justifiant par le type de la cible ;
(c) l'équipe marketing veut aussi regrouper les clients en segments, **sans aucune étiquette**. De quel paradigme s'agit-il ?

Q1.2 (1,25 pt) Classer chacune des huit variables suivantes en **numérique continue**, **numérique discrète**, **catégorielle nominale** ou **catégorielle ordinale** : `age`, `ancienete_mois`, `nb_appels_support`, `forfait`, `gouvernorat`, `mode_paiement`, `satisfaction`, `code_postal`. Justifier en une ligne les cas qui ne sont pas immédiats.

Q1.3 (0,5 pt) Dans le fichier, `satisfaction` et `code_postal` sont stockées en entiers (`int64`). Un collègue en déduit qu'elles sont numériques. Expliquer pourquoi le raisonnement est faux, en citant pour chacune une opération qui n'a pas de sens.

Exercice 2 — Résumer une variable : centre, dispersion, imputation

Objectif : calculer et interpréter les statistiques descriptives d'une colonne, puis choisir une valeur d'imputation. **Durée :** 12 min · **Difficulté :** facile à intermédiaire · **Barème :** 3,5 pts

On extrait du **jeu d'apprentissage** la facture mensuelle (TND) de huit clients :

$$x = (30,\ 35,\ 35,\ 40,\ 45,\ 50,\ 55,\ 230)$$

Q2.1 (0,75 pt) Calculer la moyenne $\bar{x}$ et la médiane. Combien de clients ont une facture inférieure à la moyenne ? Que traduit cet écart entre moyenne et médiane ?

Q2.2 (1 pt) À l'aide d'un tableau à trois lignes (x_i, $x_i - \bar{x}$, $(x_i - \bar{x})^2$), calculer la variance σ^2 et l'écart-type σ **de population**. Vérifier votre tableau grâce à une propriété des écarts à la moyenne.

Q2.3 (1 pt) (a) Calculer la variance s^2 et l'écart-type s **d'échantillon**.
(b) Quelle valeur (σ ou s) renvoie chacun des appels suivants : `np.std(x)`, `pd.Series(x).std()`, `StandardScaler().fit(X).scale_` ?

Q2.4 (0,75 pt) Un neuvième client du jeu d'apprentissage a une facture **manquante**. Proposer une valeur d'imputation, justifier le choix entre moyenne et médiane, et préciser **sur quelles lignes** cette valeur doit être calculée.

Exercice 3 — Détecter les valeurs aberrantes : règle IQR contre z-score

Objectif : appliquer deux règles de détection, expliquer leur désaccord et prendre une décision justifiée.
Durée : 11 min · **Difficulté :** intermédiaire · **Barème :** 3 pts

On reprend la série de l'exercice 2 : $x = (30,\ 35,\ 35,\ 40,\ 45,\ 50,\ 55,\ 230)$.

Q3.1 (1 pt) Avec la convention d'interpolation linéaire rappelée dans les consignes, calculer Q_1, Q_3 et IQR. Donner la position h utilisée pour chaque quartile.

Q3.2 (0,5 pt) Calculer les barrières de Tukey et indiquer les valeurs signalées.

Q3.3 (0,75 pt) Calculer le z-score de la valeur 230 (écart-type de population). La règle $|z| > 3$ la signale-t-elle ? Expliquer ce désaccord avec la règle IQR.

Q3.4 (0,75 pt) Le service commercial confirme que la facture de 230 TND est **réelle** : il s'agit d'une entreprise abonnée à plusieurs lignes. Parmi *garder*, *plafonner*, *supprimer* et *transformer*, quelle(s) décision(s) proposez-vous ? Justifier. Si vous plafonnez, sur quelles données le seuil doit-il être calculé ?

Exercice 4 — Encoder et mettre à l'échelle

Objectif : choisir un encodage sans inventer de structure et montrer, par le calcul, l'effet de la mise à l'échelle sur un plus proche voisin. **Durée :** 13 min · **Difficulté :** intermédiaire · **Barème :** 3,5 pts

Q4.1 (1 pt) Proposer un encodage (one-hot ou ordinal) pour `forfait`, `gouvernorat`, `mode_paiement` et `satisfaction`. Justifier chaque choix en une ligne.

Q4.2 (0,5 pt) Un collègue code `mode_paiement` ainsi : carte $= 0$, espèces $= 1$, mobile $= 2$, puis entraîne une régression logistique. Citer deux hypothèses fausses que ce codage impose au modèle.

Q4.3 (1,25 pt) Un modèle kNN compare trois clients décrits par (`age`, `facture`) : A $= (25,\ 40)$, B $= (55,\ 42)$, C $= (26,\ 90)$. Sur le jeu d'apprentissage, on a mesuré : $\mu_{\text{age}} = 40$, $\sigma_{\text{age}} = 10$, $\mu_{\text{facture}} = 50$, $\sigma_{\text{facture}} = 20$.

(a) Calculer les distances euclidiennes $d(A, B)$ et $d(A, C)$ sur les valeurs brutes. Quel est le plus proche voisin de A ?

(b) Standardiser les trois clients avec les statistiques d'apprentissage, puis recalculer les deux distances. Quel est maintenant le plus proche voisin de A ?

(c) Expliquer en une phrase pourquoi la conclusion change.

Q4.4 (0,75 pt) On applique une normalisation min–max ajustée sur l'apprentissage ($x_{\min} = 20$, $x_{\max} = 260$ TND).
(a) Calculer la valeur transformée d'un client **de test** dont la facture vaut 300 TND. Est-ce une erreur ? Faut-il réajuster la normalisation sur le jeu de test ?
(b) Un arbre de décision a-t-il besoin de cette mise à l'échelle ? Pourquoi ?

Exercice 5 — Mesurer une relation sans conclure trop vite

Objectif : calculer covariance et corrélation de Pearson, puis en délimiter l'interprétation. **Durée :** 10 min · **Difficulté :** intermédiaire · **Barème :** 2,5 pts

Pour cinq clients, on relève $x =$ `nb_appels_support` et $y =$ consommation de données mobiles du mois (Go) :

Client	1	2	3	4	5
x (appels)	0	1	2	3	4
y (Go)	5	4	4	2	0

Q5.1 (1 pt) Calculer $\mathrm{Cov}(x, y)$ (diviseur n), σ_x, σ_y et le coefficient de Pearson r_{xy}. Interpréter le signe et l'intensité.

Q5.2 (0,5 pt) Un analyste conclut : « appeler le support fait baisser la consommation de données ». Critiquer cette conclusion et proposer une autre explication plausible.

Q5.3 (0,5 pt) Sur un autre échantillon, $u = (1, 2, 3, 4, 5)$ et $v = (4, 1, 0, 1, 4)$. Calculer r_{uv}. Peut-on conclure que v n'a aucun lien avec u ?

Q5.4 (0,5 pt) Un rapport affirme : « avec $r = 0{,}26$, la facture explique 26 % de la résiliation ». Corriger cette phrase.

Exercice 6 — Synthèse : auditer le notebook d'un collègue

Objectif : détecter les fuites et les erreurs d'évaluation dans un code réaliste, comparer à une baseline, décider du traitement des manques et écrire un protocole sans fuite. **Durée :** 18 min · **Difficulté :** avancé · **Barème :** 5 pts

Un collègue présente le code suivant. La colonne `appel_retention` vaut 1 si le client a été contacté par le service de fidélisation **après avoir déposé sa demande de résiliation**, et 0 sinon. Le score affiché vaut 0,99.

```
1  df = pd.read_csv("tunicom.csv")
2  X = df.drop(columns=["resilie"])
3  y = df["resilie"]
4  X["age"] = X["age"].fillna(X["age"].median())
5  X["forfait"] = X["forfait"].map({"Basic": 0, "Standard": 1, "Premium": 2})
6  scaler = StandardScaler()
7  X_s = scaler.fit_transform(X)
8  X_tr, X_te, y_tr, y_te = train_test_split(X_s, y, test_size=0.25, random_state=42)
9  model = LogisticRegression().fit(X_tr, y_tr)
10 print(model.score(X_tr, y_tr))
```

On suppose ici que `X` ne contient que des colonnes numériques après la ligne 5 (`age`, `facture`, `nb_appels_support`, `forfait`, `appel_retention`).

Q6.1 (2 pts) Identifier **quatre** problèmes distincts. Pour chacun : la ligne ou la colonne concernée, le type de problème, sa conséquence et la correction.

Q6.2 (1 pt) Dans le jeu d'apprentissage, 16 % des clients ont résilié. Après correction, le modèle obtient une exactitude (*accuracy*) de **0,85 sur le test**.
(a) Calculer l'exactitude de la baseline de la classe majoritaire.
(b) Le modèle corrigé est-il convaincant ? Pourquoi l'exactitude est-elle trompeuse ici ? Que faudrait-il regarder du point de vue de TuniCom ?

Q6.3 (1,25 pt) Voici l'audit des valeurs manquantes sur le **jeu d'apprentissage** (1 500 clients, taux global de résiliation : 16 %) :

Colonne	Valeurs manquantes	Résiliation si manquant	Résiliation si renseigné
`age`	60 (4 %)	16 %	16 %
`satisfaction`	450 (30 %)	30 %	10 %
`code_promo`	1 380 (92 %)	15 %	27,5 %
`mode_paiement`	6 (0,4 %)	—	—

Proposer et justifier une décision pour chaque colonne. Que penser de la suppression de toutes les lignes incomplètes ?

Q6.4 (0,75 pt) Écrire, en pseudo-code ordonné (5 à 7 étapes), le protocole corrigé, de la lecture des données à l'évaluation finale.

Barème indicatif

Exercice	Thème	Points
1	Cadrer le problème et typer les variables	2,5
2	Centre, dispersion, imputation	3,5
3	Valeurs aberrantes : IQR et z-score	3
4	Encodage et mise à l'échelle	3,5
5	Covariance et corrélation	2,5
6	Synthèse : fuite, baseline, protocole	5
	Total	**20**

Autoévaluation

Répondez en quelques lignes, pour vous-même.

1. Expliquez avec vos mots pourquoi une statistique apprise (médiane, μ, σ, seuil) doit être calculée sur l'apprentissage seulement.

2. Quelle notion de ce TD pourriez-vous maintenant expliquer à un camarade absent ? Donnez un exemple.

3. Quelle question vous a posé le plus de difficultés, et qu'est-ce qui reste flou ?